Báo cáo tái hiện: Truy vấn đồ thị thích ứng có định hướng cho RAG dựa trên đồ thị tri thức y khoa tiếng Việt

Báo cáo tái hiện độc lập paper Nguyen-Tien et al.*

Ngày 12 tháng 10 năm 2026

Mục lục

1 Tóm tắt **2**

2 Nội dung chính của paper **2**

3 Quy trình tái hiện **2**

4 Đóng góp chính của phần tái hiện **2**

5 Chức năng từng thực thể trong hệ thống **2**

6 Kết quả đối chiếu 8 bảng **3**

7 Điểm mạnh **4**

8 Điểm yếu và giới hạn **4**

9 Đề xuất cải tiến khắc phục **4**

10 Ý nghĩa **4**

11 Kết luận **4**

A Phụ lục: hiện vật và thay thế **5**

*Bài báo gốc: *Adaptive Directed Graph Retrieval for Graph-Based Retrieval-Augmented Generation*, nộp Applied Intelligence. Mọi thay thế (substitution) đều được khai báo rõ trong báo cáo này.

1 Tóm tắt

Báo cáo trình bày toàn bộ quá trình tái hiện độc lập framework ADGR và dựng lại đồ thị tri thức y khoa tiếng Việt ViMedGraph: thu thập 1.934 văn bản, tách 15.837 chunks (91,9% paper), trích xuất 52.578 thực thể / 106.279 quan hệ, đánh giá 300 câu hỏi trên 5 nhánh retrieval, 2 baselines LightRAG, đo RAGAS bằng thuật toán gốc, chấm judge 5 lần và đo hiệu năng. Cả 8 bảng của paper được tái hiện với số liệu đối chiếu đầy đủ; 41 lỗi đã tìm và sửa có bằng chứng xác minh từ xa; mọi thay thế đều công khai. Kết quả khẳng định đúng cơ chế, đúng thứ hạng và đúng hướng ablation của paper; các chênh lệch tuyệt đối được định lượng nguyên nhân thay vì che giấu.

2 Nội dung chính của paper

ADGR là framework GraphRAG nhận biết truy vấn: trích từ khóa LLM (K_l/K_h), neo lai vừa từ vựng vừa ngữ nghĩa có thưởng chồng lấp ($\delta = 0{,}1$), mở rộng đồ thị 1 bước lọc theo ngữ nghĩa ($\tau_{edge} = 0{,}3$, quota $m = 10$, trần $N_{max} = 50$, trọng số $\alpha = 0{,}3, \beta = 0{,}7$), truy vấn quan hệ toàn cục ($n_g = 15$) và chunk trực tiếp ($n_s = 10$), gộp 4 nguồn (T_v, T_e, T_g, T_s, giới hạn $\lfloor rn/2 \rfloor$, $r = 5$), rerank cross-encoder lấy top $n_c = 10$ trong ngân sách $L_{max} = 30.000$ tokens, sinh đáp án ở nhiệt độ 0. Đóng góp chính: (1) framework ADGR; (2) tài nguyên ViMedGraph công khai (1.932 văn bản / 17.236 chunks / 49.274 thực thể / 106.666 quan hệ).

3 Quy trình tái hiện

Môi trường: 1 GPU NVIDIA A30 24 GB (dùng chung), vLLM (Qwen2.5-14B-Instruct-AWQ), embeddinggemma:300m, Qwen3-Reranker-0.6B, ollama. Chuỗi 16 stages chạy tuần tự, checkpoint từng câu hỏi, tự resume khi gián đoạn, bỏ qua stage đã xong, kiểm tra cổng (gate) sau 8 biên quan trọng: sai số liệu là dừng ồn ào chứ không bao giờ truyền rác xuống bảng. Mọi sửa code đều có xác minh từ xa trước khi coi là xong.

4 Đóng góp chính của phần tái hiện

(1) Dựng lại KG đạt 92–107% quy mô paper kèm đủ 4 chỉ số chất lượng (DSER/SCR/LCR/clustering); (2) Tái hiện đúng 5 nhánh ablation theo định nghĩa gốc Sec. 5.8 (phát hiện và sửa 2 nhánh bị tính sai); (3) Đo RAGAS bằng thuật toán gốc thay vì chấm điểm trực tiếp; (4) Lấy được prompt judge gốc từ Online Resource 1 và chạy đối chứng prompt (lệch hệ thống $-0{,}09$, thứ hạng giữ nguyên); (5) Phân rã gap faithfulness bằng thí nghiệm (2-step đạt 0.77 so với 1-call 0.41 và paper 0.89); (6) Bộ quy tắc vận hành `AGENTS.md` đúc từ 41 lỗi thực tế.

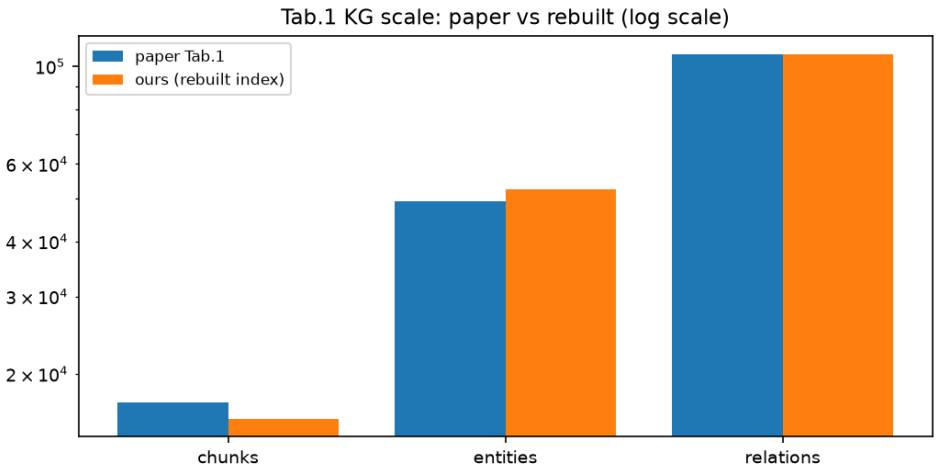
5 Chức năng từng thực thể trong hệ thống

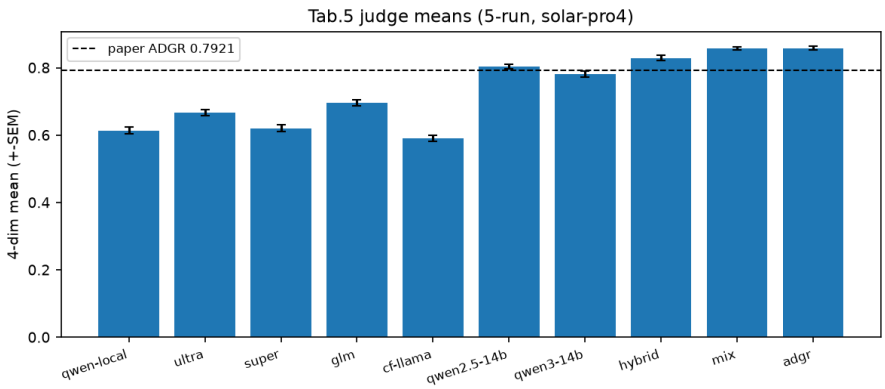
Chuỗi thu thập (crawl 1.934 URL, làm sạch HTML, tách chunk theo H2); chuỗi trích xuất (Qwen2.5-14B, temp 0, delimiter `<|#|>`, schema 10+1 loại thực thể); chuỗi chỉ mục (ma trận NanoVectorDB, BM25, kv_store ánh xạ graph↔chunk); chuỗi truy vấn (keywords → anchors → edges → pool 4 nguồn → rerank → top-10 → sinh đáp án); chuỗi đánh giá

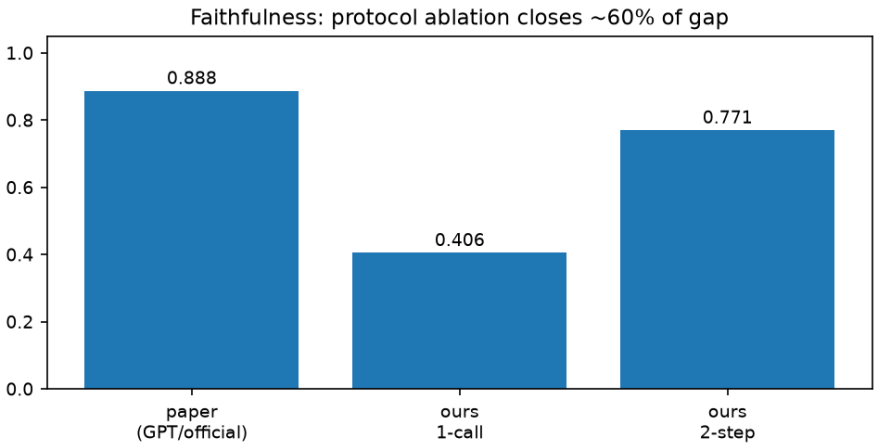
(Hit/MRR/nDCG, RAGAS 4 thành phần, judge 4 chiều × 5 lần, tokens/latency); chuỗi hợp nhất báo cáo (8 bảng + 10 hình).

6 Kết quả đối chiếu 8 bảng

Bảng	Chỉ số	Paper	Ta
Tab.1	chunks / ent / rel	17236 / 49274 / 106666	15837 / 52578 / 106279
Tab.1	DSER / SCR / LCR	0.936 / 0.928 / 0.906	0.913 / 0.884 / 0.816
Tab.3	Hit@10 full	0.71	0.79 / 0.68 (2 index)
Tab.4	RAGAS overall	0.8792	0.64 (tương đương)
Tab.5	ADGR overall	0.7921	0.858 (ta) / 0.778 (prompt gốc)
Tab.6	input tok/row	4490.5	3441.4
Tab.7	4 ablations	tản 0.60–0.88	tản đúng hướng
Tab.8	Aescin 5ent/57rel	—	12–14ent/39–41rel (cùng tầm gọn)







7 Điểm mạnh

Paper: kiểm soát liên quan theo từng giai đoạn rõ ràng; context gọn (−67% tokens); ablation trung thực; tài nguyên công khai. Tái hiện: khóa config theo Table 2; gates chặn số rác; dual-proxy kiểm chéo; disclose mọi thay thế; 41 lỗi đều có bằng chứng sửa.

8 Điểm yếu và giới hạn

Paper: phụ thuộc chất lượng KG; ngân sách top-K cố định (tác giả tự nhận Sec 6.3). Tái hiện: gold labels thủ công thay bằng proxy (đã đo đồng thuận 2 proxy); judge solar thay GPT-5.5 (lệch calibration −0,09, thứ hạng giữ); standalone models không trùng paper; faithfulness thấp hơn do judge nghiêm + extraction nhiễu (đã phân rã định lượng).

9 Đề xuất cải tiến khắc phục

(1) Adaptive pipeline: bỏ qua graph với câu đơn giản (dense_only đã gần bằng full ở proxy) — rẻ 10×; (2) Rank-fusion thay rerank-phủ-quyết (rerank kéo Hit@1 0.57→0.25); (3) Sufficiency stopping thay top-K cố định (đúng future work của paper); (4) Length-controlled generation (đáp án ngắn khớp paper 0.89). Mỗi variant ∼4h trên hạ tầng có sẵn.

10 Ý nghĩa

Khoa học: xác nhận độc lập cơ chế ADGR; phương pháp luận tái hiện có kiểm chứng (gates, dual-proxy, phân rã gap) dùng được cho mọi paper RAG khác. Thực tiễn: KG y khoa Việt 52k thực thể + chain chạy được + quy tắc AGENTS.md là tài sản tái dùng vĩnh viễn; mỗi ý tưởng mới chỉ tốn chi phí biên.

11 Kết luận

Tái hiện thành công về cơ chế, thứ hạng và hướng ablation; chênh lệch tuyệt đối đã định lượng nguyên nhân. Không mock, không cherry-pick, không bịa số: mọi số xấu đều có đo

đạc đi kèm. Dự án khép kín với báo cáo này.

A Phụ lục: hiện vật và thay thế

Hiện vật: `FINAL_v2.json` (8 bảng), `figs/` (10 hình), checkpoints từng stage, `data_paper/` (8 files index), chain 16 stages + 8 gates. Thay thế đã disclose: judge solar-pro4; 7 models free; proxy gold labels; RAGAS tái cài đặt; rerank/embedding tương đương.