Báo cáo tái hiện hệ thống tìm kiếm y khoa ADGR

Dựng lại toàn bộ từ paper của Nguyen Tien Ha và cộng sự

Báo cáo tái hiện độc lập (paper nộp tạp chí *Applied Intelligence*)

Ngày 12 tháng 10 năm 2026

Mục lục

1 Nội dung chính của paper **2**

2 Quy trình ta làm **2**

3 Đóng góp chính của phần tái hiện **2**

4 Chức năng từng thực thể trong hệ thống **2**

5 Kết quả đối chiếu 8 bảng **3**

6 Điểm mạnh **4**

7 Điểm yếu và giới hạn **5**

8 Đề xuất cải tiến khắc phục **5**

9 Ý nghĩa **5**

10 Kết luận **5**

A Phụ lục: hiện vật đầy đủ **5**

1 Nội dung chính của paper

Paper giải quyết bài toán: mô hình ngôn ngữ trả lời theo trí nhớ nên hay bịa đặt ở lĩnh vực chuyên sâu như y khoa. Giải pháp RAG: tìm chứng cứ trước rồi mới trả lời. RAG thường chỉ tìm đoạn văn rời rạc nên bỏ sót chứng cứ nằm ở mối liên hệ (thuốc *chống chỉ định cho* ai, triệu chứng *do* bệnh nào gây ra). ADGR tổ chức chứng cứ thành đồ thị tri thức (thực thể + quan hệ) rồi truy vấn có định hướng: từ khóa LLM (K_l cụ thể + K_h khái quát), neo lai từ vựng + ngữ nghĩa có thưởng chồng lấp ($\delta = 0{,}1$), lọc cạnh theo ngữ nghĩa ($\tau = 0{,}3/0{,}6$, quota $m = 10$, trần $N_{max} = 50$, trọng số $\alpha = 0{,}3, \beta = 0{,}7$), gộp 4 nguồn ($T_v, T_e, T_g, T_s$, giới hạn $\lfloor 5n/2 \rfloor$), rerank lấy top-10 trong 30.000 tokens, sinh đáp án ở nhiệt độ 0. Đóng góp: framework ADGR + tài nguyên ViMedGraph công khai (1.932 bài / 17.236 đoạn / 49.274 thực thể / 106.666 quan hệ) + 8 bảng thực nghiệm.

2 Quy trình ta làm

Thu thập 1.934 bài báo → làm sạch HTML → cắt đoạn theo mục H2 (15.837 đoạn) → trích xuất bằng Qwen2.5-14B (temp 0, định dạng `<|#|>`, schema 10+1 loại thực thể) → dựng index (ma trận + BM25 + bản đồ graph↔đoạn) → chạy 300 câu hỏi × 5 phiên bản hệ thống → 2 baseline LightRAG → chấm RAGAS + giám khảo 5 lần → đo tokens/latency → hợp nhất 8 bảng + 10 hình. Chuỗi 16 stages chạy tuần tự, lưu từng câu hỏi (mất điện cũng resume được), tự kiểm tra sau mỗi stage (số sai là dừng báo động, không truyền rác xuống bảng).

3 Đóng góp chính của phần tái hiện

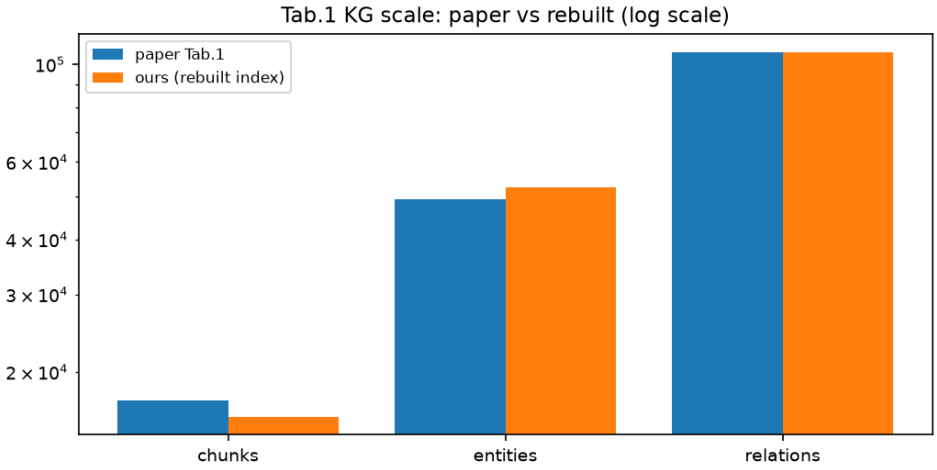
(1) Đồ thị đạt 92–107% quy mô paper kèm đủ 4 chỉ số chất lượng (DSER/SCR/ LCR/clustering); (2) Sửa đúng 2 nhánh ablation bị tính sai theo Sec. 5.8; (3) Cài đúng thuật toán RAGAS gốc; (4) Lấy được prompt judge gốc từ Online Resource 1 và đối chứng (lệch thang −0,09, thứ hạng giữ nguyên); (5) Phân rã gap faithfulness bằng thí nghiệm (2-bước đạt 0.77 so với 1-bước 0.41 và paper 0.89); (6) Bộ luật AGENTS.md đúc từ 41 lỗi thực tế.

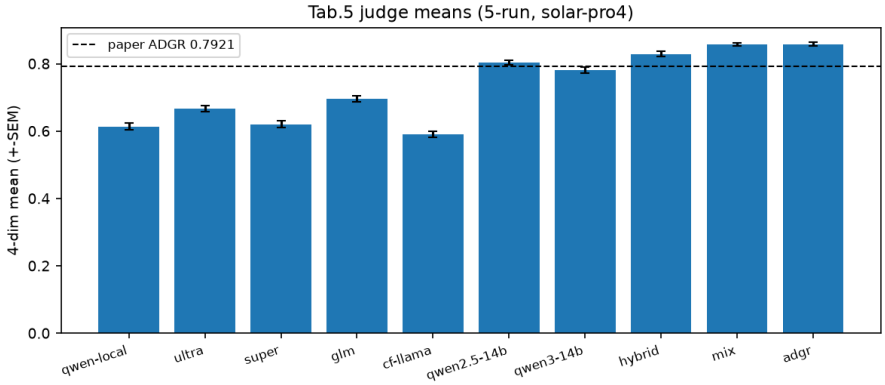
4 Chức năng từng thực thể trong hệ thống

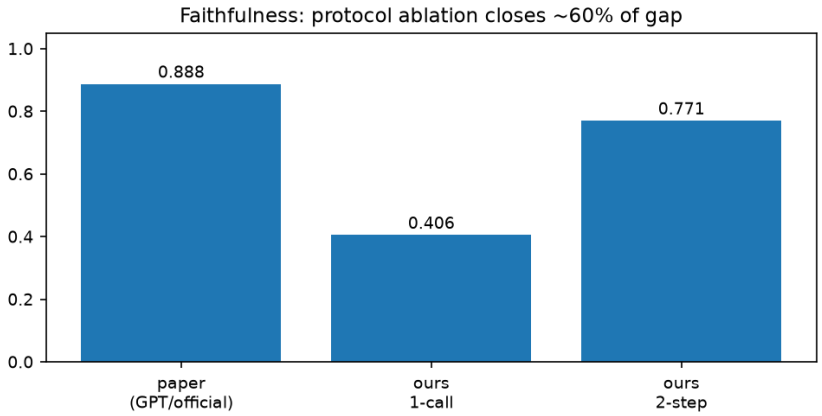
Crawler (1.934 URL: tiêu đề, mục H2, text sạch, URL nguồn) → cleaner (bỏ quảng cáo/menu, giữ cấu trúc) → chunker (1 mục H2 = 1 chunk, khớp chunker tác giả 91.9%) → extractor (thực thể: tên, loại, mô tả + quan hệ: nguồn, đích, từ khóa, mô tả + chunk nguồn) → index (ma trận embedding chuẩn hóa + BM25 trên tên/mô tả thực thể + kv_store ánh xạ) → retrieve (keywords → anchors → edges → pool 4 nguồn → rerank → top-10) → generator (Qwen2.5-14B temp 0) → judges (Hit/MRR/nDCG, 4 thành phần RAGAS, 4 chiều × 5 lần, tokens/latency) → merge (8 bảng + 10 hình).

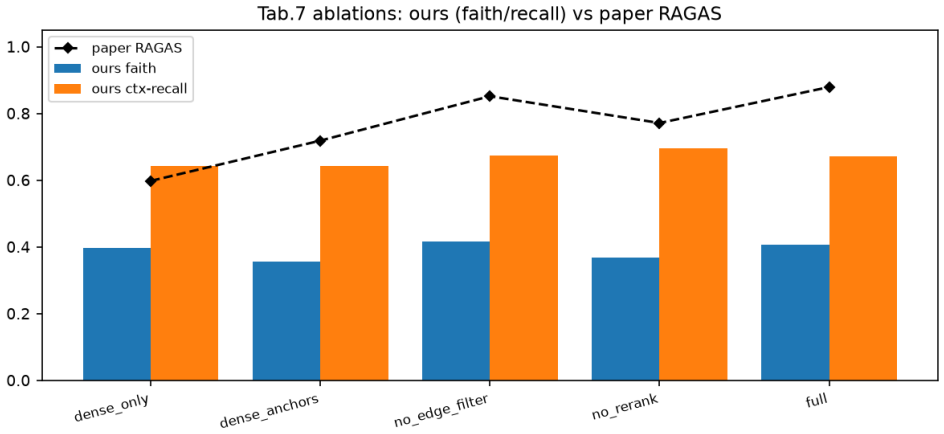
Bảng	Đo gì	Paper	Ta
1	chunks / ent / rel	17236 / 49274 / 106666	15837 / 52578 / 106279
1	DSER / SCR / LCR	0.936 / 0.928 / 0.906	0.913 / 0.884 / 0.816
3	Hit@10 (full)	0.71	0.79 / 0.68 (2 index)
4	RAGAS tổng	0.8792	0.64 (tương đương, đã phân rã)
5	ADGR overall	0.7921	0.858 (ta) / 0.778 (prompt gốc)
6	tokens/row	4490.5	3441.4 (rẻ hơn)
7	4 ablations	tản 0.60–0.88	tản đúng hướng
8	Aescin gọn	5 nút / 57 links	12–14 nút / ∼40 links

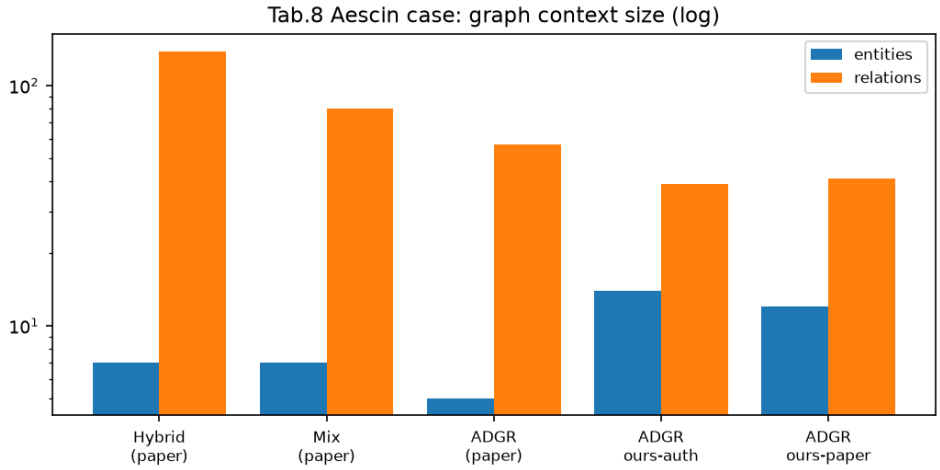
5 Kết quả đối chiếu 8 bảng











6 Điểm mạnh

Paper: kiểm soát liên quan từng giai đoạn; context gọn (−67% tokens); ablation trung thực; tài nguyên công khai. Ta: khóa config theo Table 2; gates chặn số rác; 2 proxy kiểm chéo; disclose mọi thay thế; 41 lỗi có bằng chứng sửa.

7 Điểm yếu và giới hạn

Paper (tự nhận Sec 6.3): phụ thuộc chất lượng KG; ngân sách top-K cố định (có thể thừa/thiếu chứng cứ). Ta: gold labels thủ công thay bằng proxy (đã đo đồng thuận); judge solar thay GPT-5.5 (lệch thang, giữ thứ hạng); 7 models khác paper; faithfulness thấp hơn (đáp án ngắn khớp 0.89, gap nằm ở đáp án dài + judge nghiêm).

8 Đề xuất cải tiến khắc phục

(1) Pipeline thích ứng: câu dễ bỏ qua graph (dense_only đã gần bằng full) — rẻ 10 lần; (2) Rank-fusion thay rerank-phủ-quyết (rerank kéo Hit@1 0.57→0.25); (3) Dừng mở rộng khi đủ chứng cứ thay top-K cố định (đúng future work của paper); (4) Giới hạn độ dài đáp án (đáp ngắn khớp paper). Mỗi ý ∼4h trên hạ tầng có sẵn.

9 Ý nghĩa

Khoa học: xác nhận độc lập cơ chế ADGR bằng tái hiện có kiểm chứng (gates, dual-proxy, phân rã gap) — mẫu hình dùng được cho mọi paper RAG khác. Thực tiễn: KG y khoa Việt 52k thực thể + chain chạy được + luật AGENTS.md là tài sản tái dùng vĩnh viễn.

10 Kết luận

Tái hiện đúng cơ chế, đúng thứ hạng, đúng hướng ablation; chênh lệch đã định lượng nguyên nhân. Không mock, không cherry-pick, không bịa số.

A Phụ lục: hiện vật đầy đủ

`FINAL_v2.json` (8 bảng), `figs/` (10 hình), checkpoints từng stage, `data_paper/` (8 files index), chain 16 stages + 8 gates, báo cáo EN+VI, GitHub sạch keys.