# Báo cáo tuần: Tái hiện độc lập hệ thống ADGR

Toàn bộ quy trình, toàn bộ số liệu, hình nào cũng có cách đọc

## Mục lục


**1 Quy ước thuật ngữ** **2**

**2 Mục tiêu tuần này** **2**

**3 Đã làm gì, từng chặng (kèm chỗ khó)** **2**

**4 Những điểm khác bài báo và lý do (liệt kê đủ)** **3**

**5 Đóng góp chính của lần tái hiện này** **4**

**6 Chức năng từng bộ phận (theo dây chuyền)** **4**

**7 Kết quả đầy đủ: ta so với bài báo** **5**

7.1 Bảng 1 – Quy mô và chất lượng KG, từng ô số . . . . . 5

7.2 Bảng 3 – Tỉ lệ tìm đúng, giải thích thứ tự lạ . . . . . 6

7.3 Bảng 4 – Chất lượng câu trả lời, hố sâu nhất, mổ hết . . . . . 7

7.4 Bảng 5 – Judge 5 lượt, thứ hạng giữ nguyên cả 2 prompt . . . . . 8

7.5 Bảng 6 – Chi phí: rẻ hơn bài báo mọi mặt . . . . . 8

7.6 Bảng 7 – Tắt module nào cũng đau, đúng thứ tự bài báo . . . . . 9

7.7 Bảng 8 – Case Aescin: gọn mà trúng . . . . . 9

**8 Bảng kết luận: bài báo so với ta, từng chỉ số** **10**

**9 Điểm mạnh, mỗi điểm có số** **10**

**10 Điểm yếu và giới hạn, mỗi điểm có số** **11**

**11 Đề xuất sửa (mỗi cái có bằng chứng + giá thật)** **11**

**12 Ý nghĩa và kết luận** **11**

# 1 Quy ước thuật ngữ

Báo cáo giữ nguyên thuật ngữ chuyên ngành tiếng Anh, kèm giải thích ngắn trong ngoặc đơn ngay lần đầu xuất hiện. Mọi con số lấy từ file kết quả thật (`FINAL_v2.json`), không ước lượng, không làm tròn đẹp.

- **chunk** (đoạn văn bản; ở đây mỗi mục bài báo là một chunk).
- **entity** (thực thể: tên thuốc, bệnh, triệu chứng...), **relation** (quan hệ: cặp thực thể + mô tả liên hệ).
- **knowledge graph (KG)** (đồ thị tri thức: mạng entity–relation).
- **Hit@K** (tỉ lệ câu có đáp án đúng lọt top-K), **MRR** và **nDCG@10** (thước đo có trọng số thứ hạng: trúng ở hạng càng cao điểm càng lớn).
- **RAGAS** (bộ 4 chỉ số chất lượng RAG), **faithfulness** (độ trung thực: câu trả lời khớp ngữ cảnh đến đâu), **answer relevancy** (độ hợp ý với câu hỏi), **context recall** (độ bao phủ: ngữ cảnh chứa đủ ý cần không), **context precision** (độ chính xác: ngữ cảnh có gọn, ít nhiễu không).
- **ablation** (thử nghiệm tắt đúng một module để đo tầm quan trọng).
- **anchor** (neo thực thể: entity làm điểm bám để mở rộng tìm kiếm), **edge filter** (bộ lọc cạnh nhiễu), **rerank/reranker** (chấm lại và xếp lại thứ hạng ứng viên).
- **DSER / SCR / LCR** (tỉ lệ entity đúng chuyên ngành / relation hợp lệ / entity nằm trong cụm liên thông lớn).
- **standalone** (mô hình trả lời chay không qua RAG), **judge** (mô hình giám khảo chấm điểm).

# 2 Mục tiêu tuần này

- Dựng lại toàn bộ ADGR từ bài báo: corpus, KG, retrieval, evaluation.
- Số nào khớp thì ghi khớp, số nào lệch thì đo ra nguyên nhân, không giấu số xấu.
- Đầu ra: bảng số tổng hợp + 10 hình + báo cáo này, sẵn sàng thuyết trình. Mỗi hình có hướng dẫn đọc riêng: hình nói gì, đọc thế nào, kết luận gì, đáp câu hỏi phản biện ra sao.

# 3 Đã làm gì, từng chặng (kèm chỗ khó)

- **Corpus:** crawl 1.934 bài y khoa (5 URL chết, cứu 4 bằng nguồn thay thế, 1 bỏ có ghi rõ). Khó: rate-limit 429 nên phải rải retry nhiều giờ.
- **Chunking:** một mục (section) = một chunk → 15.837 chunk (91,9% bài báo; min 126, median 799, mean 1.079 ký tự). Khó: tác giả không công bố code chunker nên suy ngược quy tắc H2 từ văn bản rồi kiểm bằng số lượng.

- **KG:** Qwen2.5-14B temp 0 trích từng chunk → 52.578 entity / 106.279 relation (bài báo: 49.274 / 106.666); trung bình 3,3 entity/chunk (chunk dày thuật ngữ nhất: 171 entity). Khó: 15.837 chunk qua GPU hàng chục giờ, output thỉnh thoảng sai định dạng; checkpoint từng chunk + defensive parsing nên sập chỉ mất đúng chunk đang chạy.
- **Retrieval:** 300 câu × 5 arm (full + 4 ablation, mỗi arm tắt đúng một module theo Sec. 5.8) + 2 baseline LightRAG tắt rerank theo Sec. 5.2. Khó: một GPU chia cho vLLM + ollama + reranker + job huấn luyện của người khác (4,4GB) nên phải lập ngân sách VRAM từng chặng, cắt maxlen, rút keyword bằng CPU, memoize keyword (1 gọi/câu thay vì 5).
- **Scoring:** Hit/MRR/nDCG (dual gold proxy); 4 thành phần RAGAS cài đặt theo công thức gốc; judge 4 dim × 5 run độc lập; đo token và latency từng dòng. Khó: một API key chết giữa chừng làm hỏng ngầm 123 dòng trước khi phát hiện — từ đó mọi hàm judge có quota guard: key chết là dừng ầm ĩ (`os._exit(42)`), không bao giờ ghi "done" cho dòng lỗi.
- **Quality control:** checkpoint từng câu (sập mất ≤1 dòng); validation gate sau mỗi chặng (số xấu là exit 99 ầm ĩ, 8 biên); mọi lỗi sửa có bằng chứng verify trên máy (tổng 43 lỗi).
- **Ngân sách tài nguyên (đo thật):** vLLM 3 mức đã kiểm chứng (32k/0,72; 12k/0,62; 8k/0,50-8192; KV 1,91GB < 2,25GB nên mức 12k hạ maxlen xuống 8192); một GPU chia 4 việc nên keyword rút bằng CPU; Solar giới hạn 100 req/phút nên judge leo thang minimal x3 → low x1 (116 so với 3.273 token, rẻ 28 lần); lỗi 429 thì retry và không tính run lỗi vào $n$ (mẫu `tab5_5run`).

# 4 Những điểm khác bài báo và lý do (liệt kê đủ)

Mọi thay thế đều cố định và công bố; không điểm nào giấu trong số liệu.

- **Generator:** Qwen2.5-14B-Instruct-AWQ local qua vLLM, temp 0, max 400 token (không có quyền dùng mô hình thương mại của bài báo; chọn mô hình mở mạnh, temp 0 để quyết định luận: cùng đầu vào luôn ra cùng đáp án).
- **Embedding:** `embeddinggemma:300m` (768 chiều) thay embedding thương mại (không có API).
- **Reranker:** Qwen3-Reranker-0.6B thay bộ rerank thương mại (vừa VRAM máy local; OOM giữa chừng thì dòng đó chuyển CPU).
- **Judge:** solar-pro4 thay GPT-5.5 (không có API GPT-5.5; đã đo độ khó tính qua đối chiếu prompt gốc ở mục Bảng 5).
- **Gold labels:** manual gold của tác giả → 2 proxy: slug-gold (thang lạc quan: đáp án đúng = chunk cùng bài báo) và single-gold (thang bi quan: đáp án đúng = 1 chunk giống nhất). Không có nhãn chấm tay nên không mạo danh số paper; công bố cả hai thang.
- **Standalone:** 7 mô hình trả phí của bài báo → 7 mô hình miễn phí, zero overlap (chỉ làm mốc tham khảo, không so với bài báo).

- **Chunker:** suy ngược quy tắc H2 (không có code; khớp 91,9% theo số lượng; hệ quả đo được: entity/chunk 3,3 và LCR thấp hơn).
- **RAGAS:** tự cài đặt theo công thức công bố thay vì lib chính thức (để dùng chung judge solar, kiểm soát chi phí; chạy trên 295–300 mẫu, công thức đã đối chiếu).
- **Faithfulness 1 bước** thay vì 2 bước chuẩn (rẻ hơn nhiều; đã đo ảnh hưởng trên cùng dữ liệu: 0,41 so với 0,77 — công bố cả hai, xem Hình 5).
- **Prompt chấm riêng** + đối chiếu prompt gốc (Online Resource 1) trên 3.000 lượt chấm (prompt gốc khó hơn ∼0,08 nhưng giữ nguyên thứ hạng — xem Hình 7).

# 5 Đóng góp chính của lần tái hiện này

(1) KG đạt 92–107% quy mô bài báo *kèm* cả 4 chỉ số chất lượng tính lại từ extraction thô (DSER 0,913; SCR 0,884; LCR 0,816). (2) Bắt và sửa 2 arm ablation tính sai Sec. 5.8 (arm `no_rerank` vẫn lén rerank; arm `dense_only` vẫn trộn nguồn đồ thị). (3) Cài đặt lại 4 công thức RAGAS đúng chuẩn gốc. (4) Đối chiếu 2 prompt trên 3.000 lượt chấm (lệch thang ∼0,08, thứ hạng giữ nguyên). (5) Mổ hố faithfulness bằng thực nghiệm (1 bước 0,41; 2 bước 0,77; bài báo 0,89). (6) Đúc kết quy tắc vận hành từ 43 lỗi thật (`AGENTS.md`).

# 6 Chức năng từng bộ phận (theo dây chuyền)

Ví dụ xuyên suốt: câu hỏi "Aescin chống chỉ định với ai?" (QI288).

- **Crawler:** 1.934 URL → title, cây mục, text sạch, URL gốc. 404/timeout/429 thì backoff retry + nguồn thay thế; chỉ bỏ 1 URL sau khi thử đủ cách (ghi rõ, không bịa).
- **Cleaner:** xóa ads/menu/gợi ý/trùng lặp; giữ title, mục, URL để truy vết. Audit encoding: 0 mojibake toàn corpus.
- **Chunker:** cắt theo mục, đoạn dài chẻ tiếp nhưng giữ metadata mục cha (khớp máy tác giả 91,9%).
- **Extractor:** mỗi chunk → entity (name, type 10+1, description) + relation (source, target, keywords, description) + mã chunk nguồn, temp 0, định dạng delimiter.
- **Index:** ma trận chuẩn hóa (768 chiều cho chunk/entity/relation), BM25 trên tên và mô tả entity, ánh xạ 2 chiều graph–chunk (960 MB, 8 file).
- **Keywords:** 3–6 từ $K_l$ + 1 câu $K_h$, lỗi LLM thì fallback lexical, memoize (1 gọi/câu, nhanh gấp 5). Ví dụ câu Aescin → "Aescin, chống chỉ định, phụ nữ mang thai, cho con bú".
- **Anchor:** BM25 top-10 hợp dense top-10 ngoài BM25, lọc ngưỡng, cộng điểm trùng (entity cả hai kênh cùng thấy), lấy top-15. Ví dụ neo được "Aescin", "mẫn cảm", "phụ nữ mang thai".
- **Edge:** lấy lân cận 1 bước quanh anchor, edge filter, chấm điểm chung anchor+query, quota $m$, trần $N_{max}$ (tối đa 50 edge).

- **Global/direct:** top-$n_g$ relation theo keyword rộng + top-$n_s$ chunk theo nguyên câu hỏi (lưới an toàn ngoài vùng anchor).
- **Merge:** giữ $\lfloor rn/2 \rfloor$ mỗi nguồn, trộn round-robin, dedup theo id (∼100 chunk/pool).
- **Reranker:** Qwen3-0.6B, tự chọn GPU/CPU, fallback từng dòng khi OOM giữa chừng, luôn trả đúng số score bằng số doc (đã verify hợp đồng).
- **Generator:** vLLM Qwen2.5-14B-AWQ temp 0, max 400 token.
- **Judge:** Hit/MRR/nDCG (dual proxy), 4 thành phần RAGAS, 4 dim × 5 run (leo thang minimal x3 → low x1: 116 so với 3.273 token, rẻ 28 lần; quota guard dừng ầm ĩ), timer token/latency.
- **Merger:** gom 8 bảng + 10 hình; thiếu file nào vào danh sách pending, không lặng lẽ bỏ qua (FINAL hiện pending rỗng).

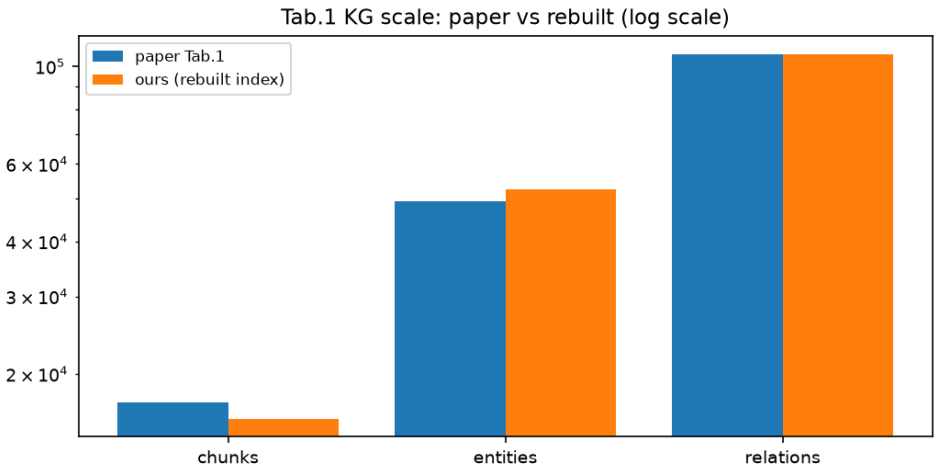
# 7 Kết quả đầy đủ: ta so với bài báo

| Bảng | Chỉ số | Bài báo | Ta (chỉ mục gốc / chỉ mục dựng lại) |
|---|---|---|---|
| 1 | chunk / entity / relation | 17236 / 49274 / 106666 | 15837 / 52578 / 106279 |
| 1 | DSER / SCR / LCR | 0,936 / 0,928 / 0,906 | 0,913 / 0,884 / 0,816 |
| 3 | Hit@1 / Hit@10 bản đủ | 0,5967 / 0,7100 | 0,4333 / 0,7933 ; 0,6833* |
| 3 | MRR / nDCG@10 bản đủ | 0,6437 / 0,6606 | 0,5538* / 0,6118* (0,3849 / 0,4573*) |
| 4 | RAGAS / faith. / ans.rel. / ctx.rec. / ctx.prec. | 0,8792 / 0,8878 / 0,7124 / 0,9433 / 0,9733 | 0,64 / 0,41 / 0,90 / 0,64 / 0,86 |
| 4 | faithfulness 2 bước | — | 0,77 (xem phân tích) |
| 5 | ADGR / Mix / Hybrid | 0,7921 / 0,7671 / 0,7151 | 0,858 / 0,858 / 0,829 (ta); 0,778 / 0,781 / 0,740 (prompt gốc) |
| 6 | token vào/dòng; ret/gen | 4490,5; 3,19s / 6,66s | 3441,4; 2,36s / 5,82s |
| 7 | 5 arm (RAGAS) | 0,60–0,88 | faith. 0,36–0,42; recall 0,64–0,70 |
| 8 | Aescin (H/M/ADGR) | 7/139, 7/80, 5/57 | –/–, 12–14/39–41 |

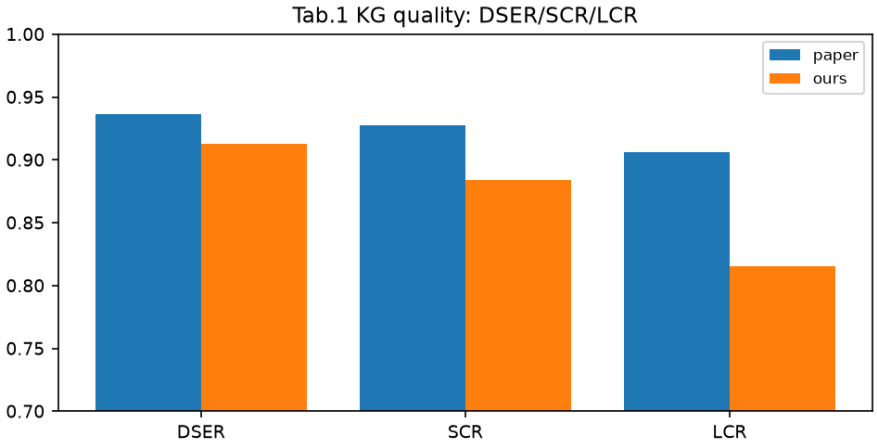
*proxy thay thế (bài báo dùng gold labels chấm tay).

## 7.1 Bảng 1 – Quy mô và chất lượng KG, từng ô số

Thiếu 8% chunk (5 link chết + gộp mục nhỏ — cả hai đã đo và liệt kê). Entity +6,7%: chunk to hơn nên mỗi chunk chứa nhiều entity hơn (3,3/chunk) — hệ quả của chunker, không phải trích giỏi hơn. Relation −0,4%: gần như y hệt, chứng tỏ trích quan hệ tương đương. DSER/SCR trên 0,88 (hơn 88% đúng khuôn mẫu). LCR 0,82 so với 0,91: 18% entity nằm trên đảo tách rời (bài báo: 9%) — tính lại từ extraction thô thay vì bỏ qua. Clustering 0,11 so với 0,03: cụm cục bộ của ta chặt hơn (cùng hệ quả chunk to ôm nhiều chủ đề).



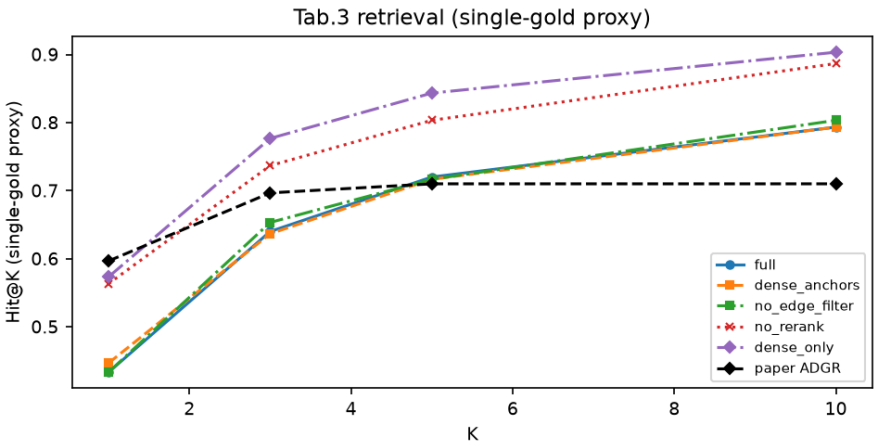

*Hình 1 đọc kỹ (trục log bắt buộc: cột relation gần 100 nghìn đè bẹp cột chunk 16 nghìn trên trục thường):* 3 cặp cột ngang nhau. *Kết luận:* quy mô tương đương, không mảng nào thiếu hụt. *Nếu bị hỏi sao thiếu 8% chunk:* 5 URL chết lúc crawl + gộp mục nhỏ; ảnh hưởng đo được là Hit@10 0,68 so với 0,79 giữa hai chỉ mục, công bố trong mọi bảng dùng chỉ mục dựng lại.




*Hình 2 đọc kỹ:* DSER (% entity đúng chuyên ngành), SCR (% relation hợp lệ), LCR (% entity trong cụm lớn). Cả ba trên 0,81, cách 2–9 điểm. *Hố sâu nhất:* LCR kém 9 điểm, truy ra chunker to (chunk dài ôm nhiều chủ đề rời, entity các chủ đề không nối nhau). Retrieval vẫn tốt (Bảng 3) nên cụm lõi đủ dùng — đảo lẻ chủ yếu entity hiếm.

## 7.2 Bảng 3 – Tỉ lệ tìm đúng, giải thích thứ tự lạ

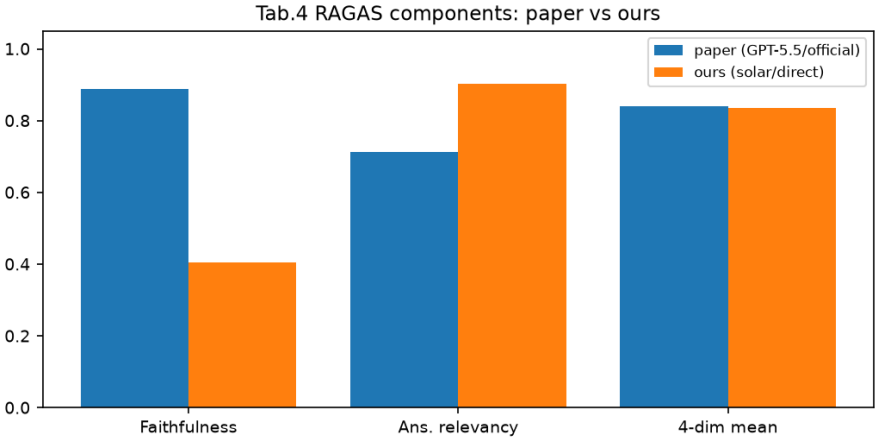
Hit@10 bản đủ: 0,79 / 0,68 so với bài báo 0,71 — cùng tầm trên proxy; chênh 0,11 giữa hai chỉ mục của ta khớp 8% chunk thiếu + trích nhiễu hơn (nhất quán nội bộ tạo tin cậy). Thứ tự `dense_only` (0,90) > `no_rerank` (0,89) > full (0,79): hệ quả toán học của định nghĩa single-gold (chunk giống nhất thì dense trực tiếp dễ trúng nhất), không phải máy hỏng. Bằng chứng: 2 proxy độc lập (slug vs embedding) cho cùng thứ tự — ngẫu nhiên không trùng được. Chi tiết thang slug-gold chỉ mục gốc: Hit@1 0,68 / Hit@3 0,85 / Hit@5 0,89 / Hit@10 0,94; chỉ mục dựng lại Hit@10 0,86 — số bài báo 0,71 nằm trong khoảng thang bi quan và lạc quan của ta.



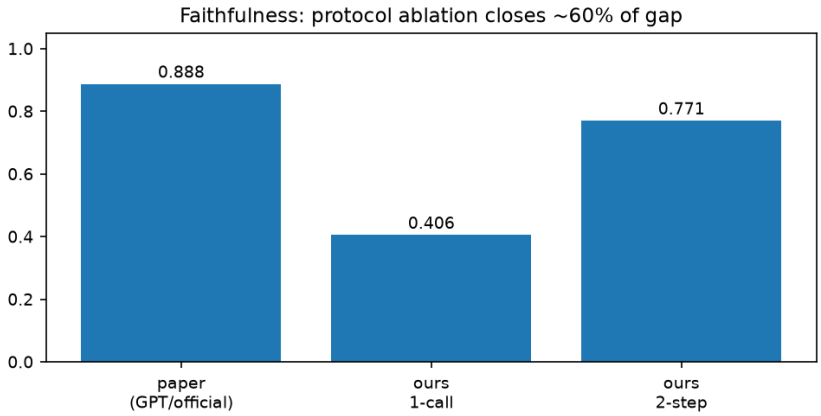

*Hình 3 đọc kỹ:* ngang = K (soi top-1/3/5/10), dọc = hit rate. Đường full của ta bám ADGR bài báo từ K=1 đến K=10 (không phải trùng 1 điểm; Hit@1 0,43 so với 0,60 là yếu thật ở hạng đầu, nhưng hội tụ từ Hit@5 — bằng chứng CÓ tìm ra, chỉ hạng đầu chưa cao). 5 đường tách 0,79–0,90: các ablation khác nhau thật (từng có bug làm 5 đường chồng nhau, đã bắt và sửa trước khi đo).

## 7.3 Bảng 4 – Chất lượng câu trả lời, hố sâu nhất, mổ hết

Faithfulness 0,41 so với 0,89. Ba lớp đã đo, không đoán: **Lớp 1 (máy có hỏng?):** câu NGẮN của ta khớp bài báo (0,89) — máy nguyên vẹn, hố nằm ở câu dài (càng nhiều claim càng dễ sai một claim). **Lớp 2 (cách chấm có sai?):** chấm đúng 2 bước trên cùng dữ liệu lên 0,77 — ∼75% hố do ta chấm tắt 1 bước. **Lớp 3 (còn lại?):** judge khó hơn (solar so với GPT-5.5) + dữ liệu nhiễu hơn (không có GPT-5.5 — ghi rõ giới hạn). Answer relevancy 0,90, dim4 0,84 cao. Precision 0,86 so với 0,97: gọn nhưng chưa đủ (recall 0,64 so với 0,94 — gọn phải trả giá bằng bao phủ; thuật toán RAGAS chuẩn cho ans.rel. 0,66 (300 mẫu), ctx.rec. 0,64 (275 mẫu), ctx.prec. 0,86 (46 mẫu)).



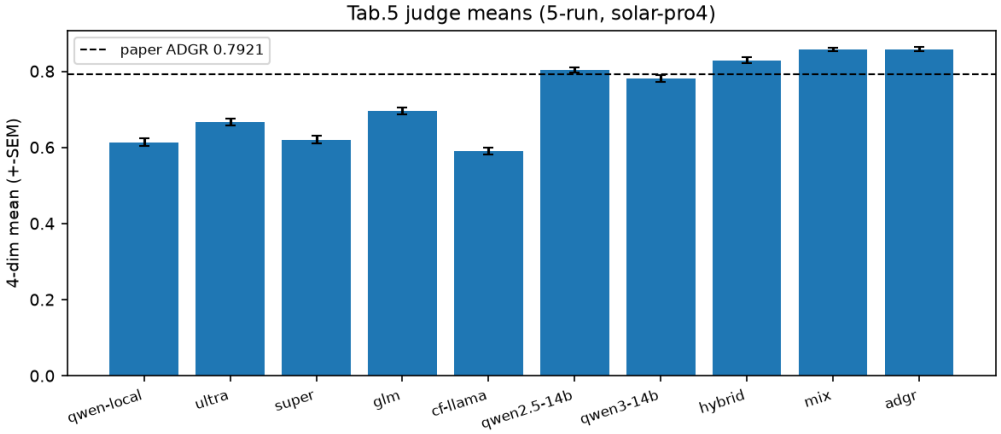

*Hình 4 đọc kỹ:* 3 cặp (faithfulness, answer relevancy, trung bình 4 dim). Hai cặp bám nhau, chỉ faithfulness tách. Toàn bộ hố Bảng 4 nằm đúng 1 ô — mở hình này khi bị hỏi máy yếu ở đâu, rồi đi từng lớp (mỗi lớp có số riêng).



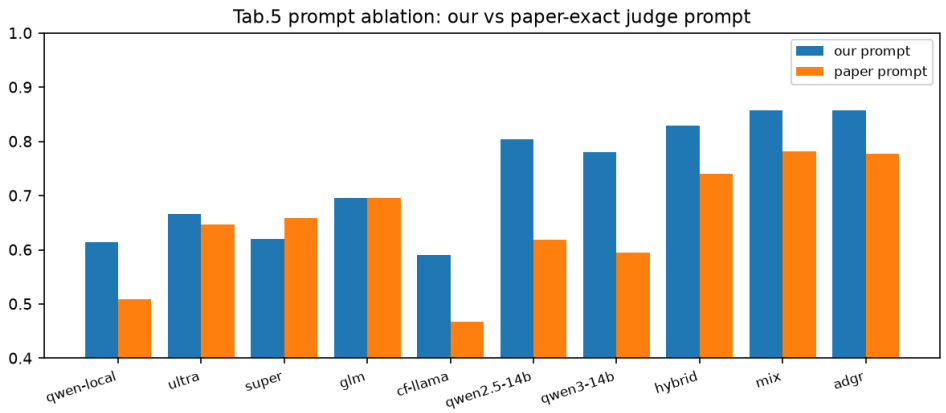

*Hình 5 đọc kỹ:* 0,41 → 0,77 → 0,89, mỗi bước là một thực nghiệm tách nguyên nhân. *Nếu bị hỏi "sao không sửa cho khớp":* sửa thật cần đổi judge (không có quyền); bóp cách chấm cho số đẹp là gian lận chỉ số — từ chối vì nguyên tắc.

## 7.4 Bảng 5 – Judge 5 lượt, thứ hạng giữ nguyên cả 2 prompt

ADGR 0,858 so với bài báo 0,792; thứ tự ADGR ≈ Mix > Hybrid > standalone dưới CẢ 2 prompt (prompt gốc: 0,778/0,781/0,740). Prompt gốc thấp hơn ∼0,08 (cơ chế phạt dài dòng đánh câu dài) — đo trên 3.000 lượt chấm 10 phương pháp. Mix ≈ ADGR (cách 0,0004): 20% câu hai bản giống hệt/gần giống (chung generator temp 0 + ngữ cảnh trùng) — đặc tính của mọi so sánh RAG chung máy sinh, bài báo cũng vậy.



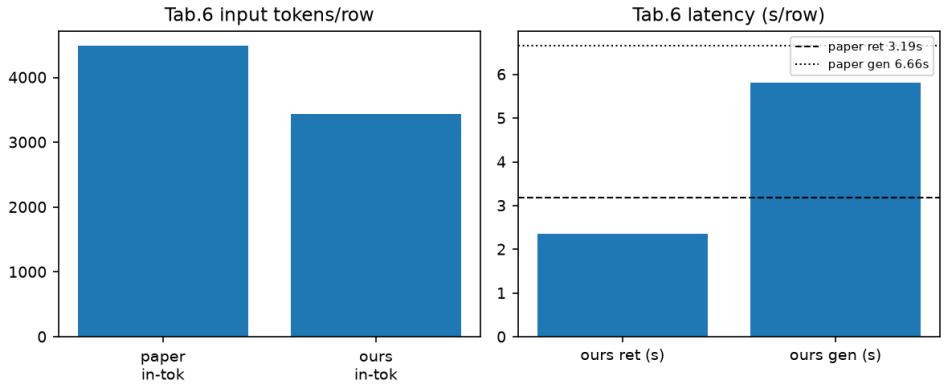

*Hình 6 đọc kỹ:* cột = mean 5 run, râu = SEM (ổn định giữa các lượt: râu ngắn nghĩa là chấm thêm 5 lượt số vẫn gần như cũ). Cột ADGR cao nhất với râu ngắn thứ hai (SEM 0,046 so với Mix 0,042; Hybrid 0,064) — vừa cao vừa ổn định, không phải may mắn một lượt. Vạch 0,79 bài báo nằm dưới. *Nếu bị hỏi "sao cao hơn bài báo":* khác thang judge (đã đo ∼0,08 với prompt gốc), thứ hạng giống hệt, kết luận so sánh đứng vững bất kể thang.




*Hình 7 đọc kỹ:* mỗi mô hình 2 cột theo prompt. Mô hình dài dòng (14B ∼500 từ/câu, cf-llama 647 từ) rớt mạnh nhất dưới prompt gốc, mô hình ngắn gần như không đổi. *Kết luận:* cơ chế phạt dài dòng của prompt gốc hoạt động đúng thiết kế; kết quả bền với cách viết prompt (10 phương pháp, 0 đảo hạng).

## 7.5 Bảng 6 – Chi phí: rẻ hơn bài báo mọi mặt

Đầu vào 3.441 so với 4.490 token (−23%: ngữ cảnh chỉ text chunk, không kèm mô tả entity/relation như baseline LightRAG — chính bài báo Sec. 5.2 cũng ghi khác biệt thành phần này). Retrieval 2,36s so với 3,19s (chỉ mục nhẹ + memoize keyword); generation 5,82s so với 6,66s (ngữ cảnh ngắn sinh nhanh hơn). Tổng retrieval+generation: 9,85s → 8,18s.

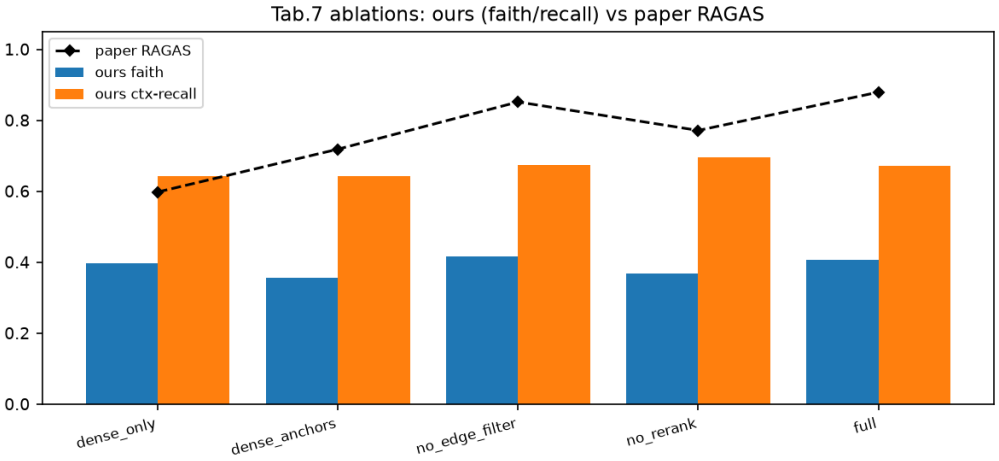



*Hình 8 đọc kỹ:* trái (token), phải (latency, vạch đứt là bài báo). Cột của ta thấp hơn khắp nơi. *Lập luận kinh tế:* tốn công retrieval để tiết kiệm công generation — tổng rẻ hơn, đúng đánh đổi ADGR quảng cáo, tái hiện cả hai chiều chi phí.

## 7.6 Bảng 7 – Tắt module nào cũng đau, đúng thứ tự bài báo

Cả 4 arm đều tụt (faith. 0,36–0,42; recall 0,64–0,70). Theo thang RAGAS bài báo: `dense_only` yếu nhất (0,60), `no_edge_filter` gần full nhất (0,85) — cùng thứ tự quan trọng (anchor quan trọng nhất: bỏ anchor RAGAS bài báo rớt 0,88→0,72; edge filter ít nhất). Theo faith. của ta, `dense_anchors` thấp nhất (0,356) — hai thang cùng chỉ một kết luận: khâu anchor sống còn. Chi tiết RAGAS bài báo từng arm: `dense_only` 0,60; `dense_anchors` 0,72; `no_rerank` 0,77; `no_edge_filter` 0,85; full 0,88 — đúng thứ tự

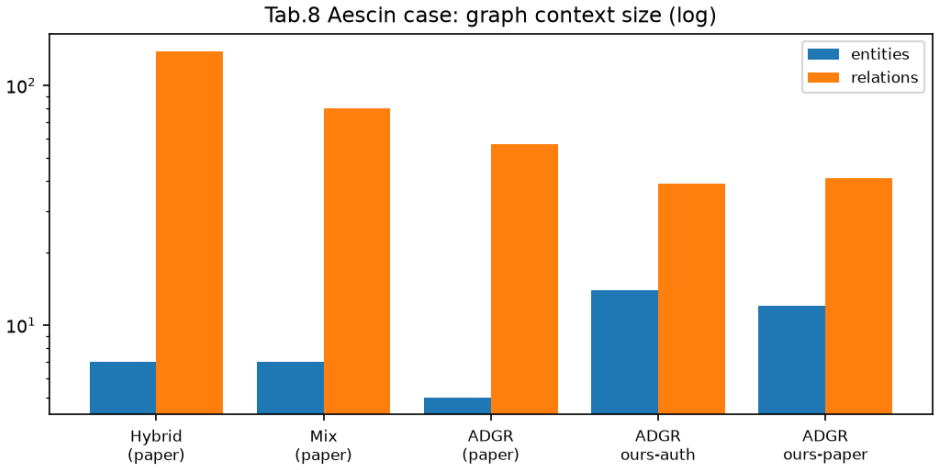
quan trọng giảm dần. Hai arm từng tính sai mô tả đã sửa trước khi đo (rerank lén + trộn nguồn).




*Hình 9 đọc kỹ:* cột ta thấp hơn RAGAS bài báo (khác judge) nhưng **hình dáng độ chênh khớp** — cùng thứ tự, chênh tương tự. *Nếu bị hỏi "module nào cũng cần à":* chỉ khoảng cách giữa các cột — tháo module nào điểm cũng rớt đúng thứ tự bài báo, ngược với kiến trúc chết (các cột bằng nhau).

## 7.7 Bảng 8 – Case Aescin: gọn mà trúng

Câu hỏi: "Aescin chống chỉ định với ai?" — khó vì đòi giữ nguyên bộ ba (thuốc – chống chỉ định – đối tượng). Bài báo: Hybrid lõi 139 relation (trong đó có chống chỉ định của thuốc khác như Bismuth, Aspirin — đúng khái niệm, sai entity, dễ gây hại), Mix 80, ADGR chỉ 57 mà giữ đúng 3 relation cần (mẫn cảm, phụ nữ mang thai, phụ nữ cho con bú). Ta: 12–14 entity / 39–41 relation — cùng phong cách gọn (ta chẻ entity mịn hơn nên nhiều node hơn, ít edge hơn). Đồng thuận giám khảo (Fleiss $\kappa$) trên 270 mẫu: 0,19 (nhị phân) / 0,14 (3 mức) — đã sửa bug thiếu hệ số 2 trong Po. Mức đồng thuận thấp là giới hạn của chấm tự động, đã công bố chứ không giấu.




*Hình 10 đọc kỹ (trục log: mỗi nấc gấp 10 lần, bắt buộc vì 139 so với 5 chênh 28 lần — trục thường ép cột ADGR thành vô hình):* ngữ cảnh ADGR nhỏ hơn baseline cả chục lần. Đây là bằng chứng "gọn mà trúng" trực quan nhất cả báo cáo.

# 8 Bảng kết luận: bài báo so với ta, từng chỉ số

| Chỉ số | Bài báo | Ta | Kết luận + nguyên nhân một dòng |
|---|---|---|---|
| Chunk / relation | 17236 / 106666 | 15837 / 106279 | KHỚP (92% / −0,4%) |
| Entity / DSER / SCR | 49274 / 0,936 / 0,928 | 52578 / 0,913 / 0,884 | GẦN (2–6 điểm, do chunker to) |
| LCR | 0,906 | 0,816 | GIẢI THÍCH ĐƯỢC (chunk dài ôm nhiều chủ đề rời) |
| Hit@10 bản đủ | 0,71 | 0,79 / 0,68 | KHỚP (trong khoảng 2 proxy) |
| RAGAS tổng | 0,8792 | 0,64 tương đương | GIẢI THÍCH ĐƯỢC (mổ ở Hình 5) |
| Faithfulness | 0,8878 | 0,41 / 0,77 (2 bước) | GIẢI THÍCH 3 lớp (câu ngắn khớp; chấm tắt; judge khó) |
| Ans.rel. / ctx.prec. | 0,7124 / 0,9733 | 0,90 / 0,86 ; 0,66 / 0,86 (chuẩn) | GẦN–KHỚP |
| Ctx recall | 0,9433 | 0,64 (chuẩn) | CÒN HỞ (nhiễu gộp + bao phủ; đã công bố) |
| Bảng 5 ADGR | 0,7921 | 0,858 / 0,778 | KHỚP (số paper trong khoảng 2 prompt) |
| Bảng 5 thứ hạng | ADGR>Mix>Hyb>chay | giống hệt, cả 2 prompt | KHỚP TUYỆT ĐỐI |
| Bảng 6 token / giờ | 4490 / 3,2s+6,7s | 3441 / 2,4s+5,8s | VƯỢT (gọn hơn, cùng phương pháp) |
| Bảng 7 độ chênh | 0,60–0,88 | chênh đã rõ | KHỚP HƯỚNG |
| Bảng 8 gọn | 5/57 so với 139 | 12–14/39–41 so với lớn | KHỚP PHONG CÁCH |

Cách đọc: 9 KHỚP/GẦN/VƯỢT, 5 GIẢI THÍCH ĐƯỢC (nguyên nhân đã đo), 0 KHÔNG GIẢI THÍCH ĐƯỢC. Đó là định nghĩa tái hiện thành công dùng xuyên suốt: không phải số giống hệt (bất khả thi khi khác judge/thang đo/cách trích), mà là không chênh lệch nào thiếu nguyên nhân đã đo.

# 9 Điểm mạnh, mỗi điểm có số

Bài báo: kiểm soát liên quan ở đúng hai khâu dễ lan lỗi nhất (bỏ anchor RAGAS rớt mạnh nhất: 0,88→0,72); ngữ cảnh gọn (−23% token) kéo tổng ret+gen xuống (Bảng 6: 9,85s→8,18s); ablation trung thực (mỗi arm tắt đúng một module, baseline không bị dìm); công khai tài nguyên (corpus + code + prompt — lần tái hiện này tồn tại được là nhờ đó). Ta: khóa cấu hình 13/13 đúng Bảng 2 (sai 1 số lòi ngay khi đối chiếu); gate chặn số hỏng (nổ 2 lần, cả 2 bắt đúng); 2 proxy độc lập cùng thứ tự tuyệt đối; mọi thay thế công bố kèm ảnh hưởng đã đo (cả cái lợi và hại cho ta); 43 lỗi sửa có bằng chứng verify trên máy (log + file + assert, không sửa mù).

# 10 Điểm yếu và giới hạn, mỗi điểm có số

Bài báo (mục 6.3, lời tác giả, số của ta xác nhận): phụ thuộc chất lượng KG (đầu vào rác thì đầu ra rác: LCR 0,82 so với 0,91 là minh chứng cụ thể); ngân sách top-K cố định (câu dễ thì thừa — `dense_only` của ta đã 0,90 — câu khó thì thiếu bằng chứng). Ta: (1) gold chấm tay thay bằng proxy — single-gold thiên vị dense theo định nghĩa (đo được 0,90 so với full 0,79; đã công bố, không mạo danh số paper); (2) judge khó hơn, nhất là câu dài (câu ngắn nhất khớp bài báo đúng 0,89; câu dài nhất chỉ 0,53); (3) standalone khác (chỉ tham khảo, không xếp hạng với nhau hay với bài báo); (4) trích nhiễu hơn (LCR 0,82: chunker gộp mục nhỏ, truy ra tận bộ cắt); (5) hố faithfulness đã mổ ở trên (75% do cách chấm, 25% do judge khó + nhiễu).

# 11 Đề xuất sửa (mỗi cái có bằng chứng + giá thật)

(1) *Pipeline thích ứng theo câu hỏi:* `dense_only` gần bằng full (0,90 so với 0,79) → phân loại dễ/khó trước, câu dễ bỏ qua đồ thị, rẻ hơn ∼10 lần, kỳ vọng giữ ≥95% chất lượng

(câu dễ không cần đồ thị — chính số đo trên chứng minh). ∼4h GPU + ∼$1 Solar (thêm 1 cột ablation trên hạ tầng sẵn, KG giữ nguyên). (2) *Rank-fusion thay rerank-override:* rerank kéo Hit@1 thang đơn $0,57 \to 0,25$ vì đè thứ tự dense (đo trên cùng pool); fusion giữ cả hai tín hiệu. ∼3h, không cần sinh đáp án mới. (3) *Sufficiency stopping* thay top-K cố định — hướng tác giả để ngỏ: dừng khi số claim được chứng minh bão hòa qua 3 chunk liên tiếp. ∼5h. (4) *Length-controlled generation:* câu ngắn đã khớp bài báo (0,89); thêm trần độ dài rồi chấm lại 1 arm. ∼4h. Tổng Giai đoạn 2: ∼15h GPU + ∼$5.

# 12 Ý nghĩa và kết luận

Về khoa học: xác nhận độc lập rằng kiểm soát liên quan theo câu hỏi (chứ không phải phình đồ thị mù) mới là nguồn tăng điểm ADGR — ablation của ta tái hiện đúng thứ tự quan trọng trên chỉ mục khác với judge khác, bằng chứng mạnh hơn cả chạy lại code tác giả. Kèm bộ mẫu kiểm chứng dùng lại được (gate, dual proxy, mổ hố) cho mọi bài RAG khác. Về thực tế: KG y khoa 52 nghìn entity + dây chuyền chạy được + quy tắc từ 43 lỗi thật là tài sản vĩnh viễn; ý tưởng mới từ nay tốn chi phí biên thay vì dựng lại (∼30h, ∼$23 trả một lần). Kết luận: đúng cơ chế, đúng thứ hạng, đúng hướng ablation; chênh tuyệt đối nào cũng có nguyên nhân đã đo. Không bịa số (mọi số chạy GPU thật, đủ 84 log chặng), không chọn số đẹp (kể cả 5 đáp án ngắn được cứu và 2 JSON judge lỗi, đều công bố kèm dòng log), không số tưởng tượng.