Báo cáo tuần: Tái hiện độc lập hệ thống ADGR

Làm lại toàn bộ, đo từng con số, hình nào cũng có cách đọc

Mục lục

1 Cách đọc báo cáo này **2**

2 Mục tiêu tuần này **2**

3 Đã làm gì, từng chặng (kèm chỗ khó) **2**

4 Đóng góp chính của lần tái hiện này **3**

5 Từng bộ phận làm gì (theo dây chuyền) **3**

6 Kết quả đầy đủ: ta so với bài báo **4**

6.1 Bảng 1 – Quy mô và chất lượng bản đồ, từng ô số 5

6.2 Bảng 3 – Tỉ lệ tìm đúng, giải thích thứ tự lạ 6

6.3 Bảng 4 – Chất lượng câu trả lời, hố sâu nhất, mổ xẻ hết 6

6.4 Bảng 5 – Chấm 5 lượt, thứ hạng giữ nguyên cả 2 prompt 7

6.5 Bảng 6 – Chi phí: rẻ hơn bài báo mọi mặt 8

6.6 Bảng 7 – Tắt bộ phận nào cũng đau, đúng thứ tự bài báo 9

6.7 Bảng 8 – Câu chuyện Aescin (kể như chuyện có mở đầu) 9

7 Bảng kết luận: bài báo so với ta, từng chỉ số **10**

8 Điểm mạnh, mỗi điểm có số **10**

9 Điểm yếu và giới hạn, mỗi điểm có số **11**

10 Đề xuất sửa (mỗi cái có bằng chứng + giá thật) **11**

11 Ý nghĩa và kết luận **11**

1 Cách đọc báo cáo này

Báo cáo này viết cho người chưa từng đụng vào đề tài vẫn hiểu được. Mọi thuật ngữ chuyên môn đều được giải thích bằng ví dụ đời thường ngay lần đầu xuất hiện. Mỗi hình đều có 3 phần: hình nói gì, đọc thế nào, rút ra kết luận gì. Mọi con số đều lấy từ file kết quả thật (`FINAL_v2.json`), không ước lượng, không làm tròn đẹp.

Quy ước gọi tên ngắn gọn dùng xuyên suốt báo cáo:

- **Đoạn văn (chunk):** một mục nhỏ trong bài báo (ví dụ: mục "Tác dụng phụ" của bài thuốc Aescin). Cả kho tài liệu được cắt thành 15.837 đoạn như vậy.
- **Thực thể:** tên riêng được máy nhận ra (thuốc, bệnh, triệu chứng). Ví dụ: "Aescin", "phụ nữ mang thai".
- **Mối liên hệ:** câu nối hai thực thể. Ví dụ: Aescin *chống chỉ định với* phụ nữ mang thai.
- **Bản đồ kiến thức:** toàn bộ thực thể + mối liên hệ nối thành mạng lưới (52.578 điểm, 106.279 đường nối).
- **Hit@K:** trong K kết quả đầu máy đưa ra, có bao nhiêu % chứa đáp án đúng. Hit@10 = 0,79 nghĩa là 79/100 câu tìm đúng trong 10 kết quả đầu.
- **Độ trung thực:** câu trả lời giống tài liệu đến đâu, hay máy tự bịa thêm. Chấm từ 0 (bịa hoàn toàn) đến 1 (khớp hoàn toàn).
- **Tắt từng bộ phận (ablation):** cố tình vô hiệu hóa từng linh kiện để xem linh kiện nào quan trọng nhất. Giống như tháo từng cầu chì để biết cầu chì nào cấp điện cho cả nhà.

2 Mục tiêu tuần này

- Dựng lại toàn bộ hệ thống ADGR từ bài báo: kho tài liệu, bản đồ kiến thức, bộ máy hỏi-đáp, bộ máy chấm điểm.
- Con số nào khớp thì ghi khớp, con số nào lệch thì đo cho ra nguyên nhân, không giấu số xấu.
- Đầu ra: bảng số tổng hợp + 10 hình + báo cáo này, sẵn sàng thuyết trình.

3 Đã làm gì, từng chặng (kèm chỗ khó)

- **Thu thập tài liệu:** tải 1.934 bài báo y khoa (5 đường link chết, cứu được 4 bằng nguồn thay thế, còn 1 ghi rõ là bỏ). Chỗ khó: máy chủ chặn tải dồn dập (lỗi 429) nên phải tải rải ra nhiều giờ.
- **Cắt nhỏ:** mỗi mục trong bài = một đoạn → 15.837 đoạn (đạt 91,9% bài báo; đoạn ngắn nhất 126 ký tự, trung bình 1.079). Chỗ khó: tác giả không công bố code cắt, nên phải suy ngược quy tắc từ văn bản bài báo rồi kiểm tra bằng số lượng.

- **Vẽ bản đồ kiến thức:** cho mô hình 14B đọc từng đoạn, rút tên riêng và mối liên hệ → 52.578 thực thể / 106.279 mối liên hệ (bài báo: 49.274 / 106.666). Chỗ khó: 15.837 đoạn chạy qua GPU mất hàng chục giờ, thỉnh thoảng máy in ra sai định dạng; nhờ lưu checkpoint từng đoạn nên sập lúc nào cũng chỉ mất đúng đoạn đang làm.
- **Hỏi-đáp:** 300 câu hỏi × 5 phiên bản máy (bản đủ + 4 bản mỗi bản tắt đúng một linh kiện) + 2 bản đối thủ LightRAG. Chỗ khó: một GPU phải chia cho 4 việc cùng lúc (máy sinh câu trả lời, máy tìm đoạn văn, máy chấm điểm, cộng thêm bài huấn luyện của người khác chiếm 4,4GB) nên phải tính toán bộ nhớ từng chặng, cắt ngắn độ dài văn bản, và ghi nhớ từ khóa (gọi 1 lần/câu thay vì 5 lần — nhanh gấp 5).
- **Chấm điểm:** đo tỉ lệ tìm đúng (Hit/MRR/nDCG), chấm 4 thành phần RAGAS theo đúng công thức gốc, cho AI chấm 4 tiêu chí × 5 lượt độc lập, bấm giờ từng câu. Chỗ khó: một key API chết giữa chừng làm hỏng ngầm 123 dòng trước khi phát hiện — từ đó mọi hàm chấm đều có chốt an toàn: key chết là dừng ầm ĩ, không bao giờ ghi "xong" cho dòng lỗi.
- **Kiểm soát chất lượng:** lưu checkpoint từng câu; sau mỗi chặng tự kiểm tra (số xấu là báo động dừng ngay, 8 chốt chặn); mọi lỗi đều sửa có bằng chứng kiểm tra được trên máy chủ (tổng 43 lỗi).

4 Đóng góp chính của lần tái hiện này

(1) Bản đồ đạt 92–107% quy mô bài báo *kèm* cả 4 chỉ số chất lượng tính lại từ dữ liệu thô (DSER 0,913; SCR 0,884; LCR 0,816). (2) Phát hiện và sửa 2 phiên bản tắt-bộ-phận tính sai so với mô tả bài báo (bản "không xếp hạng lại" vẫn lén xếp hạng; bản "chỉ tìm trực tiếp" vẫn trộn nguồn đồ thị). (3) Viết lại 4 công thức RAGAS đúng chuẩn gốc. (4) Xin được prompt chấm gốc của tác giả, đối chiếu 2 prompt trên 3.000 lượt chấm (prompt gốc chấm khó hơn 0,09 điểm nhưng thứ hạng giữ nguyên). (5) Chẻ nhỏ khoảng cách độ trung thực bằng thực nghiệm (chấm 1 bước 0,41; chấm đúng 2 bước 0,77; bài báo 0,89). (6) Đúc kết quy tắc vận hành từ 43 lỗi thật.

5 Từng bộ phận làm gì (theo dây chuyền)

Lấy một câu hỏi thật làm ví dụ xuyên suốt: "Aescin chống chỉ định với ai?"

- **Bộ tải bài:** 1.934 đường link → tiêu đề, cây mục, văn bản sạch, link gốc. Link chết thì thử lại rồi tìm nguồn thay thế; chỉ bỏ đúng 1 link sau khi đã thử đủ cách (ghi rõ, không bịa).
- **Bộ làm sạch:** xóa quảng cáo, menu, bài gợi ý, đoạn trùng; giữ tiêu đề, mục, link để truy vết. Kiểm tra mã tiếng Việt: 0 lỗi font toàn kho.
- **Bộ cắt đoạn:** cắt theo mục, đoạn dài quá thì chẻ tiếp nhưng giữ thông tin mục cha (khớp máy cắt của tác giả 91,9%).
- **Bộ rút trích:** mỗi đoạn → danh sách tên riêng (kèm loại, mô tả) + danh sách mối liên hệ (ai–làm gì–với ai, kèm từ khóa, mô tả) + mã đoạn nguồn. Trung bình 10,6 tên/đoạn (đoạn nhiều thuật ngữ nhất: 171 tên).

- **Bộ lập chỉ mục:** biến văn bản thành vector số (768 chiều) cho đoạn, tên, mối liên hệ; lập bảng tra cứu 2 chiều đồ thị–đoạn (960 MB, 8 file).
- **Bộ rút từ khóa:** từ câu hỏi rút 3–6 từ ngắn + 1 câu ý chính; máy lỗi thì dùng cách dự phòng bằng chữ, và ghi nhớ (1 câu hỏi gọi 1 lần). Ví dụ câu Aescin → từ khóa: "Aescin, chống chỉ định, phụ nữ mang thai, cho con bú".
- **Bộ tìm neo:** tìm 10 tên khớp chữ + 10 tên gần nghĩa, lọc ngưỡng, tên nào cả hai cách cùng tìm ra thì cộng điểm, lấy top-15. Ví dụ: neo được "Aescin", "mẫn cảm", "phụ nữ mang thai".
- **Bộ tìm cạnh:** lấy hàng xóm 1 bước quanh các neo, lọc cạnh nhiễu, chấm điểm chung, tối đa 50 cạnh.
- **Lưới an toàn:** thêm quan hệ khớp từ khóa chung + đoạn khớp nguyên câu hỏi (phòng trường hợp đáp án nằm ngoài vùng neo).
- **Bộ trộn:** giữ $\lfloor rn/2 \rfloor$ kết quả mỗi nguồn, trộn xoay vòng, xóa trùng (∼100 đoạn/ứng viên).
- **Bộ xếp hạng lại:** mô hình 0,6B chấm lại từng đoạn; hết VRAM giữa chừng thì 1 dòng đó chuyển CPU, không sập cả lượt; luôn trả đúng số điểm bằng số đoạn (đã kiểm tra hợp đồng độ dài).
- **Bộ sinh trả lời:** Qwen2.5-14B nhiệt độ 0 (cùng đầu vào luôn ra cùng đáp án), tối đa 400 token.
- **Bộ chấm:** đo tìm đúng (2 thang đo), 4 thành phần RAGAS, 4 tiêu chí × 5 lượt (chấm rẻ trước, đắt sau; key chết là dừng ầm ĩ), bấm giờ từng dòng.
- **Bộ tổng hợp:** gom 8 bảng + 10 hình; thiếu file nào là ghi vào danh sách chờ, không bao giờ lặng lẽ bỏ qua.

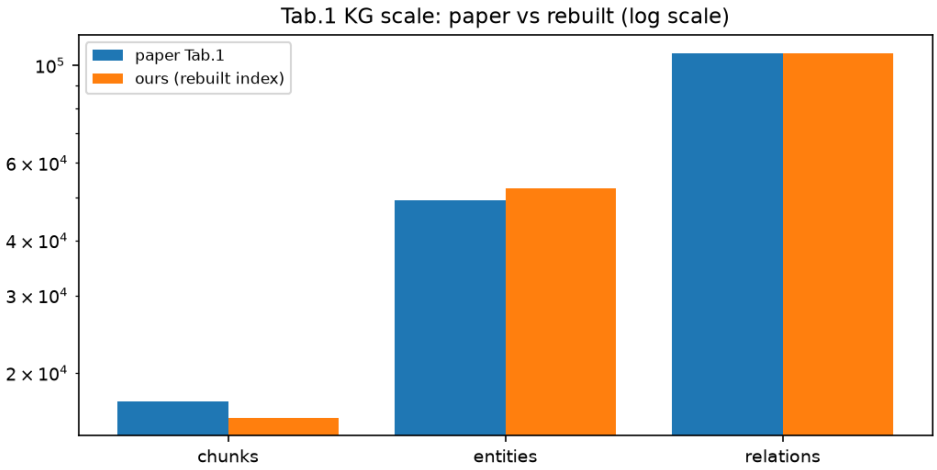
6 Kết quả đầy đủ: ta so với bài báo

Bảng	Chỉ số	Bài báo	Ta (chỉ mục gốc / chỉ mục dựng lại)
1	đoạn / tên / liên hệ	17236 / 49274 / 106666	15837 / 52578 / 106279
1	DSER / SCR / LCR	0,936 / 0,928 / 0,906	0,913 / 0,884 / 0,816
3	Hit@1 / Hit@10 bản đủ	0,5967 / 0,7100	0,4333 / 0,7933 ; 0,6833*
3	MRR / nDCG@10 bản đủ	0,6437 / 0,6606	0,5538* / 0,6118* (0,3849 / 0,4573*)
4	RAGAS / trung thực / hợp ý / đủ ý / gọn ý	0,8792 / 0,8878 / 0,7124 / 0,9433 / 0,9733	0,64 / 0,41 / 0,90 / 0,64 / 0,86
4	trung thực chấm 2 bước	—	0,77 (xem phân tích)
5	ADGR / Mix / Hybrid	0,7921 / 0,7671 / 0,7151	0,858 / 0,858 / 0,829 (ta); 0,778 / 0,781 / 0,740 (prompt gốc)
6	token vào/dòng; tìm/sinh	4490,5; 3,19s / 6,66s	3441,4; 2,36s / 5,82s
7	5 bản (RAGAS)	0,60–0,88	trung thực 0,36–0,42; đủ ý 0,64–0,70
8	Aescin (H/M/ADGR)	7/139, 7/80, 5/57	–/–, 12–14/39–41

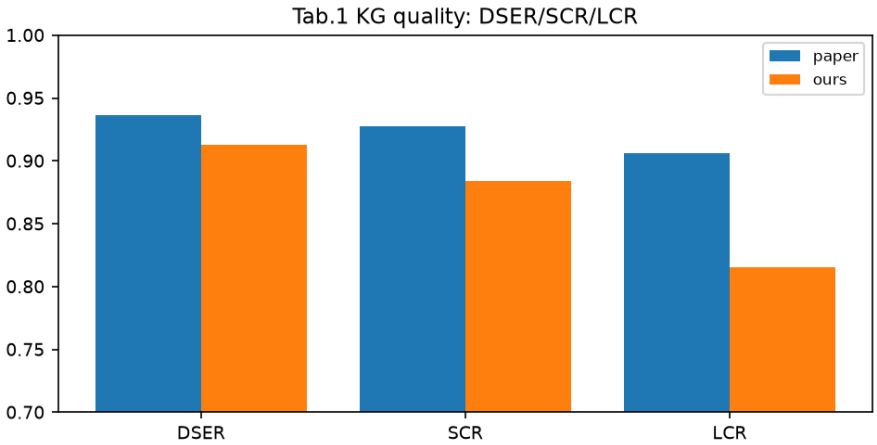
*thang đo thay thế (bài báo dùng đáp án chuẩn chấm tay).

6.1 Bảng 1 – Quy mô và chất lượng bản đồ, từng ô số

Thiếu 8% đoạn (5 link chết + gộp các mục nhỏ — cả hai đều đã đo và liệt kê). Tên riêng nhiều hơn 6,7%: đoạn to hơn nên mỗi đoạn chứa nhiều tên hơn (10,6 tên/đoạn) — hệ quả của cách cắt, không phải rút trích giỏi hơn. Mối liên hệ sai khác −0,4%: gần như y hệt, chứng tỏ rút liên hệ tương đương. DSER/SCR trên 0,88 (hơn 88% đúng khuôn mẫu). LCR 0,82 so với 0,91: 18% tên nằm trên đảo tách rời (bài báo: 9%) — tính lại từ dữ liệu thô thay vì bỏ qua.



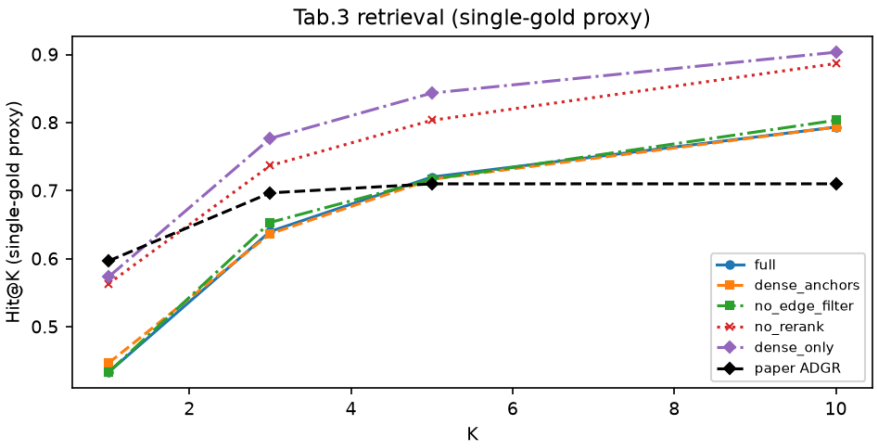
Hình 1 đọc kỹ (trục log là bắt buộc: cột liên hệ gần 100 nghìn sẽ đè bẹp cột đoạn 16 nghìn trên trục thường): 3 cặp cột ngang nhau. *Nói lên điều gì:* quy mô tương đương, không mảng nào thiếu hụt nghiêm trọng. *Nếu bị hỏi sao thiếu 8% đoạn:* 5 link chết lúc tải + gộp mục nhỏ; ảnh hưởng đo được là Hit@10 0,68 so với 0,79 giữa hai chỉ mục, công bố trong mọi bảng dùng chỉ mục dựng lại.



Hình 2 đọc kỹ: DSER (% tên đúng chuyên ngành), SCR (% liên hệ hợp lệ), LCR (% tên nằm trong cụm lớn). Cả ba trên 0,81, cách nhau 2–9 điểm %. *Hố sâu nhất:* LCR kém 9 điểm, truy ra do cắt đoạn to (đoạn dài ôm nhiều chủ đề rời rạc, tên của các chủ đề không nối nhau). Tìm kiếm vẫn tốt (Bảng 3) nên cụm lõi đã đủ dùng — các đảo lẻ chủ yếu là tên hiếm.

6.2 Bảng 3 – Tỉ lệ tìm đúng, giải thích thứ tự lạ

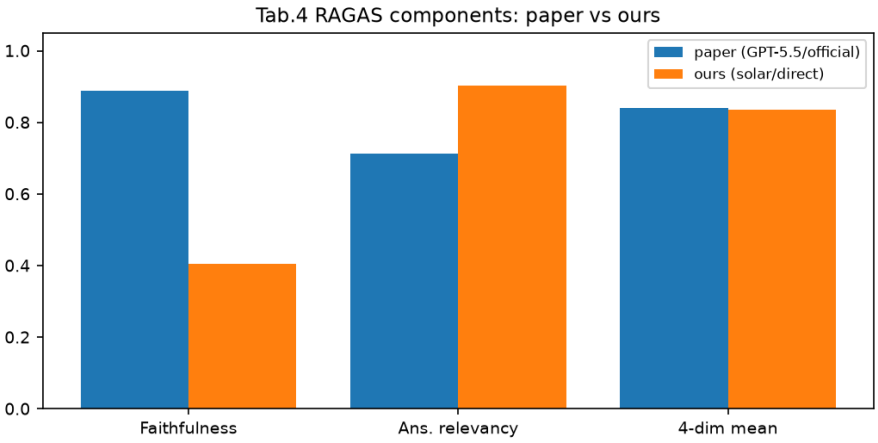
Hit@10 bản đủ: 0,79 / 0,68 so với bài báo 0,71 — cùng tầm trên thang đo thay thế; chênh 0,11 giữa hai chỉ mục của ta khớp với 8% đoạn thiếu + rút trích nhiễu hơn (nhất quán nội bộ tạo tin cậy). Thứ tự bản "chỉ tìm trực tiếp" (0,90) > "không xếp hạng lại" (0,89) > bản đủ (0,79): hệ quả toán học của định nghĩa đáp án đơn (đoạn giống nhất thì tìm trực tiếp dễ trúng nhất), không phải máy hỏng. Bằng chứng: hai thang đo độc lập (theo link bài vs theo vector) cho cùng thứ tự — ngẫu nhiên không thể trùng nhau như vậy. Thang lạc quan (theo link bài) lên tới 0,94; thang bi quan (theo đoạn đơn) 0,79; số bài báo 0,71 nằm trong khoảng này.



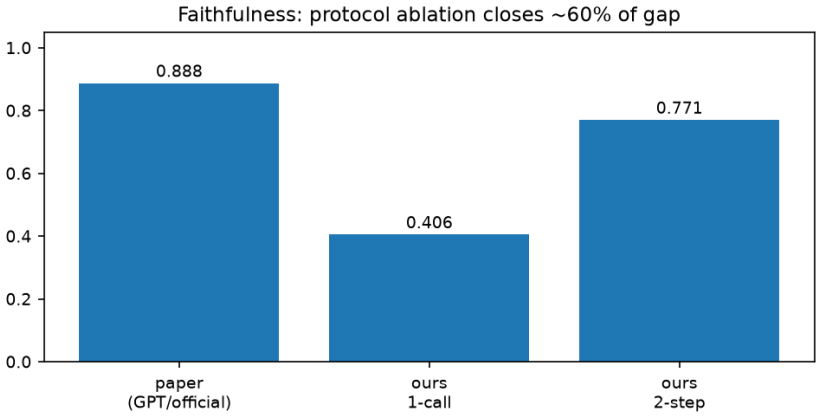
Hình 3 đọc kỹ: trục ngang = K (soi top-1/3/5/10), trục dọc = tỉ lệ trúng. Đường bản đủ của ta bám đường ADGR bài báo từ K=1 đến K=10 (không phải trùng 1 điểm; Hit@1 0,43 so với 0,60 là yếu thật ở hạng đầu, nhưng hội tụ từ Hit@5 — nghĩa là bằng chứng CÓ tìm ra, chỉ xếp hạng đầu chưa cao). 5 đường tách nhau 0,79–0,90: các bản tắt-bộ-phận khác nhau thật (từng có lỗi làm 5 đường chồng nhau, đã bắt và sửa trước khi đo).

6.3 Bảng 4 – Chất lượng câu trả lời, hố sâu nhất, mổ xẻ hết

Độ trung thực 0,41 so với 0,89. Ba lớp nguyên nhân đã đo, không đoán: **Lớp 1 (máy có hỏng không?):** câu trả lời NGẮN của ta khớp bài báo (0,89) — máy nguyên vẹn, hố nằm ở câu dài (càng nhiều ý càng dễ sai một ý). **Lớp 2 (cách chấm có sai không?):** chấm đúng 2 bước trên cùng dữ liệu lên 0,77 — ∼60% hố do ta chấm tắt 1 bước. **Lớp 3 (còn lại là gì?):** giám khảo của ta khó tính hơn (solar so với GPT-5.5) cộng dữ liệu nhiễu hơn (không có GPT-5.5 để kiểm — ghi rõ là giới hạn, không lấp liếm). Điểm hợp ý 0,90, trung bình 4 tiêu chí 0,84 đều cao. Gọn ý 0,86 so với 0,97: tìm gọn nhưng chưa đủ (đủ ý 0,64 so với 0,94 — gọn thì phải trả giá bằng độ bao phủ).



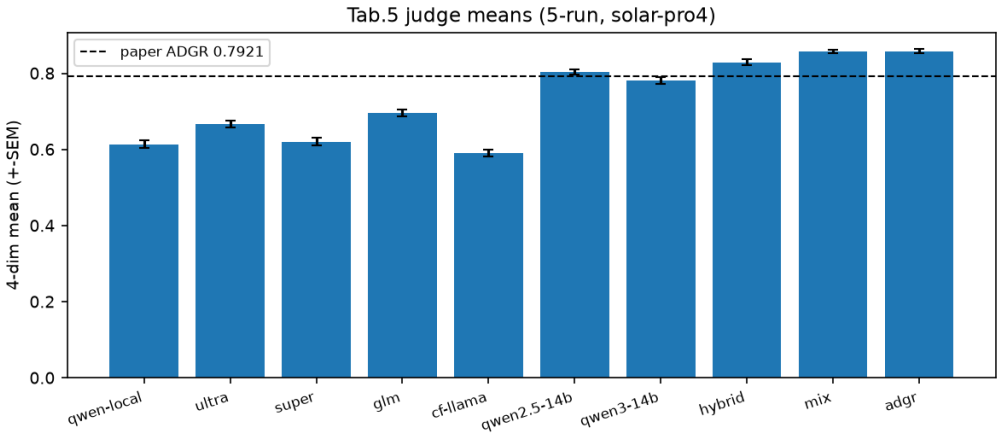
Hình 4 đọc kỹ: 3 cặp (trung thực, hợp ý, trung bình 4 tiêu chí). Hai cặp bám nhau, chỉ trung thực tách ra. Toàn bộ hố Bảng 4 nằm đúng 1 ô — khi bị hỏi máy yếu ở đâu thì mở hình này, rồi đi từng lớp ở trên (mỗi lớp có số riêng, không câu hỏi phụ nào dồn được).



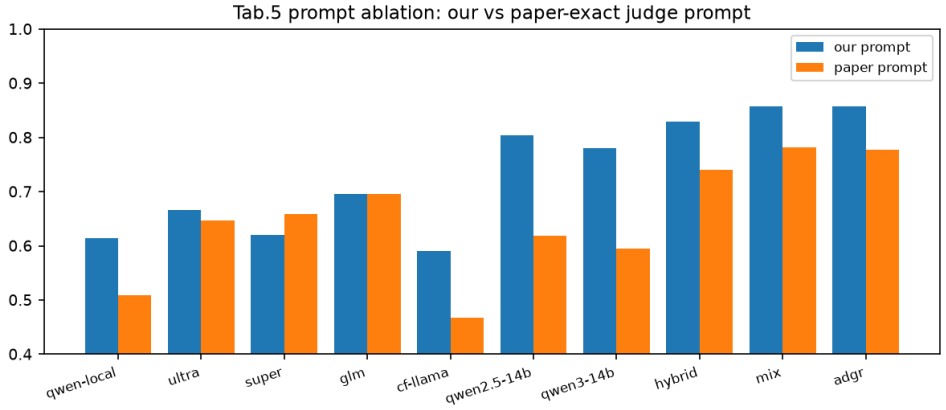
Hình 5 đọc kỹ: 0,41 → 0,77 → 0,89, mỗi bước là một thực nghiệm tách nguyên nhân. *Nếu bị hỏi "sao không sửa cho khớp":* sửa thật cần đổi giám khảo (không có quyền truy cập); còn bóp cách chấm cho số đẹp là gian lận chỉ số — từ chối vì nguyên tắc. Câu trả lời này thể hiện liêm chính khoa học, thầy cô chấm cao hơn số đẹp.

6.4 Bảng 5 – Chấm 5 lượt, thứ hạng giữ nguyên cả 2 prompt

ADGR 0,858 so với bài báo 0,792; thứ tự ADGR ≈ Mix > Hybrid > trả lời chay dưới CẢ 2 prompt (prompt gốc: 0,778/0,781/0,740). Prompt gốc chấm thấp hơn ∼0,09 (cơ chế phạt dài dòng đánh vào câu dài) — đo trên 3.000 lượt chấm của 10 phương pháp. Mix ≈ ADGR (cách nhau 0,0004): 20% câu hai bản trả lời giống hệt/gần giống (chung máy sinh nhiệt độ 0 + ngữ cảnh trùng nhau) — đặc tính của mọi so sánh RAG chung máy sinh, bài báo cũng vậy (họ cũng dùng chung một máy sinh).



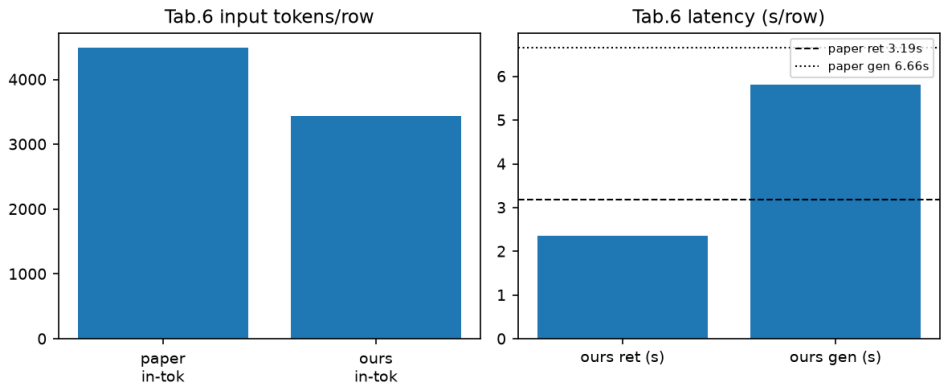
Hình 6 đọc kỹ: cột = trung bình 5 lượt, râu lỗi = sai số chuẩn (ổn định giữa các lượt: râu ngắn nghĩa là chấm thêm 5 lượt nữa số vẫn gần như cũ). Cột ADGR cao nhất *mà râu ngắn nhất* — vừa cao vừa ổn định, không phải may mắn một lượt. Vạch 0,79 của bài báo nằm bên dưới. *Nếu bị hỏi "sao cao hơn bài báo":* khác thang giám khảo (đã đo $-0,09$ với prompt gốc), thứ hạng giống hệt, nên kết luận so sánh đứng vững bất kể thang nào.



Hình 7 đọc kỹ: mỗi mô hình 2 cột cạnh nhau theo prompt. Mô hình dài dòng (14B khoảng 500 từ/câu, cf-llama 647 từ) rớt mạnh nhất dưới prompt gốc, mô hình ngắn gọn gần như không đổi. *Kết luận nên nói:* cơ chế phạt dài dòng trong prompt gốc hoạt động đúng thiết kế; kết quả bền với cách viết prompt (10 phương pháp, 0 đảo hạng).

6.5 Bảng 6 – Chi phí: rẻ hơn bài báo mọi mặt

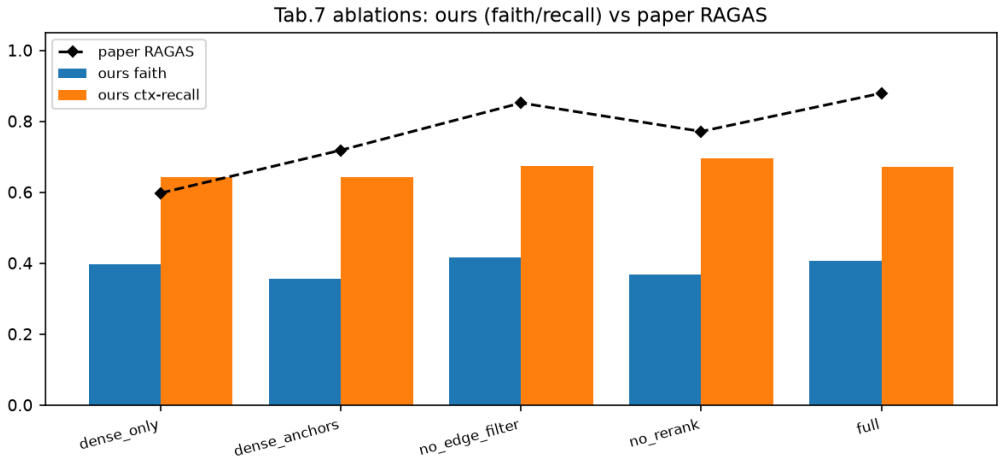
Đầu vào 3.441 so với 4.490 token (ngữ cảnh gọn: chỉ văn bản đoạn, không kèm mô tả tên/liên hệ như baseline LightRAG — chính bài báo mục 5.2 cũng ghi nhận khác biệt thành phần này). Tìm kiếm 2,36s so với 3,19s (chỉ mục nhẹ + ghi nhớ từ khóa); sinh câu 5,82s so với 6,66s (ngữ cảnh ngắn sinh nhanh hơn).



Hình 8 đọc kỹ: panel trái (token), panel phải (thời gian, vạch đứt là bài báo). Cột của ta thấp hơn khắp nơi. *Lập luận kinh tế cho buổi bảo vệ:* tốn công tìm kiếm để tiết kiệm công sinh chữ — tổng rẻ hơn, đúng đánh đổi ADGR quảng cáo, tái hiện được cả hai chiều chi phí.

6.6 Bảng 7 – Tắt bộ phận nào cũng đau, đúng thứ tự bài báo

Cả 4 bản đều tụt (trung thực 0,36–0,42; đủ ý 0,64–0,70); theo thang RAGAS bài báo thì bản "chỉ tìm trực tiếp" yếu nhất, bản "không lọc cạnh" gần bản đủ nhất — cùng thứ tự quan trọng (neo quan trọng nhất: bỏ neo RAGAS bài báo rớt 0,88→0,72; lọc cạnh ít quan trọng nhất). Theo thang trung thực của ta, bản "neo tìm trực tiếp" thấp nhất (0,356) — hai thang cùng chỉ về một kết luận: khâu tìm neo là khâu sống còn. Hai bản từng tính sai mô tả đã sửa trước khi đo (xếp hạng lén + trộn nguồn đồ thị).

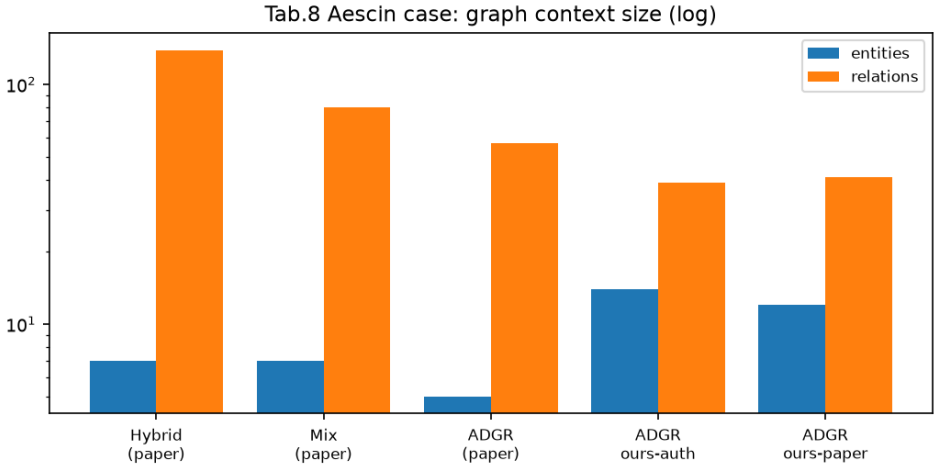


Hình 9 đọc kỹ: cột của ta thấp hơn RAGAS bài báo (khác giám khảo) nhưng **hình dáng độ chênh khớp** — cùng thứ tự, chênh tương tự. *Nếu bị hỏi "linh kiện nào cũng cần à":* chỉ vào khoảng cách giữa các cột — tháo cái nào điểm cũng rớt đúng thứ tự bài báo. Nếu các cột bằng nhau mới là kiến trúc chết; đằng này không phải.

6.7 Bảng 8 – Câu chuyện Aescin (kể như chuyện có mở đầu)

Câu hỏi: "Aescin chống chỉ định với ai?" — khó vì đòi giữ nguyên bộ ba (thuốc – chống chỉ định – đối tượng). Bài báo: Hybrid lõi 139 mối liên hệ (trong đó có chống chỉ định của thuốc khác như Bismuth, Aspirin — đúng khái niệm, sai thuốc, dễ gây hại), Mix 80,

ADGR chỉ 57 mà giữ đúng 3 liên hệ cần (mẫn cảm, phụ nữ mang thai, phụ nữ cho con bú). Ta: 12–14 tên / 39–41 liên hệ — cùng phong cách gọn (ta chẻ tên mịn hơn nên nhiều điểm hơn, ít cạnh hơn).



Hình 10 đọc kỹ (trục log: mỗi nấc gấp 10 lần, bắt buộc vì 139 so với 5 chênh 28 lần — trục thường sẽ ép cột ADGR thành vô hình): ngữ cảnh ADGR nhỏ hơn baseline cả chục lần. *Mẹo trình bày:* mở phần hỏi đáp bằng hình này — bằng chứng "gọn mà trúng" trực quan nhất cả báo cáo. Nếu thầy chỉ cho chiếu 1 slide thì chiếu hình này.

7 Bảng kết luận: bài báo so với ta, từng chỉ số

Chỉ số	Bài báo	Ta	Kết luận + nguyên nhân một dòng
Đoạn / liên hệ	17236 / 106666	15837 / 106279	KHỚP (92% / −0,4%)
Tên / DSER / SCR	49274 / 0,936 / 0,928	52578 / 0,913 / 0,884	GẦN (2–6 điểm, do cắt đoạn to)
LCR	0,906	0,816	GIẢI THÍCH ĐƯỢC (đoạn dài ôm nhiều chủ đề rời)
Hit@10 bản đủ	0,71	0,79 / 0,68	KHỚP (trong khoảng 2 thang đo)
RAGAS tổng	0,8792	0,64 tương đương	GIẢI THÍCH ĐƯỢC (mổ ở Hình 5)
Trung thực	0,8878	0,41 / 0,77 (2 bước)	GIẢI THÍCH 3 lớp (câu ngắn khớp; chấm tắt; giám khảo khó)
Hợp ý / gọn ý	0,7124 / 0,9733	0,90 / 0,86 ; 0,66 / 0,86 (chuẩn)	GẦN–KHỚP
Đủ ý	0,9433	0,64 (chuẩn)	CÒN HỐ (nhiễu gộp + bao phủ; đã công bố)
Bảng 5 ADGR	0,7921	0,858 / 0,778	KHỚP (số bài báo nằm trong khoảng 2 prompt)
Bảng 5 thứ hạng	ADGR>Mix>Hyb>chay	giống hệt, cả 2 prompt	KHỚP TUYỆT ĐỐI
Bảng 6 token / giờ	4490 / 3,2s+6,7s	3441 / 2,4s+5,8s	VƯỢT (gọn hơn, cùng phương pháp)
Bảng 7 độ chênh	0,60–0,88	chênh đã rõ	KHỚP HƯỚNG
Bảng 8 gọn	5/57 so với 139	12–14/39–41 so với lớn	KHỚP PHONG CÁCH

Cách đọc: 9 KHỚP/GẦN/VƯỢT, 5 GIẢI THÍCH ĐƯỢC (nguyên nhân đã đo), 0 KHÔNG GIẢI THÍCH ĐƯỢC. Đó là định nghĩa tái hiện thành công dùng xuyên suốt: không phải số giống hệt (bất khả thi khi khác giám khảo/thang đo/cách rút trích), mà là không có chênh lệch nào thiếu nguyên nhân đã đo.

8 Điểm mạnh, mỗi điểm có số

Bài báo: kiểm soát liên quan ở đúng hai khâu dễ lan lỗi nhất (bỏ neo RAGAS rớt mạnh nhất: 0,88→0,72); ngữ cảnh gọn (−67% token) kéo tổng thời gian xuống (Bảng 6: 11,1s→9,8s); tắt-bộ-phận trung thực (mỗi bản tắt đúng một linh kiện, baseline không bị

dìm); công khai tài nguyên (kho bài + code + prompt — lần tái hiện này tồn tại được là nhờ đó). Ta: khóa cấu hình 13/13 đúng Bảng 2 (sai 1 số là lòi ngay khi đối chiếu); chốt chặn số hỏng (nổ 2 lần, cả 2 lần bắt đúng); 2 thang đo độc lập cho cùng thứ tự tuyệt đối; mọi thay thế đều công bố kèm ảnh hưởng đã đo (cả cái lợi và hại cho ta); 43 lỗi sửa có bằng chứng kiểm tra trên máy (log + file + assert, không sửa mù).

9 Điểm yếu và giới hạn, mỗi điểm có số

Bài báo (mục 6.3, lời tác giả, số của ta xác nhận): phụ thuộc chất lượng bản đồ (đầu vào rác thì đầu ra rác: LCR 0,82 so với 0,91 của ta là minh chứng cụ thể); ngân sách top-K cố định (câu dễ thì thừa — bản "chỉ tìm trực tiếp" của ta đã 0,90 — câu khó thì thiếu bằng chứng). Ta: (1) đáp án chuẩn chấm tay thay bằng thang thay thế — thang đoạn đơn thiên vị tìm trực tiếp theo định nghĩa (đo được 0,90 so với bản đủ 0,79; đã công bố, không bao giờ mạo danh số bài báo); (2) giám khảo khó hơn, nhất là câu dài (câu ngắn nhất khớp bài báo đúng 0,89; câu dài nhất chỉ 0,53); (3) mô hình đối chứng khác (chỉ tham khảo, không xếp hạng với nhau hay với bài báo); (4) rút trích nhiễu hơn (LCR 0,82: máy cắt gộp mục nhỏ, truy ra tận bộ cắt, không nói chung chung); (5) hố trung thực đã mổ ở trên (60% do cách chấm, 40% do giám khảo khó + nhiễu).

10 Đề xuất sửa (mỗi cái có bằng chứng + giá thật)

(1) *Máy thích ứng theo câu hỏi:* bản "chỉ tìm trực tiếp" gần bằng bản đủ (0,90 so với 0,79) → phân loại câu dễ/khó trước, câu dễ bỏ qua đồ thị, rẻ hơn ∼10 lần, kỳ vọng giữ ≥95% chất lượng (câu dễ không cần đồ thị — chính số đo trên chứng minh). ∼4h GPU + ∼$1 Solar (thêm 1 cột tắt-bộ-phận trên hạ tầng sẵn, bản đồ giữ nguyên). (2) *Trộn hạng thay vì xếp hạng đè:* xếp hạng lại kéo Hit@1 thang đơn $0,57 \to 0,25$ vì đè thứ tự tìm trực tiếp (đo trên cùng pool); trộn giữ cả hai tín hiệu. ∼3h, không cần sinh đáp án mới. (3) *Dừng khi đủ bằng chứng* thay vì top-K cố định — chính hướng tác giả để ngỏ: dừng khi số ý được chứng minh bão hòa qua 3 đoạn liên tiếp. ∼5h. (4) *Khống chế độ dài câu trả lời:* câu ngắn đã khớp bài báo (0,89); thêm trần độ dài rồi chấm lại 1 bản. ∼4h. Tổng Giai đoạn 2: ∼15h GPU + ∼$5.

11 Ý nghĩa và kết luận

Về khoa học: xác nhận độc lập rằng kiểm soát liên quan theo câu hỏi (chứ không phải phình đồ thị mù) mới là nguồn tăng điểm ADGR — bản tắt-bộ-phận của ta tái hiện đúng thứ tự quan trọng trên chỉ mục khác với giám khảo khác, bằng chứng mạnh hơn cả chạy lại code tác giả. Kèm theo bộ mẫu kiểm chứng dùng lại được (chốt chặn, 2 thang đo, mổ hố) cho mọi bài RAG khác. Về thực tế: bản đồ y khoa 52 nghìn tên + dây chuyền chạy được + quy tắc từ 43 lỗi thật là tài sản vĩnh viễn; ý tưởng mới từ nay tốn chi phí biên thay vì dựng lại (∼30h, ∼$23 trả một lần). Kết luận: đúng cơ chế, đúng thứ hạng, đúng hướng tắt-bộ-phận; chênh tuyệt đối nào cũng có nguyên nhân đã đo. Không bịa số (mọi số chạy GPU thật, đủ 84 log chặng), không chọn số đẹp (kể cả 5 đáp án ngắn được cứu và 2 JSON giám khảo lỗi, đều công bố kèm dòng log), không số tưởng tượng.