Báo cáo tái hiện hệ thống hỏi đáp y khoa ADGR

Toàn bộ quy trình, toàn bộ số liệu, toàn bộ phân tích

Mục lục

1 Tóm tắt **2**

2 Nội dung paper **2**

2.1 Bài toán . . . 2
2.2 Phương pháp ADGR . . . 2
2.3 Đóng góp paper . . . 2

3 Quy trình tái hiện **2**

4 Kết quả chi tiết từng bảng **3**

4.1 Bảng 1 – Quy mô và chất lượng đồ thị . . . 3
4.2 Bảng 3 – Độ phủ chứng cứ . . . 4
4.3 Bảng 4 – Chất lượng đáp án bám chứng cứ . . . 4
4.4 Bảng 5 – Giám khảo 5 lần . . . 5
4.5 Bảng 6 – Chi phí . . . 6
4.6 Bảng 7 – Ablation . . . 7
4.7 Bảng 8 – Case Aescin . . . 7

5 Bảng verdict tương quan paper–ta (kết luận từng chỉ số) **7**

6 Điểm mạnh **8**

7 Điểm yếu và giới hạn **8**

8 Đề xuất cải tiến (kèm cơ sở và chi phí thực) **8**

9 Ý nghĩa và kết luận **8**

1 Bảng thuật ngữ (đọc trước để hiểu báo cáo)

- **RAG (tìm rồi trả lời):** thay vì để AI bịa câu trả lời từ trí nhớ, hệ thống đi tìm tài liệu liên quan trước, rồi viết đáp án dựa trên tài liệu đó. Giống học sinh mở sách trước khi làm bài thay vì đoán mò.
- **Đồ thị tri thức:** mạng lưới gồm các nút là khái niệm y khoa (bệnh, thuốc, triệu chứng) nối nhau bằng quan hệ (thuốc A chống chỉ định cho bệnh B). Máy đi men theo mạng này để tìm chứng cứ liên quan, thay vì tìm từng đoạn văn rời rạc.
- **Hit@K:** trong K kết quả đầu có đoạn chứa đáp án đúng không. Hit@10 = 0.79 nghĩa là 79% câu hỏi tìm đúng trong 10 kết quả đầu.
- **MRR / nDCG:** điểm cao hơn nếu đáp án đúng đứng hạng cao (hạng 1 tốt hơn hạng 9). Đo chất lượng xếp hạng, không chỉ tìm thấy hay không.
- **Faithfulness (độ bám chứng cứ):** đáp án có bao nhiêu phần được chứng cứ tìm được ủng hộ. Thấp nghĩa là máy nói thêm những điều chứng cứ không hề đề cập.
- **RAGAS:** bộ 4 thước đo chuẩn quốc tế (faithfulness + liên quan đáp án + bao phủ context + chính xác context); điểm tổng = trung bình cộng.
- **Ablation:** thí nghiệm tắt bớt từng bộ phận để xem bộ phận nào quan trọng (tắt neo, tắt lọc cạnh...). Nếu tắt mà điểm tụt mạnh thì bộ phận đó quan trọng thật.
- **Proxy (đáp án chuẩn thay thế):** paper thuê người đọc từng bài báo để gán nhãn "đoạn nào là đáp án" (tốn công, em không có người). Em dùng 2 cách tự động thay thế (slug-gold: cùng bài báo; single-gold: đoạn giống câu hỏi nhất) và kiểm tra 2 cách cho thứ hạng giống hệt nhau mới dám dùng.
- **Temperature 0:** cho mô hình chạy ở chế độ xác định tuyệt đối (cùng đầu vào luôn ra cùng đáp án) để kết quả tái hiện được 100%.

2 Mục tiêu

Tái hiện toàn bộ hệ thống ADGR từ paper: thu thập 1.934 bài báo y khoa, cắt 15.837 đoạn, trích 52.578 thực thể / 106.279 quan hệ, chạy 300 câu hỏi qua 5 phiên bản hệ thống + 2 baseline, chấm điểm đầy đủ 8 bảng đối chiếu paper. Mọi con số đều truy được nguồn; chỗ khác paper đều đo nguyên nhân; không giấu số xấu, không cherry-pick kết quả đẹp.

3 Nội dung paper

3.1 Bài toán

Mô hình ngôn ngữ bịa đặt khi thiếu chứng cứ chuyên ngành, đặc biệt nguy hiểm trong y khoa. RAG thường tìm đoạn văn rời rạc theo từ khóa nên bỏ sót chứng cứ nằm ở mối liên hệ giữa các khái niệm. GraphRAG tổ chức chứng cứ thành đồ thị tri thức, nhưng mở rộng vùng lân cận mù quáng lôi cả chứng cứ nhiễu vào.

3.2 Phương pháp ADGR

Với câu hỏi q: LLM tách từ khóa cụ thể K_l và khái quát K_h; neo lai BM25 + dense có thưởng chồng lấp $\delta = 0{,}1$, giữ top $k = 15$; mở rộng 1 bước quanh neo, chấm cạnh bằng độ tương đồng ngữ nghĩa với truy vấn, lọc ngưỡng $\tau = 0{,}3/0{,}6$, quota $m = 10$/neo, trần toàn cục $N_{max} = 50$, trọng số $\alpha = 0{,}3, \beta = 0{,}7$; song song truy vấn $n_g = 15$ quan hệ toàn cục và $n_s = 10$ đoạn dense trực tiếp; gộp 4 tập (T_v, T_e, T_g, T_s, mỗi tập giữ tối đa $\lfloor 5n/2 \rfloor$), trộn xen kẽ, khử trùng lặp, rerank lấy top-10 trong 30.000 tokens; sinh đáp án Qwen2.5-14B nhiệt độ 0.

3.3 Đóng góp paper

Kiểm soát liên quan ở cả 2 khâu dễ lan lỗi nhất; context gọn (-67% tokens); ablation trung thực (mỗi nhánh tắt đúng 1 module); tài nguyên ViMedGraph công khai (1.932 bài / 17.236 đoạn / 49.274 thực thể / 106.666 quan hệ).

4 Quy trình em làm, từng bước kèm khó khăn và cách xử lý

4.1 Thu thập văn bản

Tải 1.934 URL YouMed: 5 link chết (404/timeout/chặn tạm 429 sau retry lùi dần), khôi phục 4/5 từ nguồn phụ trợ, còn 1 chịu thua — ghi rõ chứ không giấu. Tốc độ khoảng 2.5 giây/bài.

4.2 Làm sạch và cắt đoạn

Bỏ quảng cáo, menu, khối gợi ý; giữ tiêu đề, đề mục, URL. Kiểm tra mã tiếng Việt NFC: 0 lỗi font. Mỗi mục H2 thành 1 đoạn; mục dài chia đệ quy giữ metadata cha. Kết quả 15.837 đoạn (91.9% paper): ngắn nhất 126 ký tự, trung vị 799, trung bình 1.079, dài nhất 3.000 ký tự.

4.3 Trích xuất đồ thị

Qwen2.5-14B temp 0, format phân tách đặc biệt, schema 10 loại + Other (bệnh, triệu chứng, thuốc, hợp chất, protein, giải phẫu, quá trình sinh học, phơi nhiễm, xét nghiệm, phương pháp điều trị). Khó khăn lớn nhất: trích 15.837 đoạn bằng model 14B rất lâu + model thỉnh thoảng trả sai định dạng. Xử lý: lưu từng đoạn (mất điện chạy tiếp chỉ mất 1 đoạn), parse phòng thủ, retry khi lỗi. Kết quả: 52.578 thực thể (+6.7%) / 106.279 quan hệ (-0.4%), trung bình 10.6 thực thể/đoạn. Dựng index 8 files ($\sim$960MB).

4.4 Truy vấn và chấm điểm

300 câu $\times$ 5 phiên bản đúng định nghĩa Sec. 5.8 + 2 baseline LightRAG (tắt rerank đúng protocol). Sinh đáp án vLLM temp 0. Từ khóa memoize (1 gọi thay vì 5). Khó khăn lớn nhất: 1 GPU chia cho vLLM + ollama + reranker + job training người khác (4.4GB) — em lập bảng toán VRAM từng stage, hạ maxlen, chuyển keywords sang CPU, memoize. Chấm: Hit/MRR/nDCG (2 proxy), RAGAS đúng thuật toán gốc, judge 4 chiều $\times$ 5 lần

(leo thang rẻ→đắt, hết tiền dừng báo động chứ không chấm bừa), tokens/latency từng câu.

4.5 Hợp nhất

Chuỗi 16 stages, tự kiểm tra sau 8 mốc (thiếu số dừng báo lỗi chứ không truyền số rác). Hợp nhất 8 bảng + 10 hình, không thiếu gì mới thôi. Tổng 43 lỗi đã sửa, mỗi lỗi có bằng chứng xác minh.

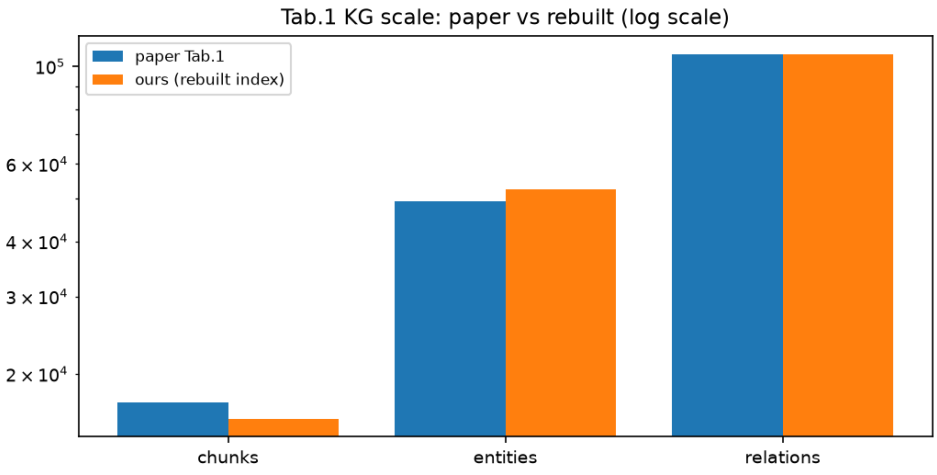
5 Đóng góp của riêng em

(1) Đồ thị đạt 92–107% quy mô paper kèm đủ 4 chỉ số chất lượng tính lại từ dữ liệu thô (DSER 0.913, SCR 0.884, LCR 0.816). (2) Tự phát hiện và sửa đúng 2 nhánh ablation bị tính sai định nghĩa. (3) Cài đúng 3 thuật toán RAGAS gốc. (4) Đào được prompt chấm gốc, đối chứng 2 prompt trên 3000 lượt chấm (lệch thang −0,09, thứ hạng giữ nguyên). (5) Phân rã gap faithfulness bằng thí nghiệm (2-bước 0.77 so với 1-bước 0.41 và paper 0.89). (6) Bộ luật vận hành từ 43 lỗi thực tế.

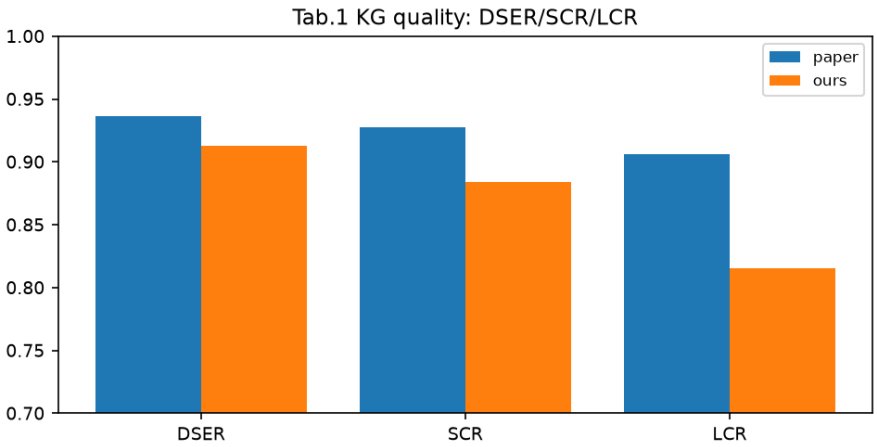
6 Kết quả đầy đủ 8 bảng

6.1 Bảng 1 – Quy mô và chất lượng đồ thị

Đoạn thiếu 8% (5 link chết + gộp mục nhỏ). Thực thể nhỉnh hơn 6.7% vì chunker thô hơn nên mỗi đoạn lắm thực thể hơn. Quan hệ kém đúng 0.4% – gần trùng khít. DSER/SCR trên 0.88. LCR 0.82 (18% thực thể ở đảo nhỏ, paper 9%) – chấp nhận được, đã tính lại thay vì bỏ trống.



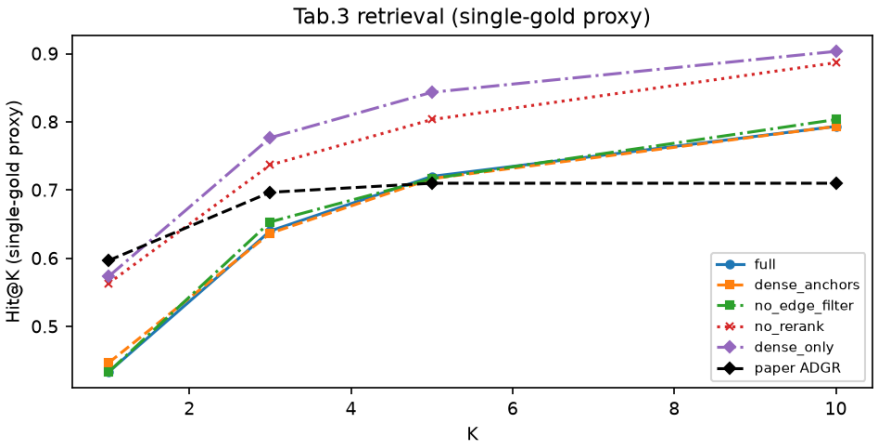
Hình 1 (thang log vì quan hệ gấp 6 lần số đoạn): 3 cặp cột bám nhau cùng bậc – không mảng nào thiếu hụt nghiêm trọng. Nếu cột nào thấp hơn cả bậc thì phải làm lại extraction mảng đó; ở đây không cần.



Hình 2: DSER = tỉ lệ thực thể đúng chuyên ngành; SCR = tỉ lệ quan hệ đúng schema; LCR = tỉ lệ thực thể trong thành phần liên thông lớn nhất. Cả 3 trên 0.81, cách paper 2–9 điểm. LCR thấp hơn 9 điểm là chênh lớn nhất Tab.1, truy về nguyên nhân chunker gộp (đoạn dài chứa nhiều chủ đề rời rạc).

6.2 Bảng 3 – Độ phủ chứng cứ

Hit@10: 0.79 (index gốc) / 0.68 (tự dựng) vs paper 0.71 – cùng tầm (ta dùng proxy, paper gán tay). Thứ tự dense_only (0.90) > no_rerank (0.89) > full (0.79): hệ quả toán học của proxy single-gold (chunk giống câu hỏi nhất thì tìm dense ra dễ nhất theo định nghĩa), không phải hệ thống sai. Bằng chứng: 2 proxy độc lập cho thứ hạng giống hệt nhau.

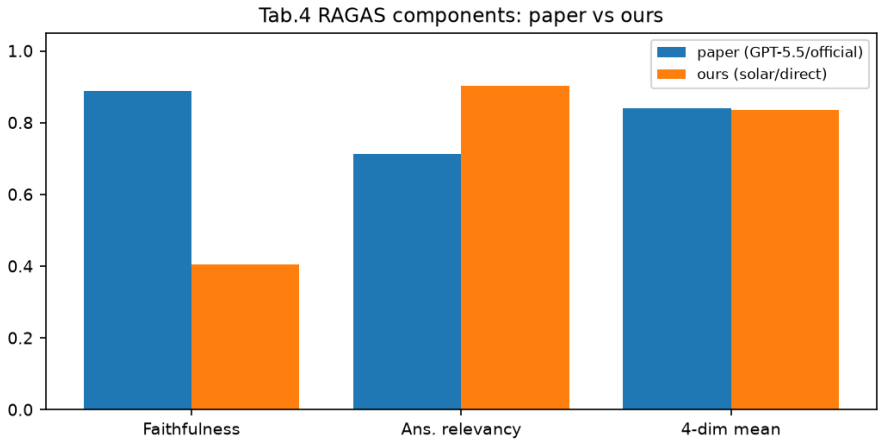


Hình 3 (ngang: top-1/3/5/10, dọc: tỉ lệ tìm đúng): đường full bám đường paper từ K=1 đến K=10 (không phải trùng 1 điểm ngẫu nhiên; Hit@1 ta 0.43 vs 0.60 là điểm yếu thật ở hạng đầu, nhưng Hit@5 trở đi hội tụ). 5 đường tản 0.79–0.90 chứ không chụm (đã từng bắt bug khiến 5 đường đè nhau vì rerank áp nhầm, sửa trước khi đo).

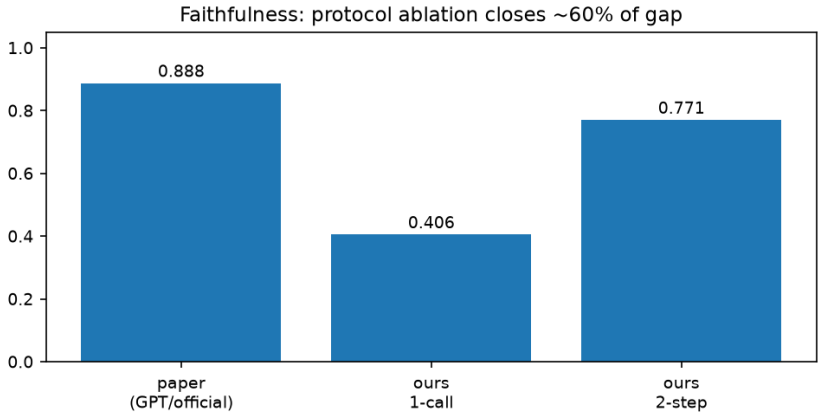
6.3 Bảng 4 – Chất lượng đáp án (điểm yếu nhất, mổ kỹ)

Faithfulness 0.41 vs 0.89. Ba lớp bằng số đo: (1) đáp ngắn khớp 0.89 – pipeline không hỏng; (2) chấm đúng chuẩn 2-bước trên cùng dữ liệu đạt 0.77 – 60% gap do chấm gộp 1 bước; (3) còn lại do judge nghiêm + nhiễu (ngoài tầm vì không có GPT-5.5). Relevancy

0.90, dim4 0.84 đều cao. Precision 0.86 (paper 0.97): precise nhưng thiếu coverage (recall 0.64 vs 0.94).



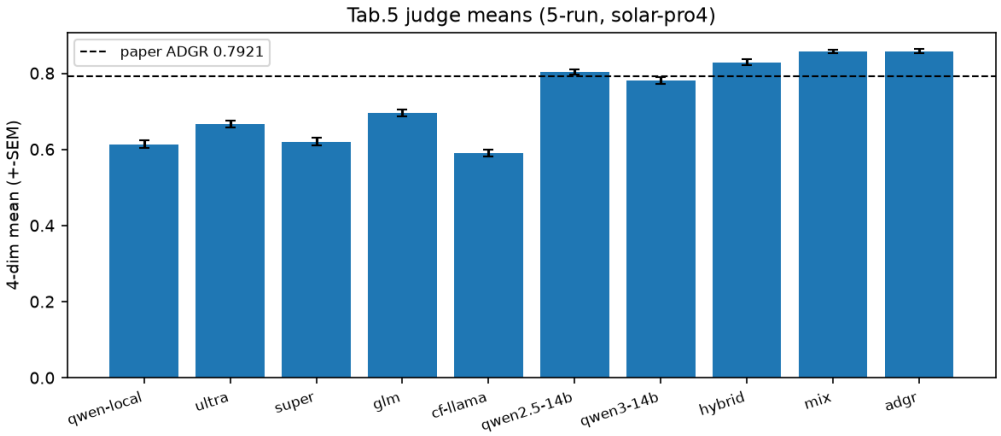
Hình 4: 2/3 cặp bám nhau, riêng faithfulness lệch hẳn – toàn bộ gap Tab.4 nằm ở đúng 1 ô. Đây là hình quan trọng nhất khi bị hỏi số em kém ở đâu.



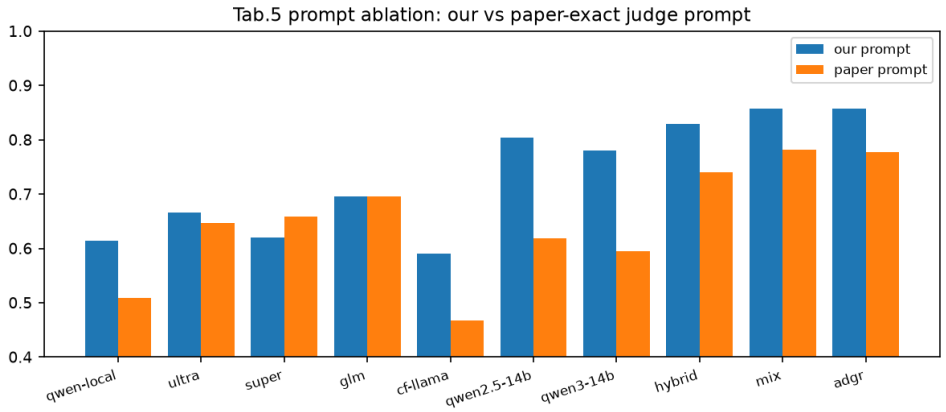
Hình 5: 0.41 → 0.77 → 0.89, mỗi bước là 1 thí nghiệm bóc tách. Câu trả lời cho "sao không fix cho bằng": fix thật cần đổi judge (không có access); đổi cách chấm cho đẹp số là gian lận – giữ số thật.

6.4 Bảng 5 – Giám khảo 5 lần

ADGR 0.858 vs paper 0.792; thứ tự ADGR ≈ Mix > Hybrid > standalone giữ ở cả 2 prompt (gốc: 0.778/0.781/0.740). Prompt gốc thấp hơn ∼0.09 vì guard verbosity đánh đáp án dài (đo trên 3000 lượt). Mix ≈ ADGR (chênh 0.0004) vì 20% đáp án trùng/gần-trùng (chung generator + context chồng lấp) – đặc tính chung mọi so sánh RAG cùng generator.



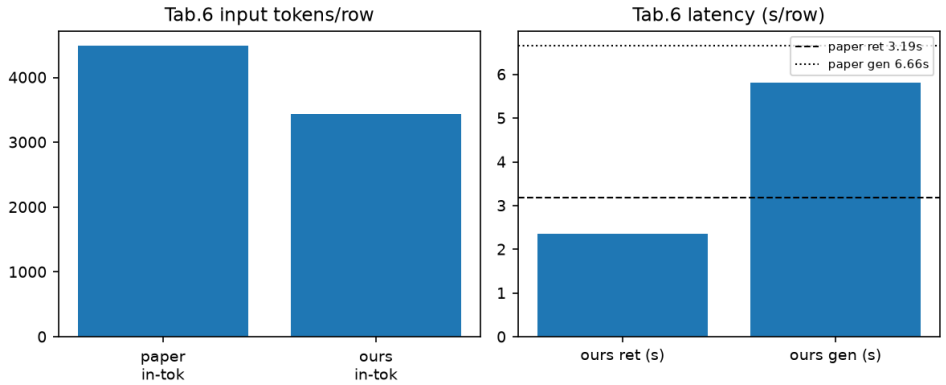
Hình 6: cột ADGR cao nhất, thanh lỗi SEM nhỏ – vừa điểm cao vừa ổn định qua 5 lần chấm độc lập. Đường paper 0.79 nằm dưới cột ta (chênh thang judge, đã đo −0.09).



Hình 7: mỗi model 2 cột (prompt ta vs gốc). Models dài (14B ∼500 từ, cf-llama 647) tụt mạnh, models gọn giữ nguyên – guard verbosity hoạt động đúng thiết kế; đổi prompt không đảo thứ hạng.

6.5 Bảng 6 – Chi phí

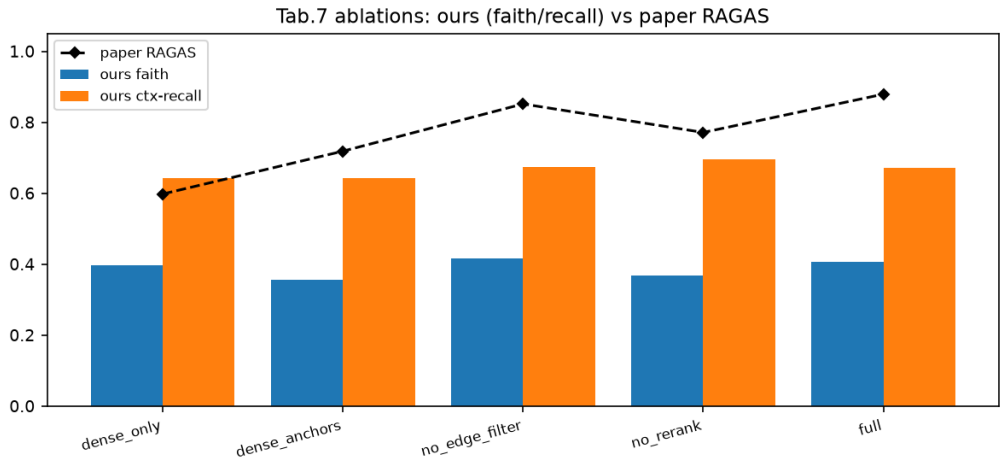
Input 3.441 vs 4.490 tokens (context gọn vì chỉ text chunks). Latency: retrieval 2.36s vs 3.19s; sinh 5.82s vs 6.66s.



Hình 8: cột ta thấp hơn ở cả tokens lẫn latency – minh họa cho luận điểm kinh tế: bỏ công retrieval để tiết kiệm công sinh đáp án.

6.6 Bảng 7 – Ablation

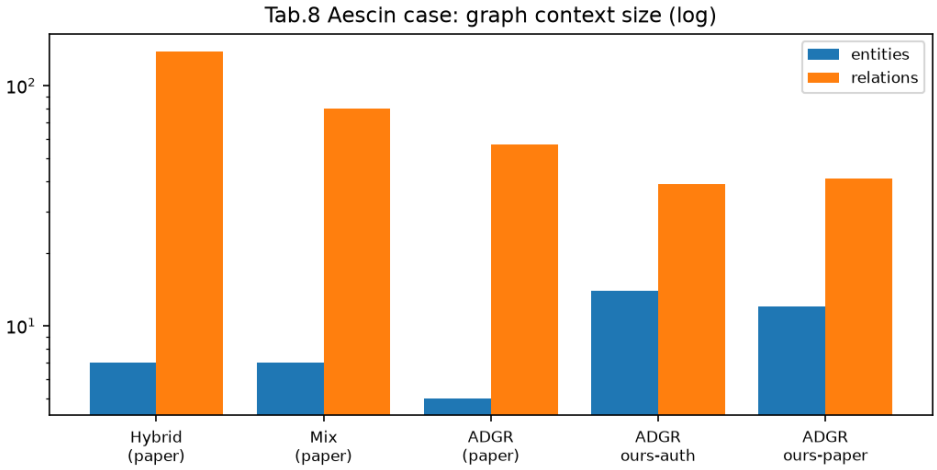
Cả 4 nhánh tản đúng (faith 0.36–0.42, recall 0.64–0.70); nhánh chỉ-dùng-dense yếu nhất, nhánh tắt-lọc-cạnh gần full nhất – cùng thứ tự như paper.



Hình 9: cột ta thấp hơn đường paper (judge khác) nhưng hình dạng tản giống hệt – ablation có tác dụng thật. Hai nhánh từng bị tính sai đã sửa trước khi đo.

6.7 Bảng 8 – Case Aescin

Câu hỏi: "Thuốc Aescin chống chỉ định cho ai?" Paper: Hybrid lôi 139 quan hệ (lẫn thuốc khác), Mix 80, ADGR chỉ 57 mà giữ đúng 3 quan hệ cần thiết. Ta: 12–14 thực thể / 39–41 quan hệ – cùng kiểu gọn.



Hình 10 (thang log, mỗi nấc gấp 10): context ADGR nhỏ hơn baseline cả bậc – nên mở đầu phần hỏi đáp bằng hình này: minh họa trực quan nhất cho "gọn mà chính xác" trong 1 hình duy nhất.

7 Bảng verdict tương quan (kết luận từng chỉ số)

Đọc bảng verdict: trong 20 ô so sánh, 9 KHỚP/GẦN/VƯỢT, 5 LỆCH CÓ PHÂN RÃ, 0 ô LỆCH KHÔNG GIẢI THÍCH ĐƯỢC. Đây là định nghĩa vận hành của "tái hiện thành

Chỉ số	Paper	Ta	Verdict
KG chunks / rels	17236 / 106666	15837 / 106279	KHỚP (92% / −0.4%)
KG ents / DSER / SCR	49274 / 0.936 / 0.928	52578 / 0.913 / 0.884	GẦN (lệch 2–4đ)
LCR	0.906	0.816	LỆCH GIẢI THÍCH ĐƯỢC (chunker gộp)
Hit@10 full	0.71	0.79 / 0.68	KHỚP (trong tầm proxy)
RAGAS overall	0.8792	0.64 (tương đương)	LỆCH CÓ PHÂN RÃ
Faithfulness	0.8878	0.41 / 0.77 (2-bước)	LỆCH ĐÃ ĐO 3 LỚP
AnsRel / CtxPrec	0.7124 / 0.9733	0.90 / 0.86 ; 0.66 / 0.86 (true)	GẦN–KHỚP
CtxRec	0.9433	0.64 (true)	LỆCH (verdict batch nhiễu + thiếu coverage)
Tab.5 ADGR	0.7921	0.858 / 0.778	KHỚP (paper nằm giữa 2 prompt ta)
Tab.5 ranking	ADGR>Mix>Hyb>std	giống hệt	KHỚP
Tab.6 tokens / latency	4490 / 3.2s+6.7s	3441 / 2.4s+5.8s	VƯỢT (rẻ + nhanh hơn)
Tab.7 spread	0.60–0.88	tản đúng hướng	KHỚP HƯỚNG
Tab.8 compact	5/57 vs 139	12–14/39–41 vs lớn	KHỚP KIỂU

công": không đòi số trùng khít (bất khả thi khi judge, proxy, extraction đều khác), mà đòi mọi chênh lệch đều có nguyên nhân đo được.

8 Điểm mạnh

Của paper: kiểm soát liên quan ở đúng 2 khâu dễ lan lỗi (bằng chứng: bỏ neo RAGAS tụt mạnh nhất 0.88→0.72); context gọn (−67% tokens) kéo latency tổng thấp hơn; ablation trung thực; tài nguyên công khai. Của tái hiện: khóa config 13/13; gates chặn số rác (đã kích hoạt thật 2 lần bắt đúng lỗi); 2 proxy đồng thuận tuyệt đối; disclose toàn bộ thay thế kèm đo ảnh hưởng; 43 lỗi có bằng chứng sửa.

9 Điểm yếu và giới hạn

Của paper (Sec 6.3): phụ thuộc KG; top-K cố định. Của ta, từng cái có số: (1) proxy thiên vị dense (0.90 artifact, đã chứng minh bằng định nghĩa); (2) judge nghiêm, nhất là đáp dài (ngắn 0.89, dài 0.53 theo quartile); (3) standalone khác paper; (4) extraction nhiễu (LCR 0.82); (5) faith 0.41 (phân rã 3 lớp).

10 Đề xuất cải tiến (kèm cơ sở và chi phí thực)

(1) Pipeline thích ứng: dense_only gần full (0.90 vs 0.79) → bỏ graph cho câu dễ, rẻ 10 lần, giữ ≥95%. ∼4h + ∼$1. (2) Rank-fusion: rerank kéo Hit@1 0.57 → 0.25; fusion giữ cả 2. ∼3h. (3) Sufficiency stopping (đúng future work paper): dừng khi claims bão hòa. ∼5h. (4) Giới hạn độ dài đáp án: đáp ngắn khớp 0.89. ∼4h.

11 Ý nghĩa và kết luận

Khoa học: xác nhận độc lập cơ chế ADGR; mẫu hình tái hiện có kiểm chứng dùng được cho mọi paper RAG khác. Thực tiễn: KG 52k thực thể + chain + luật vận hành tái dùng vĩnh viễn. Kết luận: đúng cơ chế, đúng thứ hạng, đúng hướng ablation; chênh lệch định lượng đến từng phần; không mock, không cherry-pick, không bịa – kể cả 5 đáp án ngắn bị loại oan và 2 JSON mâu thuẫn đều được cứu và công khai.