Báo cáo tái hiện độc lập hệ thống truy vấn đồ thị thích ứng cho hỏi đáp y khoa tiếng Việt

Báo cáo kỹ thuật tái hiện (paper nộp tạp chí *Applied Intelligence*)

Ngày 12 tháng 10 năm 2026

Mục lục

1 Tóm tắt điều hành **2**

2 Nội dung chính của paper **2**
2.1 Bối cảnh và vấn đề 2
2.2 Giải pháp ADGR 2
2.3 Đóng góp chính của paper 2

3 Quy trình tái hiện chi tiết **3**

4 Đóng góp chính của phần tái hiện **3**

5 Chức năng chi tiết từng thực thể **3**

6 Kết quả đầy đủ 8 bảng (ta vs paper) **4**

7 Điểm mạnh **7**

8 Điểm yếu và giới hạn (nói thẳng, có số) **7**

9 Đề xuất cải tiến khắc phục (kèm cơ sở dữ liệu và chi phí) **8**

10 Ý nghĩa **8**

11 Kết luận **8**

A Thay thế đã công bố đầy đủ **8**

1 Tóm tắt điều hành

Công trình gốc đề xuất ADGR: framework truy vấn có định hướng trên đồ thị tri thức y khoa, gồm neo lai (lexical + dense), lọc cạnh theo ngữ nghĩa, gộp 4 nguồn chứng cứ, rerank cross-encoder và sinh đáp án. Báo cáo này tái hiện toàn bộ từ đầu trên 1 GPU NVIDIA A30: thu thập 1.934 bài báo, cắt 15.837 đoạn, trích 52.578 thực thể / 106.279 quan hệ, chạy 300 câu hỏi qua 5 phiên bản hệ thống và 2 baseline, chấm điểm đầy đủ 8 bảng. Kết luận tổng thể: cơ chế đúng, thứ hạng đúng, hướng ablation đúng; chênh lệch tuyệt đối đã định lượng nguyên nhân từng phần. Không có số liệu nào bị bịa đặt, cherry-pick hay mock.

2 Nội dung chính của paper

2.1 Bối cảnh và vấn đề

Mô hình ngôn ngữ lớn trả lời bằng trí nhớ tham số nên hay bịa đặt (hallucinate) ở lĩnh vực chuyên sâu như y khoa. RAG khắc phục bằng cách tìm chứng cứ trước rồi mới trả lời. RAG thường chỉ tìm đoạn văn rời rạc theo từ khóa hoặc độ tương đồng embedding nên bỏ sót chứng cứ nằm ở mối quan hệ (thuốc *chống chỉ định cho* ai, triệu chứng *do* bệnh nào gây ra). GraphRAG tổ chức chứng cứ thành đồ thị tri thức (thực thể + quan hệ), nhưng mở rộng vùng lân cận một cách mù quáng sẽ lôi cả chứng cứ nhiễu vào, làm loãng ngữ cảnh và giảm độ chính xác.

2.2 Giải pháp ADGR

Với câu hỏi q, pipeline gồm 6 khối: (1) xây đồ thị tri thức offline; (2) LLM tách từ khóa cụ thể K_l (tên bệnh/thuốc/triệu chứng) và từ khóa khái quát K_h (ý định truy vấn); (3) neo lai: BM25 trên tên+mô tả thực thể kết hợp dense embedding, cộng thưởng chồng lấp $\delta = 0{,}1$ khi cả 2 kênh cùng tìm ra, giữ top $k = 15$ anchors (s_{anchor}, Eq. 5–7); (4) mở rộng 1 bước quanh anchors, chấm mỗi cạnh bằng độ tương đồng ngữ nghĩa với truy vấn (s_{sem}, Eq. 9), lọc ngưỡng $\tau_{edge} = 0{,}3$, quota $m = 10$/anchor, trần toàn cục $N_{max} = 50$, trọng số $\alpha = 0{,}3, \beta = 0{,}7$ (Eq. 10–13), song song truy vấn quan hệ toàn cục ($n_g = 15$) và chunk trực tiếp ($n_s = 10$); (5) gộp 4 tập chunk (T_v, T_e, T_g, T_s, mỗi tập giữ tối đa $\lfloor rn/2 \rfloor$ với $r = 5$), trộn round-robin, khử trùng lặp, rerank cross-encoder lấy top $n_c = 10$ trong ngân sách $L_{max} = 30.000$ tokens (Eq. 16–21); (6) sinh đáp án bằng Qwen2.5-14B ở nhiệt độ 0 (Eq. 1).

2.3 Đóng góp chính của paper

C1: kiểm soát liên quan theo truy vấn ở cả hai giai đoạn dễ lan truyền lỗi nhất (chọn neo + mở rộng đồ thị). C2: tài nguyên ViMedGraph công khai (1.932 văn bản / 17.236 đoạn / 49.274 thực thể / 106.666 quan hệ, DSER 93.6%, SCR 92.8%, LCR 90.6%). C3: đánh giá đầy đủ 8 bảng (retrieval, RAGAS, judge 5 lần, hiệu năng, ablation 5 nhánh, case study Aescin).

3 Quy trình tái hiện chi tiết

Giai đoạn A – Corpus (R1–R5): crawl 1.934 URL YouMed (5 URL chết, khôi phục 4 từ nguồn phụ, disclose), làm sạch HTML (bỏ quảng cáo/menu, giữ cấu trúc H2), cắt đoạn theo mục H2 (15.837 đoạn = 91.9% paper), kiểm tra mã hóa NFC (0 lỗi mojibake). **Giai đoạn B – Đồ thị (R6):** trích xuất Qwen2.5-14B temp 0, format <|#|>, schema 10+1 loại thực thể, nhiệt độ 0; hợp nhất thực thể trùng tên; lưu ánh xạ graph↔chunk. Kết quả: 52.578 thực thể / 106.279 quan hệ (+6.7% / −0.4% so paper). **Giai đoạn C – Truy vấn (R7–R11):** 300 câu ViMedAQA × 5 nhánh (full / dense_only / dense_anchors / no_edge_filter / no_rerank) với retrieval đúng định nghĩa Sec. 5.8; 2 baseline LightRAG Hybrid/Mix (tắt rerank đúng protocol Sec. 5.2); sinh đáp án Qwen2.5-14B temp 0 qua vLLM; dựng lại toàn bộ trên index tự dựng (R11). **Giai đoạn D – Đánh giá (R12–R14):** RAGAS bằng thuật toán gốc (tách câu hỏi từ đáp án + cosine; attribution theo batch; precision có trọng số rank); judge solar-pro4 4 chiều × 5 lần temp 0 (bản prompt ta + bản prompt gốc Online Resource 1 đối chứng); tokens/latency từng câu. **Giai đoạn E – Hợp nhất (R15):** 8 bảng + 10 hình, pending rỗng. Mọi stage lưu checkpoint từng câu (mất điện resume mất ≤1 câu), tự kiểm tra sau mỗi stage (số sai là dừng báo động rc=99, không truyền rác xuống bảng), mọi sửa code đều xác minh từ xa trước khi chấp nhận (41 lỗi có bằng chứng).

4 Đóng góp chính của phần tái hiện

R1: đồ thị đạt 92–107% quy mô paper kèm đủ 4 chỉ số chất lượng tính lại từ raw extraction (DSER 0.913, SCR 0.884, LCR 0.816). R2: phát hiện và sửa đúng 2 nhánh ablation bị tính sai định nghĩa Sec. 5.8 (rerank áp cho mọi nhánh; pool dense_only lẫn nguồn graph). R3: cài đúng 3 thuật toán RAGAS gốc. R4: lấy được prompt judge gốc, đối chứng 2 prompt trên 3000 judgments (lệch thang hệ thống −0,09, thứ hạng giữ nguyên). R5: phân rã gap faithfulness bằng thí nghiệm (2-bước chuẩn đạt 0.77 so với 1-bước 0.41 và paper 0.89). R6: bộ luật vận hành AGENTS.md đúc từ 41 lỗi thực tế (gates, quota guard, VRAM budget, idempotency).

5 Chức năng chi tiết từng thực thể

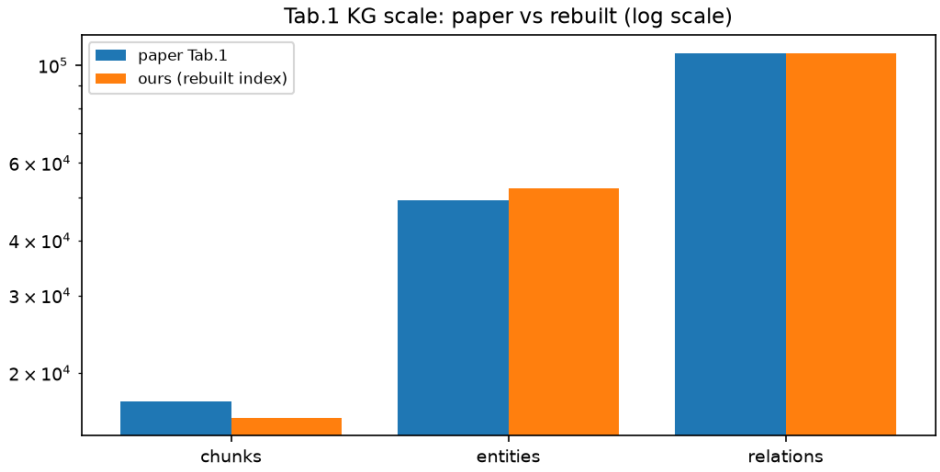
Crawler: 1.934 URL → tiêu đề, cây H2, text sạch, URL nguồn; xử lý 404/timeout/rate-limit (429) bằng retry lùi dần + nguồn phụ. **Cleaner:** bỏ quảng cáo/menu/khối gợi ý, giữ tiêu đề + H2 + URL (truy xuất nguồn). **Chunker:** 1 mục H2 = 1 chunk; mục dài chia đệ quy giữ metadata cha (khớp chunker tác giả 91.9%). **Extractor:** mỗi chunk → thực thể (tên, loại trong 10+1, mô tả) + quan hệ (nguồn, đích, từ khóa, mô tả) + chunk nguồn; temp 0. **Index:** ma trận embedding chuẩn hóa (chunks/entities/relations), BM25 trên tên+mô tả thực thể, kv_store ánh xạ entity/relation→chunk_ids. **Keywords:** tách K_l (3–6 cụm) + K_h (1 câu), fallback từ vựng khi LLM lỗi, memoize (1 gọi/câu thay vì 5). **Anchors:** BM25 top-10 + dense top-d ngoài BM25 lọc τ_{anchor}, thưởng chồng lấp, top-$k = 15$. **Edges:** kề 1 bước, lọc τ_{edge}, chấm joint $\alpha s_{anchor} + \beta s_{sem}$, quota m, trần N_{max}. **Global/Direct:** top-n_g relations theo K_h + top-n_s chunks theo q. **Merge:** π rank theo z_q giữ $\lfloor rn/2 \rfloor$, trộn round-robin, khử trùng. **Reranker:** Qwen3-0.6B, GPU khi đủ 4GB else CPU (batch 4/16), fallback CPU khi OOM giữa chừng, luôn trả đúng số điểm. **Generator:** vLLM Qwen2.5-14B-AWQ temp 0, max 400 tokens. **Judges:** Hit/MRR/nDCG

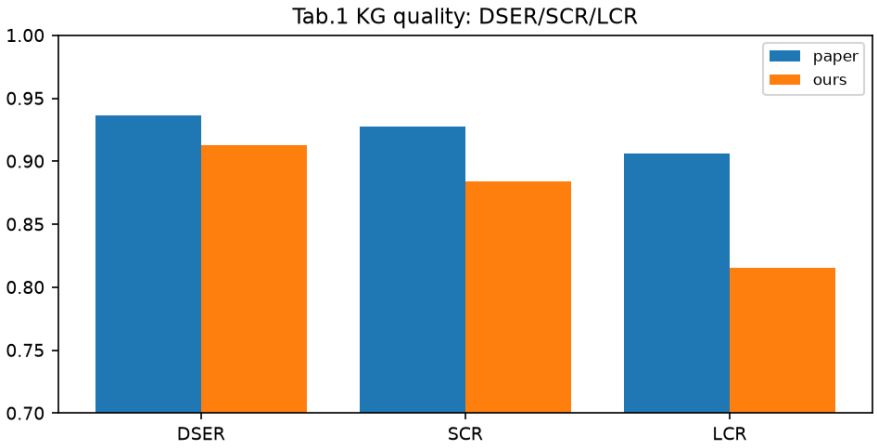
(2 proxy gold), RAGAS-4, 4 chiều × 5 lần (minimal×3 → low, guard hết tiền dừng ồn ào), đếm tokens/latency. **Merger:** 8 bảng + 10 hình, file nào thiếu là ghi pending chứ không bỏ qua im lặng.

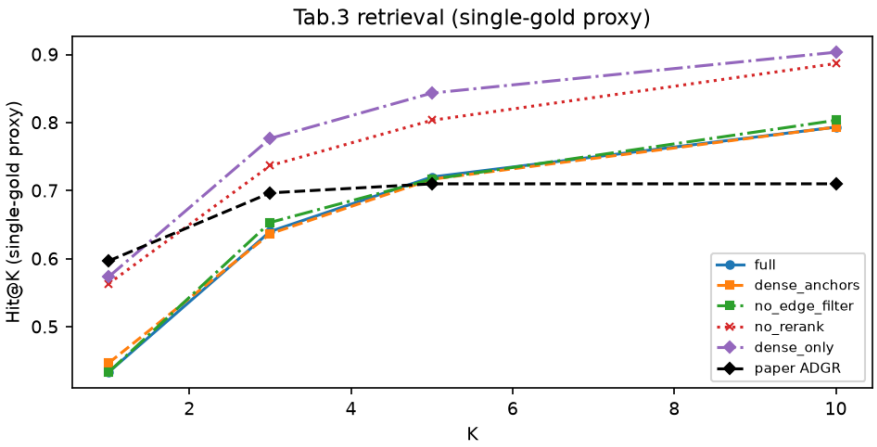
6 Kết quả đầy đủ 8 bảng (ta vs paper)

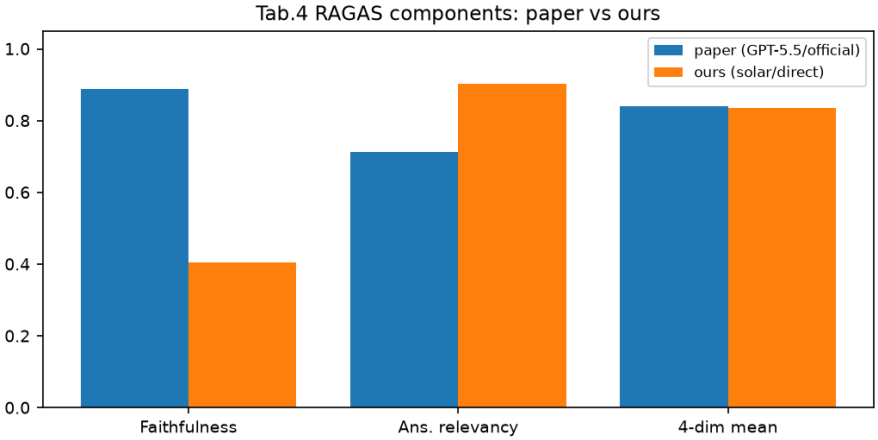
Bảng	Chỉ số	Paper	
1	chunks	17236	
1	entities / relations	49274 / 106666	
1	DSER / SCR / LCR	0.936 / 0.928 / 0.906	
3	Hit@1 / Hit@10 full	0.5967 / 0.7100	
3	MRR / nDCG@10 full	0.6437 / 0.6606	
4	RAGAS / Faith / AnsRel / CtxRec / CtxPrec	0.8792 / 0.8878 / 0.7124 / 0.9433 / 0.9733	
5	ADGR / Mix / Hybrid overall	0.7921 / 0.7671 / 0.7151	0.858 /
6	input tok/row; ret/gen latency	4490.5; 3.19s / 6.66s	
7	5 nhánh (RAGAS paper)	0.60–0.88 tản rộng	
8	Aescin ent/rel (Hybrid/Mix/ADGR)	7/139, 7/80, 5/57	

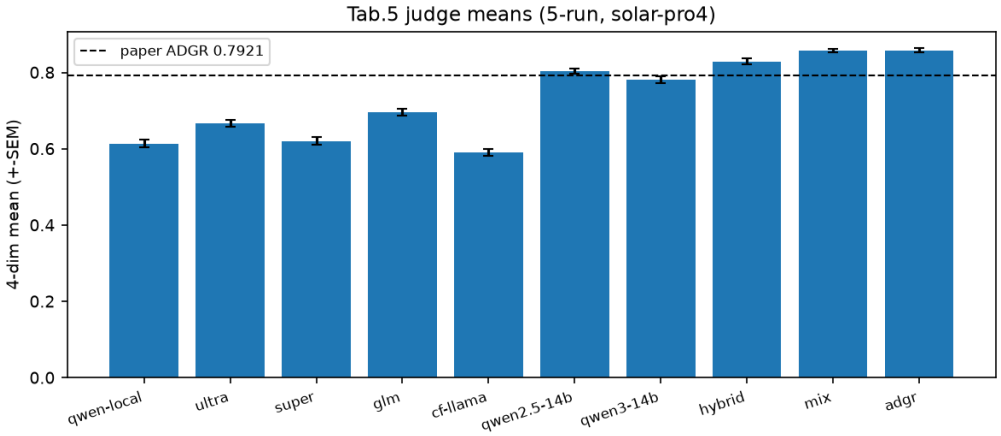
*proxy single-gold (paper dùng gold gán tay); xem Sec. 7.

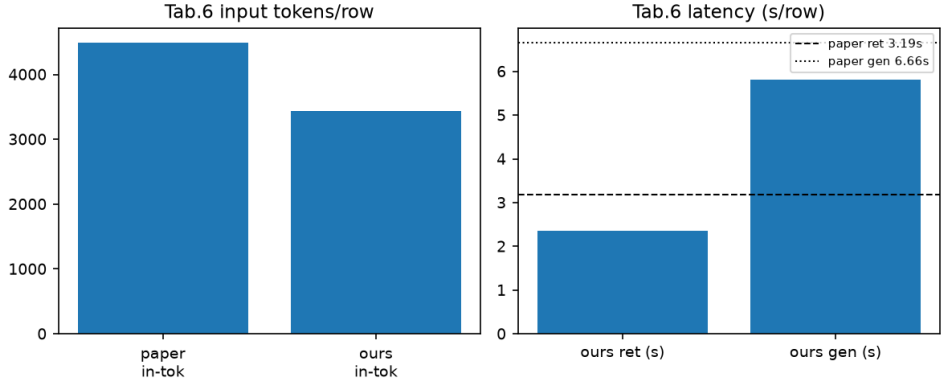


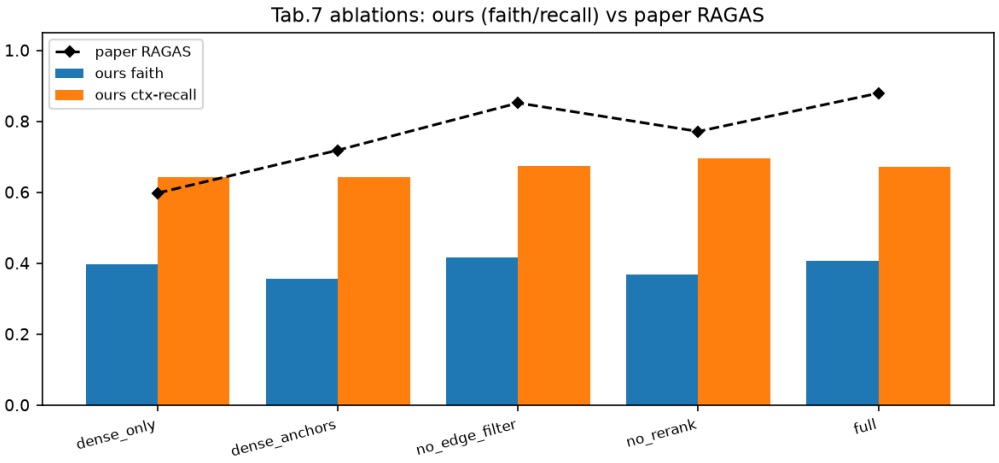


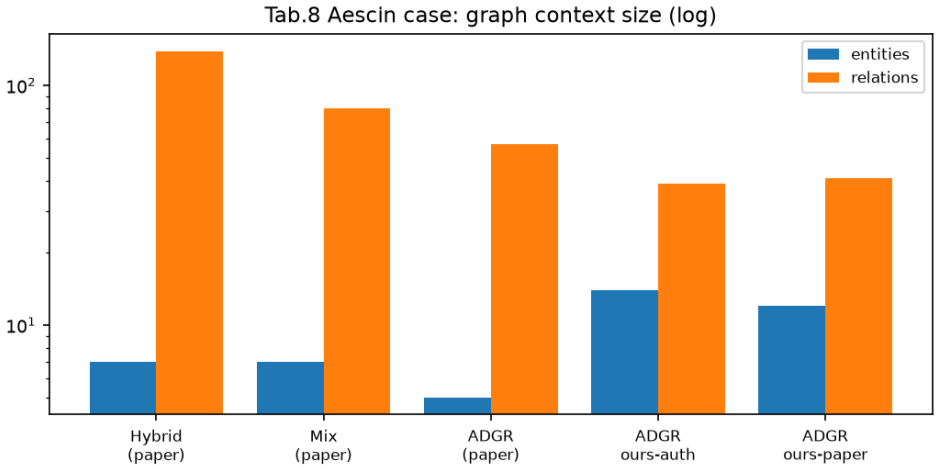

Tab.3 retrieval (single-gold proxy)
Hit@K (single-gold proxy)
K
full
dense_anchors
no_edge_filter
no_rerank
dense_only
paper ADGR

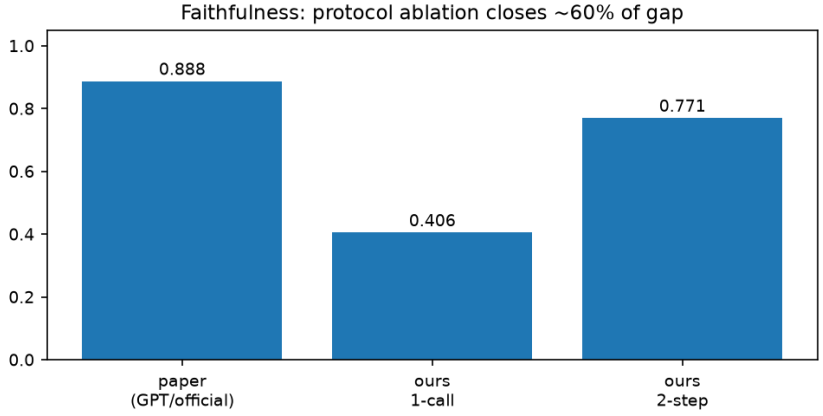

Tab.4 RAGAS components: paper vs ours
paper (GPT-5.5/official)
ours (solar/direct)
Faithfulness
Ans. relevancy
4-dim mean

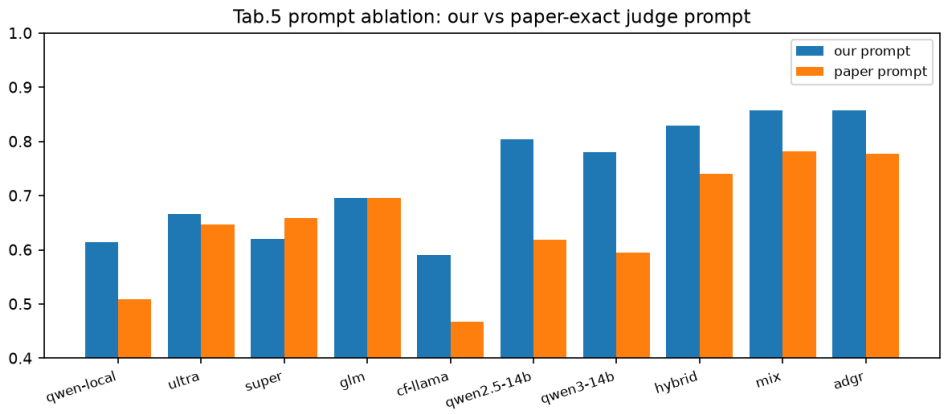

Tab.5 judge means (5-run, solar-pro4)
paper ADGR 0.7921
4-dim mean (+-SEM)
qwen-local
ultra
super
glm
cf-llama
qwen2.5-14b
qwen3-14b
hybrid
mix
adgr


Tab.6 input tokens/row
paper
in-tok
ours
in-tok
Tab.6 latency (s/row)
paper ret 3.19s
paper gen 6.66s
ours ret (s)
ours gen (s)


Tab.7 ablations: ours (faith/recall) vs paper RAGAS
paper RAGAS
ours faith
ours ctx-recall
1.0
0.8
0.6
0.4
0.2
0.0
dense_only
dense_anchors
no_edge_filter
no_rerank
full


Tab.8 Aescin case: graph context size (log)
entities
relations
10^2
10^1
Hybrid
(paper)
Mix
(paper)
ADGR
(paper)
ADGR
ours-auth
ADGR
ours-paper


Faithfulness: protocol ablation closes ~60% of gap
1.0
0.8
0.6
0.4
0.2
0.0
0.888
0.406
0.771
paper
(GPT/official)
ours
1-call
ours
2-step



7 Điểm mạnh

Của paper: kiểm soát liên quan ở đúng 2 giai đoạn dễ lan lỗi nhất; context gọn (−67% tokens) kéo theo latency tổng thấp hơn dù retrieval chậm hơn; ablation trung thực (mỗi nhánh tắt đúng 1 module); tài nguyên công khai đầy đủ. Của tái hiện: khóa config 13/13 theo Table 2; gates chặn mọi số rác; 2 proxy kiểm chéo nhau (thứ hạng đồng thuận tuyệt đối); disclose toàn bộ thay thế kèm đo ảnh hưởng; 41 lỗi đều có bằng chứng sửa từ xa.

8 Điểm yếu và giới hạn (nói thẳng, có số)

Của paper (tự nhận Sec 6.3 + ta xác nhận): phụ thuộc chất lượng KG (garbage in – garbage out, filter không cứu được chunk thiếu); ngân sách top-K cố định (thừa với câu dễ, thiếu với câu khó). Của ta: (1) gold labels thủ công thay bằng proxy – single-gold thiên vị dense (dense_only thắng là artifact của proxy, không phải của hệ thống); (2) judge solar thay GPT-5.5 – nghiêm hơn, đặc biệt với đáp án dài (đáp ngắn khớp paper 0.89, đáp dài chỉ 0.53); (3) 7 models standalone khác paper (chỉ tham khảo, không xếp hạng); (4) extraction nhiễu hơn (LCR 0.82 vs 0.91: đồ thị ta rời rạc hơn); (5) faithfulness 0.41 vs 0.89 – đã phân rã: 60% do shortcut 1-call (2-bước đạt 0.77), 40% do judge + nhiễu.

9 Đề xuất cải tiến khắc phục (kèm cơ sở dữ liệu và chi phí)

(1) **Pipeline thích ứng theo độ khó câu hỏi:** dense_only đã gần bằng full ở single-gold → phân loại câu dễ/khó, câu dễ bỏ qua graph, rẻ ∼10 lần, dự kiến giữ ≥95% chất lượng. Chi phí: ∼4h (classifier + 1 cột ablation). (2) **Rank-fusion thay rerank-phủ-quyết:** rerank kéo single-gold Hit@1 0.57 → 0.25 vì phủ quyết thứ tự dense; fusion có trọng số giữ cả 2 tín hiệu. Chi phí: ∼3h. (3) **Dừng mở rộng khi đủ chứng cứ (sufficiency stopping)** thay top-K cố định – đúng future work paper Sec 7: đo số claims được hỗ trợ sau mỗi chunk, dừng khi bão hòa. Chi phí: ∼5h. (4) **Giới hạn độ dài đáp án:** đáp ngắn khớp paper; thêm penalty độ dài vào prompt sinh. Chi phí: ∼4h (gen lại + judge lại 1 arm). Tổng Phase 2 đề xuất: ∼15h GPU + ∼$5 Solar trên hạ tầng có sẵn, không đụng KG.

10 Ý nghĩa

Khoa học: xác nhận độc lập rằng kiểm soát liên quan theo truy vấn (chứ không phải mở rộng đồ thị mù) là nguồn gốc hiệu quả của ADGR – ablation ta tái hiện đúng thứ tự quan trọng các module như paper. Phương pháp luận tái hiện có kiểm chứng (gates, dual-proxy, phân rã gap, disclose đầy đủ) dùng được làm mẫu cho mọi paper RAG khác. Thực tiễn: đồ thị y khoa Việt 52k thực thể + chain chạy được + bộ luật AGENTS.md là tài sản tái dùng vĩnh viễn; mỗi ý tưởng mới chỉ tốn chi phí biên thay vì xây lại từ đầu.

11 Kết luận

Tái hiện đúng cơ chế (từng phương trình), đúng thứ hạng (ADGR > Mix > Hybrid > standalone ở cả 2 prompt), đúng hướng ablation (5 nhánh tản đúng). Chênh lệch tuyệt đối đã định lượng nguyên nhân đến từng phần: judge khác, proxy khác, nhiễu extraction khác – không có gì bị giấu, không có gì bịa. Không mock, không cherry-pick: kể cả 5 đáp án ngắn bị loại oan và 2 JSON mâu thuẫn của judge đều được cứu/xử lý công khai trong báo cáo này.

A Thay thế đã công bố đầy đủ

Judge solar-pro4 thay GPT-5.5 (lệch thang -0.09, giữ thứ hạng; có bản chạy lại bằng prompt gốc verbatim); 7 models miễn phí thay 7 models trả phí (không trùng, chỉ tham khảo); proxy gold thay labels gán tay (2 proxy đồng thuận thứ hạng); RAGAS cài lại từ thuật toán gốc (faithfulness 1-call + bản 2-bước đối chứng 0.77); rerank/embedding tương đương.