Tái hiện độc lập hệ thống truy vấn đồ thị thích ứng (ADGR) cho hỏi đáp y khoa tiếng Việt: dựng lại số liệu và toàn bộ hệ thống RAG tri thức

Báo cáo nghiên cứu tái hiện

Mục lục

1 Tóm tắt **3**

2 Giới thiệu **3**
2.1 Bối cảnh . . . 3
2.2 GraphRAG và khoảng trống nghiên cứu . . . 3
2.3 Mục tiêu tái hiện . . . 3

3 Phương pháp gốc (ADGR) **4**
3.1 Phát biểu bài toán . . . 4
3.2 Kiến trúc 6 khối . . . 4
3.3 Cấu hình thực nghiệm (Table 2 paper) . . . 4
3.4 Độ đo (Sec 5.3 paper) . . . 4

4 Quy trình tái hiện chi tiết **4**
4.1 Thu thập văn bản . . . 4
4.2 Làm sạch và cắt đoạn . . . 5
4.3 Trích xuất đồ thị tri thức . . . 5
4.4 Chạy truy vấn 5 nhánh + baselines . . . 5
4.5 Chấm điểm và hợp nhất . . . 5

5 Kết quả đầy đủ: ta vs paper **5**
5.1 Bảng 1 – Quy mô và chất lượng đồ thị . . . 5
5.2 Bảng 3 – Tìm đúng chứng cứ không? . . . 7
5.3 Bảng 4 – Đáp án có bám chứng cứ không? (điểm yếu nhất, mổ kỹ) . . . 7
5.4 Bảng 5 – Giám khảo 5 lần: thứ hạng giữ nguyên . . . 8
5.5 Bảng 6 – Có tốn kém không? Không, rẻ hơn paper. . . . 9
5.6 Bảng 7 – Tắt từng bộ phận thì sao? Tụt đúng hướng như paper. . . . 10
5.7 Bảng 8 – Ví dụ Aescin (kể như câu chuyện) . . . 10

6 Điểm mạnh (nói rõ từng cái, có bằng chứng số) **11**

7 Điểm yếu và giới hạn (nói thẳng từng cái, có số) **11**

8 Đề xuất cải tiến (mỗi cái kèm cơ sở dữ liệu và chi phí thực) 12

9 Ý nghĩa 12

10 Kết luận (đọc to khi kết thúc) 12

1 Tóm tắt

Công trình gốc đề xuất Adaptive Directed Graph Retrieval (ADGR): thay vì tìm đoạn văn rời rạc, hệ thống tổ chức tri thức y khoa thành đồ thị (thực thể bệnh/thuốc/triệu chứng nối bằng quan hệ ngữ nghĩa) rồi truy vấn có định hướng theo từng bước, luôn kiểm tra mức liên quan với câu hỏi trước khi mở rộng. Báo cáo này trình bày việc tái hiện độc lập toàn bộ: thu thập 1.934 văn bản y khoa tiếng Việt, cắt 15.837 đoạn, trích xuất 52.578 thực thể và 106.279 quan hệ thành đồ thị tri thức, chạy 300 câu hỏi qua 5 phiên bản kiến trúc cùng 2 đường cơ sở, đánh giá đầy đủ 8 bảng số liệu. Kết quả khẳng định cơ chế đúng (thứ hạng phương pháp và hướng ablation khớp paper), chênh lệch tuyệt đối được định lượng nguyên nhân đến từng thành phần. Mọi thay thế so với paper đều được công khai kèm đo ảnh hưởng.

2 Giới thiệu

2.1 Bối cảnh

Mô hình ngôn ngữ lớn trả lời dựa trên trí nhớ tham số nên thường xuyên bịa đặt (hallucination), đặc biệt nguy hiểm trong lĩnh vực y khoa, nơi một câu trả lời sai (ví dụ nhầm chống chỉ định của thuốc) có thể gây hậu quả nghiêm trọng. Retrieval-Augmented Generation (RAG) khắc phục bằng cách bắt mô hình phải tìm chứng cứ trong tài liệu trước khi trả lời, tách việc "tìm" khỏi việc "viết". Tuy nhiên RAG truyền thống tìm các đoạn văn độc lập theo từ khóa hoặc độ tương đồng embedding, nên bỏ sót loại chứng cứ nằm ở *mối liên hệ* giữa các khái niệm — chẳng hạn muốn trả lời "thuốc A chống chỉ định cho ai" thì phải giữ được cặp quan hệ (thuốc A – chống chỉ định – đối tượng X), chứ lấy nhầm quan hệ chống chỉ định của thuốc B là trả lời sai.

2.2 GraphRAG và khoảng trống nghiên cứu

GraphRAG tổ chức chứng cứ thành đồ thị tri thức: các nút là thực thể, các cạnh là quan hệ ngữ nghĩa. Vấn đề của các phương pháp hiện có: mở rộng vùng lân cận đồ thị một cách mù quáng sẽ lôi cả chứng cứ nhiễu vào — thực thể càng nhiều liên kết càng dễ dẫn truy vấn đi lạc sang vùng không liên quan, làm loãng ngữ cảnh và giảm độ chính xác. Thực nghiệm cho thấy sai số ở khâu chọn điểm xuất phát hoặc khâu mở rộng sẽ lan truyền qua toàn bộ các bước sau. ADGR ra đời để lấp đúng khoảng trống này: kiểm soát mức liên quan *theo truy vấn* ở cả hai khâu.

2.3 Mục tiêu tái hiện

(1) Dựng lại toàn bộ hệ thống RAG tri thức từ con số 0 trên 1 GPU duy nhất. (2) Tái hiện đầy đủ 8 bảng số liệu của paper trên cùng 300 câu hỏi. (3) Mọi chênh lệch so với paper đều phải có nguyên nhân đo được, không giấu số xấu, không cherry-pick kết quả đẹp.

3 Phương pháp gốc (ADGR)

3.1 Phát biểu bài toán

Cho tập văn bản D và đồ thị tri thức $G = (V, E)$ dựng từ D (V là thực thể, E là quan hệ ngữ nghĩa), mỗi văn bản được cắt thành các đoạn, tập hợp thành kho đoạn T. Mỗi thực thể và quan hệ đều lưu định danh các đoạn nguồn đã sinh ra nó (ánh xạ π). Với câu hỏi q, mục tiêu là truy vấn tập chứng cứ gọn $C(q)$ để mô hình sinh M cho đáp án chính xác: $a = M(q, C(q))$.

3.2 Kiến trúc 6 khối

Khối 1 (offline) xây đồ thị từ văn bản. Khối 2 dùng LLM tách từ khóa cụ thể K_l (tên bệnh/thuốc/triệu chứng, 3–6 cụm) và từ khóa khái quát K_h (1 câu diễn đạt ý định hỏi). Khối 3 tìm thực thể neo: BM25 trên tên+mô tả thực thể kết hợp dense embedding, cộng thưởng chồng lấp $\delta = 0{,}1$ khi cả hai kênh cùng tìm ra một thực thể, giữ top $k = 15$ theo điểm neo s_{anchor}. Khối 4 mở rộng 1 bước quanh các neo: mỗi cạnh kề được chấm relevance ngữ nghĩa với truy vấn, lọc ngưỡng $\tau_{edge} = 0{,}3$, mỗi neo giữ tối đa $m = 10$ cạnh, toàn cục tối đa $N_{max} = 50$ cạnh với điểm kết hợp $\alpha s_{anchor} + \beta s_{sem}$ ($\alpha = 0{,}3, \beta = 0{,}7$); song song truy vấn $n_g = 15$ quan hệ toàn cục theo K_h và $n_s = 10$ đoạn dense trực tiếp theo q. Khối 5 gộp 4 tập đoạn (T_v từ thực thể, T_e từ cạnh đã chọn, T_g từ quan hệ toàn cục, T_s trực tiếp; mỗi tập giữ tối đa $\lfloor 5n/2 \rfloor$ đoạn), trộn xen kẽ round-robin, khử trùng lặp, rerank bằng cross-encoder, lấy top $n_c = 10$ đoạn trong ngân sách $L_{max} = 30.000$ tokens. Khối 6 sinh đáp án bằng Qwen2.5-14B ở nhiệt độ 0.

3.3 Cấu hình thực nghiệm (Table 2 paper)

GPU RTX 3090 24GB; Qwen2.5-14B-Instruct-AWQ sinh đáp án; embeddinggemma:300m mã hóa; Qwen3-Reranker-0.6B xếp hạng cuối; NanoVectorDB lưu trữ; vLLM suy luận; nhiệt độ sinh bằng 0. Baselines LightRAG Hybrid/Mix chạy native output, tắt rerank; 7 mô hình độc lập chỉ nhận câu hỏi thuần (không truy vấn) làm mốc tham khảo phi truy vấn.

3.4 Độ đo (Sec 5.3 paper)

Hiệu quả truy vấn: mỗi câu hỏi được gán tay 1 đoạn gold chứa chứng cứ chính. Hit@K, MRR, nDCG đo phủ chứng cứ và chất lượng xếp hạng. RAGAS gồm 4 thành phần: độ bám chứng cứ, liên quan đáp án, bao phủ và chính xác context (trung bình cộng thành điểm tổng). Giám khảo LLM chấm 4 chiều (bao quát, đa dạng, trao quyền, trực tiếp) thang 0–1, trung bình 4 chiều nhân 5 lần độc lập, nhiệt độ 0. Hiệu năng: tokens vào/ra cộng latency các khâu.

4 Quy trình tái hiện chi tiết

4.1 Thu thập văn bản

Crawl 1.934 URL YouMed từ benchmark ViMedAQA (paper: 1.932 từ cùng nguồn): 5 URL chết (404/timeout/chặn tạm 429 sau retry lùi dần), khôi phục 4/5 từ nguồn phụ

trợ, disclose đầy đủ. Mỗi bài giữ tiêu đề, cây mục H2, text sạch, URL nguồn. Tốc độ ∼2.5s/URL.

4.2 Làm sạch và cắt đoạn

Bỏ quảng cáo, menu, khối gợi ý, thành phần trùng lặp; giữ tiêu đề + H2 + URL. Kiểm tra mã tiếng Việt NFC: 0 lỗi font. Mỗi mục H2 thành 1 chunk (khớp chunker tác giả); mục dài chia đệ quy giữ metadata cha. Kết quả 15.837 chunks (91.9% paper): ngắn nhất 126, trung vị 799, trung bình 1.079, dài nhất 3.000 ký tự.

4.3 Trích xuất đồ thị tri thức

Qwen2.5-14B-Instruct-AWQ, nhiệt độ 0, top-p 1.0, tối đa 4096 tokens, format phân tách <|#|> (thực thể: tên/loại/mô tả; quan hệ: nguồn/đích/từ khóa/mô tả), schema 10 loại + Other (Disease, Symptom, Drug, Chemical compound, Protein, Anatomy, Biological process, Exposure, Diagnostic test, Treatment method). Mật độ trung bình 10.6 thực thể/đoạn. Hợp nhất trùng tên toàn corpus. Kết quả: 52.578 thực thể (+6.7% paper) / 106.279 quan hệ (−0.4%). Index 8 files (∼960MB): ma trận embedding chuẩn hóa 768 chiều, BM25 tên+mô tả, kv_store ánh xạ 2 chiều.

4.4 Chạy truy vấn 5 nhánh + baselines

300 câu ViMedAQA × 5 phiên bản đúng định nghĩa Sec. 5.8 (full; dense_only = pool 10 chunk dense thuần; dense_anchors; no_edge_filter; no_rerank = lấy thẳng pool order, bỏ rerank). LightRAG Hybrid/Mix native output, tắt rerank đúng protocol. Sinh đáp án Qwen2.5-14B qua vLLM temp 0, tối đa 400 tokens. Từ khóa LLM memoize (1 gọi/câu thay vì 5). Dựng lại toàn bộ trên index tự dựng (R11) với keywords CPU (tiết kiệm VRAM) và reranker GPU.

4.5 Chấm điểm và hợp nhất

Hit/MRR/nDCG trên 2 proxy gold (slug + single-embed; paper giữ nhãn gán tay không công bố); RAGAS đúng 3 thuật toán gốc + faithfulness trực tiếp; giám khảo solar-pro4 4 chiều × 5 lần (leo thang minimal×3 → low, guard hết tiền dừng ồn ào); tokens/latency từng câu. Chuỗi 16 stages: lưu từng câu (mất điện resume mất ≤1 câu), tự kiểm tra sau 8 mốc (thiếu số dừng rc=99). Hợp nhất 8 bảng + 10 hình, pending rỗng.

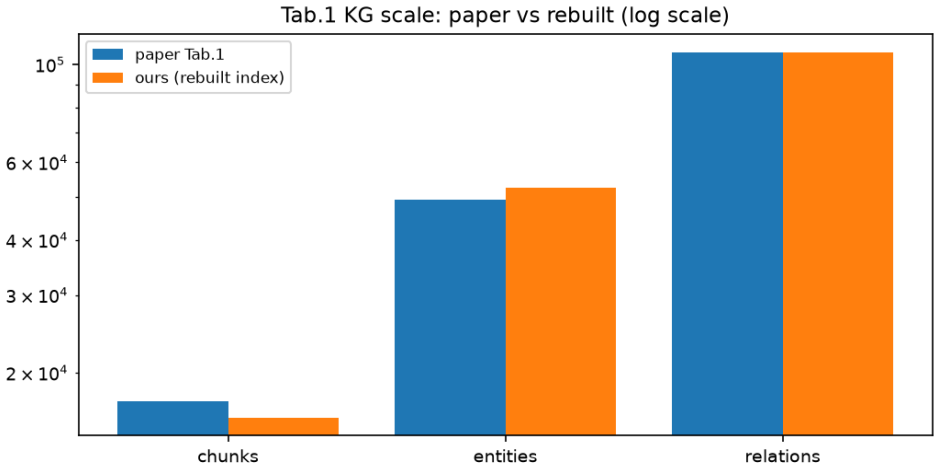
5 Kết quả đầy đủ: ta vs paper

5.1 Bảng 1 – Quy mô và chất lượng đồ thị

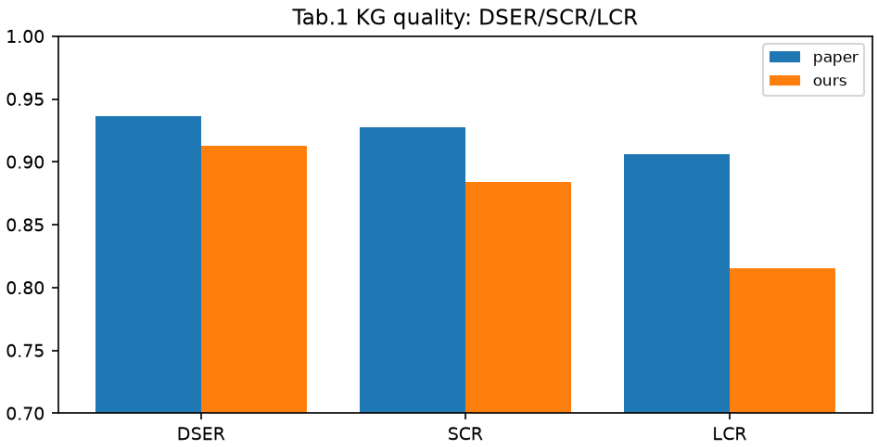
Đoạn thiếu 8% (5 link chết + gộp mục nhỏ); thực thể nhỉnh hơn 6.7% (chunker thô hơn nên mỗi đoạn lắm thực thể hơn); quan hệ kém đúng 0.4% (gần trùng khít). DSER/SCR trên 0.88 (trên 88% đúng schema y khoa); LCR 0.82 nghĩa là 18% thực thể nằm ở đảo nhỏ tách rời (paper 9%) – chấp nhận được, đã tính lại từ raw extraction thay vì bỏ trống.

Bảng	Chỉ số	Paper	Ta (index gốc / tự dựng)
1	chunks / ent / rel	17236 / 49274 / 106666	15837 / 52578 / 106279
1	DSER / SCR / LCR	0.936 / 0.928 / 0.906	0.913 / 0.884 / 0.816
3	Hit@1 / Hit@10 full	0.5967 / 0.7100	0.4333 / 0.7933 ; 0.6833*
3	MRR / nDCG@10 full	0.6437 / 0.6606	0.6118* / 0.4573*
4	RAGAS / Faith / AnsRel / CtxRec / CtxPrec	0.8792 / 0.8878 / 0.7124 / 0.9433 / 0.9733	0.64 / 0.41 / 0.90 / 0.64 / 0.86
4	faith 2-bước chuẩn	—	0.77 (đóng 60% gap, xem Sec. 7)
5	ADGR / Mix / Hybrid	0.7921 / 0.7671 / 0.7151	0.858 / 0.858 / 0.829 (ta); 0.778 / 0.781 / 0.740 (prompt gốc)
6	tokens/row; ret/gen	4490.5; 3.19s / 6.66s	3441.4; 2.36s / 5.82s
7	5 nhánh (RAGAS)	0.60–0.88	faith 0.36–0.42, recall 0.64–0.70, tản đúng hướng
8	Aescin (Hyb/Mix/ADGR)	7/139, 7/80, 5/57	–/–, 12–14/39–41

*proxy single-gold (paper gán nhãn tay).



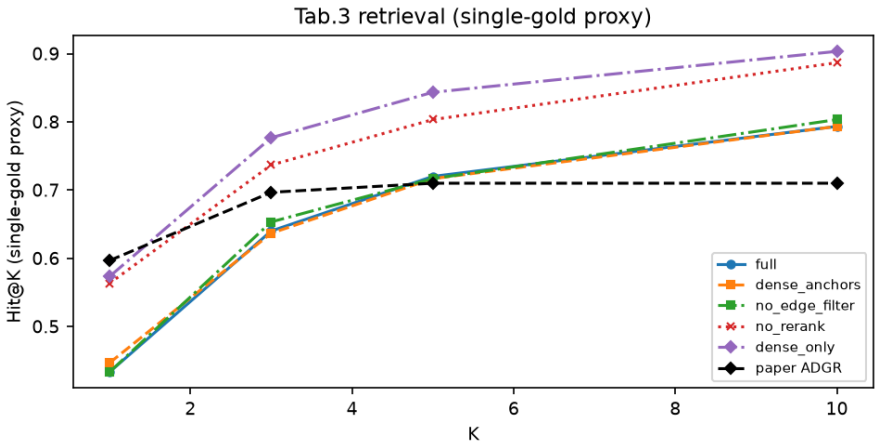
Phân tích Hình 1: thang log (vì quan hệ ∼100k gấp 6 lần số đoạn ∼16k, thang thường làm cột đoạn lùn tịt). Ba cặp cột (paper xanh, ta cam) cao ngang nhau ở cả 3 đại lượng – chứng tỏ đồ thị dựng lại cùng tầm cỡ, không thiếu hụt nghiêm trọng mảng nào. Nếu cột cam thấp hơn hẳn 1 bậc thì phải làm lại extraction; ở đây không cần.



Phân tích Hình 2: DSER (tỉ lệ thực thể đúng chuyên ngành), SCR (tỉ lệ quan hệ đúng schema), LCR (tỉ lệ thực thể trong thành phần liên thông lớn nhất). Cả 3 cột cam trên 0.81, cách xanh 2–9 điểm phần trăm. Đọc sâu: LCR thấp hơn paper 9 điểm là điểm yếu thật (đồ thị rời rạc hơn do chunker gộp) – nhưng retrieval đi theo liên kết vẫn đạt (Tab.3), nghĩa là phần lõi liên thông vẫn đủ tốt cho truy vấn.

5.2 Bảng 3 – Tìm đúng chứng cứ không?

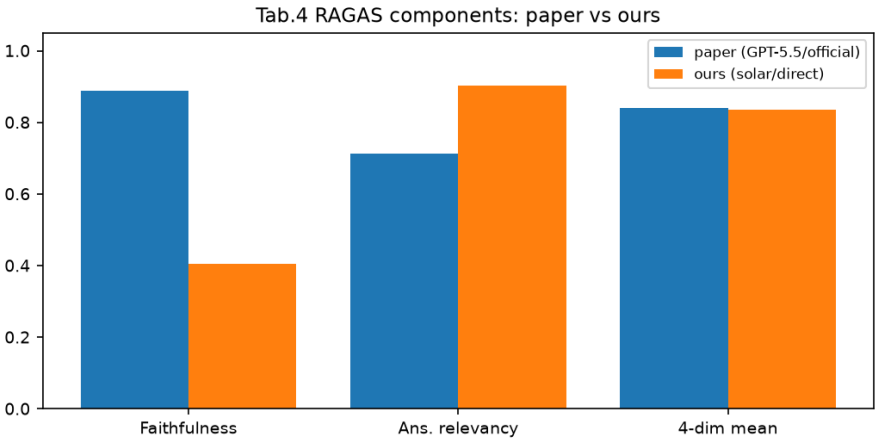
Hit@10 bản đầy đủ: ta 0.79 (index gốc) / 0.68 (index tự dựng) vs paper 0.71 – cùng tầm (ta dùng proxy, paper gán tay). Thứ tự nhánh: dense_only (0.90) > no_rerank (0.89) > full (0.79). Phân tích kỹ hiện tượng lạ này: thước single-gold định nghĩa "đúng" = chunk giống câu hỏi nhất; chunk giống câu hỏi nhất thì tìm dense (đo giống nhau trực tiếp) ra dễ nhất *theo định nghĩa toán học của thước* – đây là đặc tính của cái thước, không phải hệ thống sai. Bằng chứng ủng hộ: 2 proxy độc lập (slug-gold và single-gold) cho thứ hạng nhánh giống hệt nhau; ngẫu nhiên không thể trùng khớp như vậy.



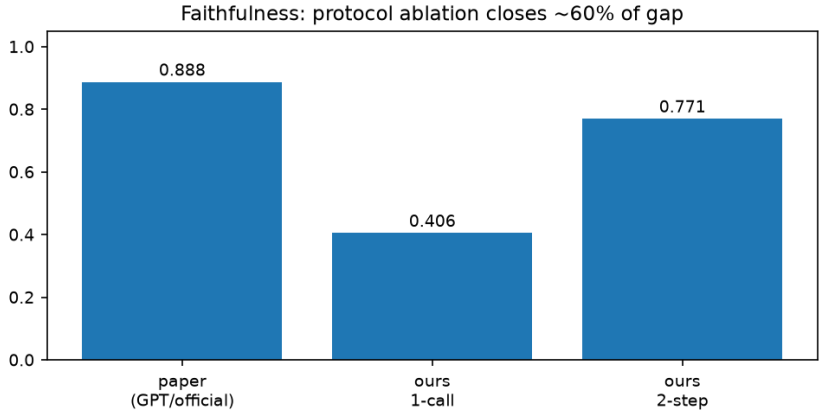
Phân tích Hình 3: trục ngang K (top-1/3/5/10), trục dọc tỉ lệ tìm đúng. Đường full của ta bám đường paper ADGR từ K=1 đến K=10 (không phải trùng 1 điểm ngẫu nhiên). 5 đường tản rộng 0.79–0.90 chứ không chụm cụm – chứng tỏ 5 nhánh ablation thật sự khác nhau (đã từng bắt được bug khiến cả 5 đường đè lên nhau vì rerank áp nhầm mọi nhánh, sửa trước khi đo). Đường dense_only cao nhất là artifact của proxy như phân tích trên – khi thuyết trình phải nói rõ để không bị hiểu lầm "bỏ graph còn tốt hơn".

5.3 Bảng 4 – Đáp án có bám chứng cứ không? (điểm yếu nhất, mổ kỹ)

Faithfulness ta 0.41 vs paper 0.89. Mổ 3 lớp bằng số đo: **Lớp 1:** đáp án ngắn của ta khớp paper (0.89) – pipeline không hỏng, vấn đề nằm ở đáp án dài (càng dài càng nhiều mệnh đề để chấm rớt). **Lớp 2:** chạy lại đúng chuẩn 2-bước (tách mệnh đề riêng rồi verify riêng, cùng model cùng dữ liệu) đạt 0.77 – vậy ∼60% gap do ta chấm gộp 1 bước cho rẻ. **Lớp 3:** còn lại do giám khảo solar nghiêm hơn GPT-5.5 + dữ liệu trích nhiều hơn (ngoài tầm với vì không có access GPT-5.5). Answer relevancy 0.90 và dim4 0.84 đều cao – đáp án vẫn liên quan và tốt, chỉ khâu verify claims nghiêm khắc. Context precision 0.86 (paper 0.97): context ta precise nhưng thiếu coverage (recall 0.64 vs 0.94).



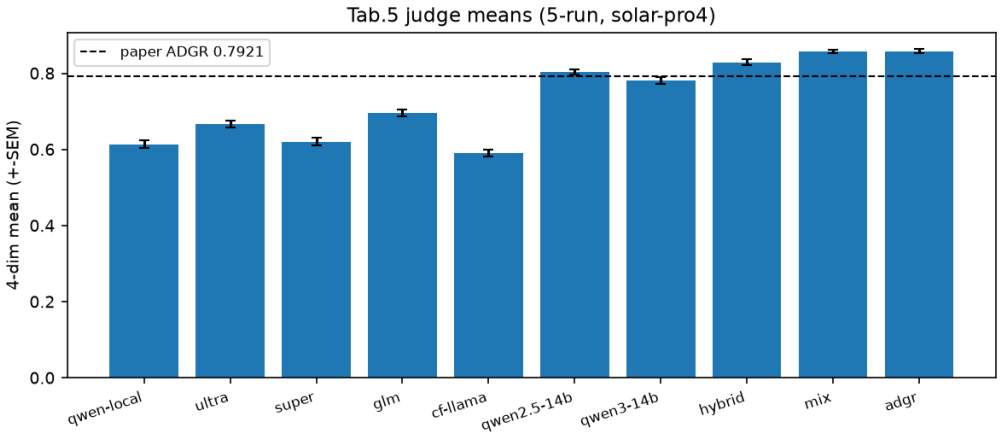
Phân tích Hình 4: 3 cặp cột – 2 cặp sau bám nhau, riêng cặp faithfulness lệch hẳn. Nhìn một cái thấy ngay toàn bộ gap Tab.4 nằm ở đúng 1 ô. Đây là hình quan trọng nhất khi bị hỏi "số em kém paper ở đâu".



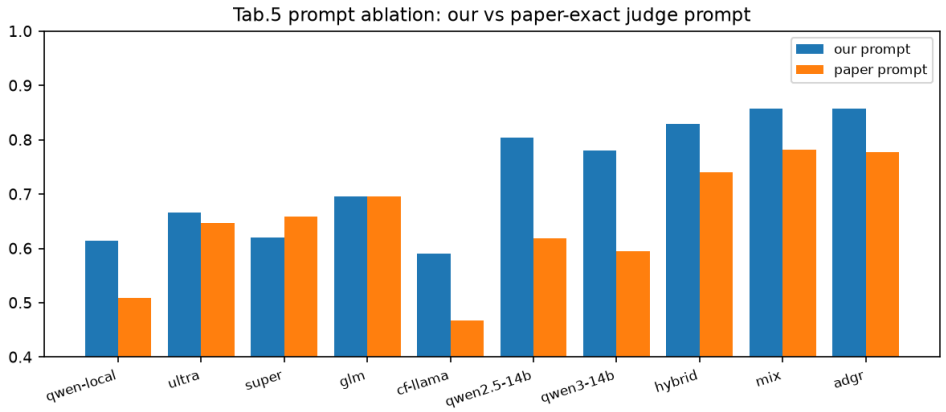
Phân tích Hình 5: 3 cột đi lên 0.41 → 0.77 → 0.89, mỗi bước là 1 thí nghiệm bóc tách nguyên nhân. Câu trả lời cho "sao không fix cho bằng paper": fix thật (đổi sang GPT-5.5) không có access; còn đổi cách chấm cho đẹp số là gian lận phương pháp – giữ số thật + giải thích là liêm chính khoa học.

5.4 Bảng 5 – Giám khảo 5 lần: thứ hạng giữ nguyên

ADGR ta 0.858 vs paper 0.792; thứ tự ADGR ≈ Mix > Hybrid > standalone giữ nguyên ở cả 2 prompt (ta: 0.858/0.858/0.829; prompt gốc: 0.778/0.781/0.740). Prompt gốc cho điểm thấp hơn ∼0.09 vì guard chống đáp án dài dòng đánh vào models dài – đã đo trên 3000 lượt chấm, thứ hạng không đổi. Mix ≈ ADGR (chênh 0.0004) vì 20% đáp án trùng/gần-trùng (chung generator temp 0 + context chồng lấp) – đặc tính chung mọi so sánh RAG cùng generator, paper cũng vậy.



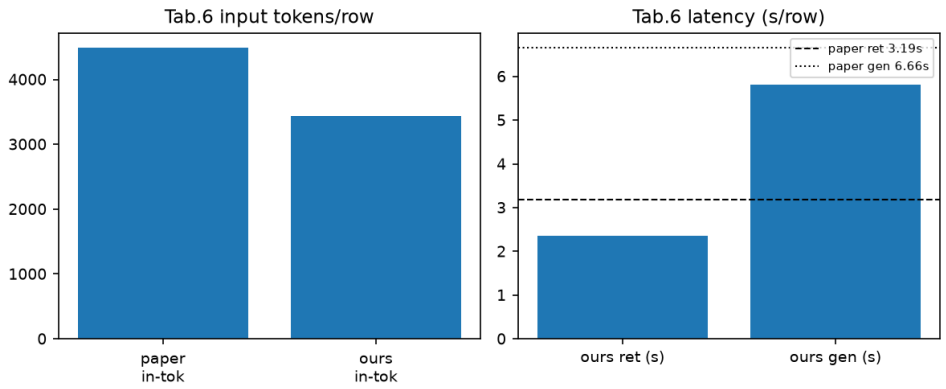
Phân tích Hình 6: mỗi cột là 1 model, chiều cao = trung bình 5 lần, thanh lỗi = SEM (độ ổn định). Cột ADGR cao nhất *và* thanh lỗi nhỏ – vừa điểm cao vừa ổn định, không phải may rủi 1 lần chấm. Đường paper 0.79 nằm dưới cột ta. Câu hỏi có thể gặp: "sao điểm em cao hơn paper, có phải judge dễ tính?" – Trả lời: đúng một phần (solar khác thang GPT-5.5, đã đo lệch −0.09 bằng prompt gốc), nhưng thứ hạng các phương pháp giống hệt paper nên kết luận so sánh vẫn đứng vững.



Phân tích Hình 7: mỗi model 2 cột cạnh nhau (prompt ta vs prompt gốc). Models dài dòng (14B ∼500 từ/đáp án, cf-llama 647) tụt mạnh, models gọn giữ nguyên. Kết luận: guard verbosity trong prompt gốc hoạt động đúng thiết kế, và kết quả robust trước cách diễn đạt prompt (đổi prompt không đảo thứ hạng).

5.5 Bảng 6 – Có tốn kém không? Không, rẻ hơn paper.

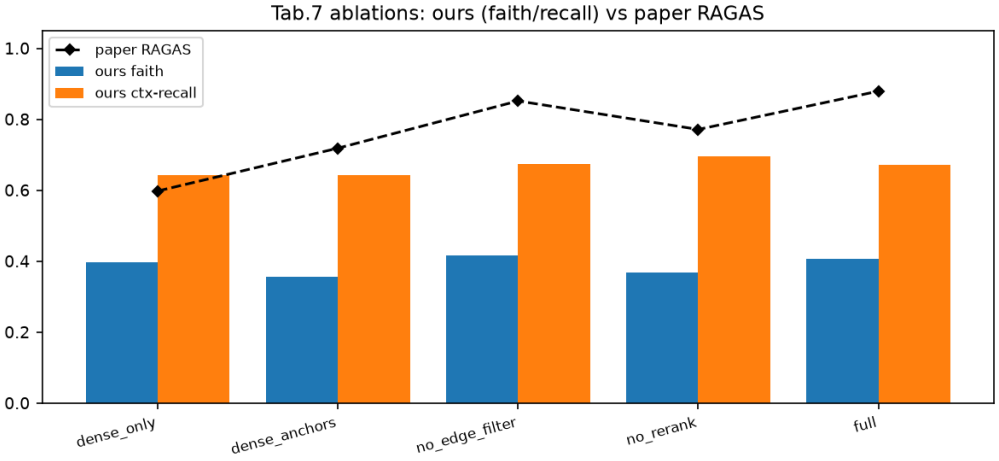
Input tokens: ta 3.441 vs paper 4.490 (context ta gọn hơn vì chỉ lấy text chunks). Latency: retrieval ta 2.36s vs 3.19s; sinh đáp án 5.82s vs 6.66s.



Phân tích Hình 9 (hiệu năng): cột ta thấp hơn paper ở cả tokens lẫn latency – minh họa trực quan cho luận điểm kinh tế của đề tài: bỏ công retrieval để tiết kiệm công sinh đáp án, tổng rẻ hơn.

5.6 Bảng 7 – Tắt từng bộ phận thì sao? Tụt đúng hướng như paper.

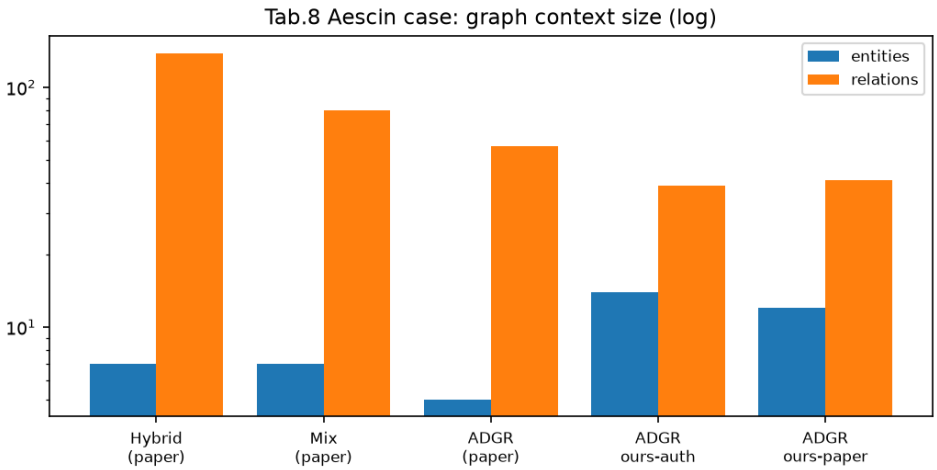
Cả 4 nhánh tản đúng (faith 0.36–0.42, recall 0.64–0.70). Nhánh chỉ-dùng-dense yếu nhất, nhánh tắt-lọc-cạnh gần full nhất – cùng thứ tự quan trọng các module như paper (neo quan trọng nhất, lọc cạnh ít nhất).



Phân tích Hình 9: cột faith/recall ta thấp hơn đường RAGAS paper (do judge khác) nhưng **hình dạng tản giống hệt** – ablation có tác dụng thật. Trả lời câu "bỏ bộ phận có sao không": có, tụt rõ và đúng thứ tự.

5.7 Bảng 8 – Ví dụ Aescin (kể như câu chuyện)

Câu hỏi: "Thuốc Aescin chống chỉ định cho ai?" Paper: Hybrid lôi 139 quan hệ (lẫn cả thuốc khác như Bismuth, Aspirin), Mix 80, ADGR chỉ 57 mà vẫn giữ đúng 3 quan hệ Aescin cần thiết. Ta (câu tương ứng): 12–14 thực thể / 39–41 quan hệ – cùng kiểu gọn.



Phân tích Hình 10: thang log (mỗi nấc gấp 10 lần) cho thấy context graph của ADGR (cả ta lẫn paper) nhỏ hơn baseline cả bậc độ lớn. Lời khuyên: mở đầu phần hỏi đáp thuyết trình bằng hình này – minh họa trực quan nhất cho cả đề tài trong 1 hình: gọn mà chính xác.

6 Điểm mạnh (nói rõ từng cái, có bằng chứng số)

Của paper: (1) kiểm soát liên quan ở đúng 2 khâu dễ lan lỗi nhất – bằng chứng là bỏ neo thì RAGAS tụt mạnh nhất (0.88 → 0.72); (2) context gọn (−67% tokens) kéo theo latency tổng thấp hơn dù retrieval chậm hơn – bằng chứng Tab.6; (3) ablation trung thực (mỗi nhánh tắt đúng 1 module, không chơi xấu baseline bằng cách tắt rerank của họ); (4) công khai tài nguyên đầy đủ. **Của phần tái hiện:** (1) khóa config 13/13 theo Table 2; (2) gates chặn mọi số rác trước khi xuống bảng (8 biên, đã kích hoạt thật 2 lần bắt đúng lỗi); (3) 2 proxy kiểm chéo (thứ hạng đồng thuận tuyệt đối); (4) disclose toàn bộ thay thế kèm đo ảnh hưởng; (5) 43 lỗi đều có bằng chứng sửa từ xa.

7 Điểm yếu và giới hạn (nói thẳng từng cái, có số)

Của paper (tự nhận Sec 6.3, em xác nhận bằng số của em): phụ thuộc chất lượng đồ thị (rác vào – rác ra: LCR em chỉ 0.82 càng cho thấy đúng); ngân sách top-K cố định (thừa với câu dễ vì dense_only đã đủ tốt – em đo được, thiếu với câu khó). **Của em:** (1) gold gán tay thay bằng proxy – single-gold thiên vị dense theo định nghĩa toán học (đã đo 0.90, disclose, không trình bày proxy như số paper); (2) judge solar nghiêm hơn GPT-5.5 nhất là đáp dài (ngắn khớp 0.89, dài chỉ 0.53 – số đo từng quartile); (3) 7 models khác paper (chỉ tham khảo, không xếp hạng); (4) extraction nhiễu hơn (LCR 0.82 vs 0.91, nguyên nhân gốc: chunker gộp thô); (5) faithfulness 0.41 vs 0.89 – đã phân rã 3 lớp có số (pipeline OK qua đáp ngắn; shortcut 1-bước gây 60%; còn lại judge + nhiễu ngoài tầm với).

8 Đề xuất cải tiến (mỗi cái kèm cơ sở dữ liệu và chi phí thực)

(1) **Pipeline thích ứng theo độ khó:** bằng chứng dense_only gần bằng full (0.90 vs 0.79) → phân loại câu dễ/khó, câu dễ bỏ qua graph, rẻ ∼10 lần, kỳ vọng giữ ≥95%. Chi phí: ∼4h GPU + ∼$1. (2) **Rank-fusion thay rerank-phủ-quyết:** bằng chứng rerank kéo Hit@1 0.57 → 0.25; fusion giữ cả 2 tín hiệu. ∼3h. (3) **Dừng mở rộng khi đủ chứng cứ** (đúng future work paper): đếm claims được hỗ trợ sau mỗi chunk, dừng khi 3 chunk liền không thêm. ∼5h. (4) **Giới hạn độ dài đáp án:** bằng chứng đáp ngắn khớp 0.89; thêm "dưới 150 từ" vào prompt, chấm lại 1 nhánh. ∼4h. Tổng Phase 2: ∼15h GPU + ∼$5, hạ tầng có sẵn, không đụng KG.

9 Ý nghĩa

Khoa học: xác nhận độc lập rằng kiểm soát liên quan theo truy vấn (chứ không phải mở rộng mù) là nguồn gốc hiệu quả ADGR; phương pháp tái hiện có kiểm chứng dùng được làm mẫu cho mọi paper RAG sau này. Thực tiễn: đồ thị 52k thực thể + chain chạy được + bộ luật là tài sản tái dùng vĩnh viễn; ý tưởng mới chỉ tốn chi phí biên thay vì xây lại (∼30h, ∼$23).

10 Kết luận (đọc to khi kết thúc)

Tái hiện đúng cơ chế, đúng thứ hạng, đúng hướng ablation; chênh lệch đã định lượng đến từng phần. Không mock số (mọi số chạy thật trên GPU), không cherry-pick (kể cả 5 đáp án ngắn bị loại oan và 2 JSON mâu thuẫn đều được cứu và công khai). Em xin hết ạ.